ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Đồ án 1

Đề tài: Tiền xử lý dữ liệu

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

22120457 - Khưu Hải Châu

23122006 - Lưu Thượng Hồng

23122020 - Nguyễn Thiên Ấn

23122034 - Lê Nguyên Khang

23122036 - Nguyễn Ngọc Khoa

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhựt Nam

Ngày 20 tháng 4 năm 2026

Mục lục

1 Giới thiệu **1**

2 Phân công công việc **1**

3 Tiền xử lý dữ liệu ảnh **1**

3.1 Dữ liệu sử dụng 1

3.2 Phân tích khám phá dữ liệu ảnh 2

3.2.1 Phân phối giá trị pixel theo từng kênh màu 2

3.2.2 Khám phá phân bố lớp 3

3.2.3 Kiểm tra ảnh trùng lặp 3

3.2.4 Độ sáng và tương phản theo lớp 4

3.3 Các kỹ thuật tiền xử lý ảnh và đánh giá định lượng 5

3.3.1 Thay đổi kích thước ảnh 5

3.3.2 Chuyển đổi không gian màu 6

3.3.3 Chuẩn hóa dữ liệu 7

3.3.4 Tăng cường dữ liệu (Data Augmentation) 8

3.3.5 Phân tích PCA trên không gian đặc trưng ảnh 9

3.3.6 Phát hiện cạnh và phân tích đặc trưng cục bộ 10

3.3.7 Tổng kết Ablation Study 12

3.4 Kết luận 12

4 Tiền xử lý dữ liệu dạng bảng **13**

4.1 Dữ liệu sử dụng 13

4.2 Phân tích khám phá dữ liệu dạng bảng 14

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 15

4.3.1 Xử lý giá trị thiếu có kiểm soát 15

4.3.2 Phát hiện và xử lý ngoại lai 16

4.3.3 Chuẩn hóa dữ liệu có kiểm định 18

4.3.4 Mã hóa biến phân loại nâng cao 19

4.3.5 Lựa chọn và giảm chiều đặc trưng 19

4.3.6 Xử lý mất cân bằng lớp 21

4.4 Đánh giá pipeline 23
4.4.1 Tổng hợp cấu hình tốt nhất 23
4.4.2 Tạo dataset tiền xử lý cuối 24
4.5 Kết luận 24

5 Tiền xử lý dữ liệu chuỗi thời gian 25
5.1 Dữ liệu sử dụng 25
5.2 Phân tích khám phá chuỗi thời gian 25
5.2.1 Time Plot 26
5.2.2 Phân tích tương quan ACF và PACF 27
5.2.3 Rolling statistics 28
5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 29
5.3.1 Xử lý khoảng trống thời gian và nội suy 29
5.3.2 Kiểm định tính dừng (Stationarity Tests) 30
5.3.3 Phân rã chuỗi thời gian 31
5.3.4 Feature Engineering & Phát hiện dị thường 32
5.4 Đánh giá pipeline 36
5.4.1 Đánh giá pipeline bằng dự báo một bước 36
5.4.2 Phân tích nhân quả Granger đa biến 37
5.5 Kết luận 39

6 Kết luận 40

Tài liệu 41

1 Giới thiệu

Báo cáo này trình bày quá trình tiền xử lý dữ liệu cho ba nhóm bài toán của đồ án: **dữ liệu ảnh**, **dữ liệu bảng** và **dữ liệu chuỗi thời gian**. Trọng tâm của nhóm là triển khai các kỹ thuật theo đề bài, đo lường định lượng tác động của từng bước, thảo luận và đưa ra lựa chọn cuối cùng dựa trên bằng chứng thực nghiệm.

2 Phân công công việc

MSSV	Họ và tên	Công việc
22120457	Khưu Hải Châu	Phân tích dữ liệu ảnh
23122006	Lưu Thượng Hồng	Viết báo cáo, QA
23122020	Nguyễn Thiên Ấn	Viết báo cáo, QA
23122034	Lê Nguyên Khang	Phân tích dữ liệu dạng bảng
23122036	Nguyễn Ngọc Khoa	Phân tích dữ liệu chuỗi thời gian

Bảng 1: Phân công công việc của nhóm

3 Tiền xử lý dữ liệu ảnh

3.1 Dữ liệu sử dụng

Nhóm sử dụng tập dữ liệu *Intel Image Classification Dataset* (Bansal, 2019) cho phần dữ liệu ảnh. Đây là một dataset rất phổ biến cho bài toán image classification, gồm 6 classes là *buildings, forest, glacier, mountain, sea, street.*

Tập dữ liệu đáp ứng được yêu cầu của đề bài. Tóm tắt thông tin tại bảng 2.

Tiêu chí	**Yêu cầu**	**Thực tế**
Số ảnh	$\geq$ 5,000	$\sim$ 25,000
Kích thước ảnh	Đồng nhất	150×150×3
Số lớp	$\geq$ 5	6 lớp

Bảng 2: Kiểm tra tiêu chí lựa chọn dữ liệu ảnh

Mặc dù tập dữ liệu đã được chia sẵn thành train và test set, nhưng do yêu cầu của bài tập tập trung vào bước tiền xử lý và số lượng ảnh trong dataset khá lớn khiến thời gian tính toán bị kéo

dài. Vì vậy, **trong phạm vi bài tập này, nhóm chỉ chọn ngẫu nhiên 5,000 ảnh từ tập train để tiến hành xử lý và đánh giá.**

3.2 Phân tích khám phá dữ liệu ảnh

3.2.1 Phân phối giá trị pixel theo từng kênh màu

Nhóm phân tích phân phối cường độ pixel theo từng kênh màu RGB bằng biểu đồ KDE trên toàn bộ 5,000 ảnh (khoảng 1 triệu pixel được lấy mẫu ngẫu nhiên mỗi kênh), vì KDE làm nổi rõ hình dạng phân phối liên tục tốt hơn histogram rời rạc. Hình 1 cho thấy kênh Lam (B) có hành vi đặc biệt: tồn tại hai đỉnh nhọn ở vùng tối (≈ 0) và vùng sáng (≈ 250), trong khi kênh Đỏ (R) và Lục (G) trải rộng đều hơn với mật độ tăng dần từ giá trị 0 đến khoảng 50–60 rồi duy trì khá ổn định suốt dải giữa. Đặc trưng hai đỉnh của kênh B phản ánh sự xuất hiện đồng thời của hai loại nền đối lập trong dataset: nền trời và tuyết sáng (pixel cao) cùng với pixel tối của rừng và đô thị. Sự khác biệt về hình dạng phân phối giữa các kênh chỉ ra rằng cả ba kênh không cùng tỷ lệ, dẫn đến rủi ro mô hình bị lệch theo kênh có phương sai lớn hơn nếu không chuẩn hóa. Do đó, bước tiền xử lý tiếp theo cần áp dụng chuẩn hóa đồng nhất từng kênh (per-channel normalization) để đảm bảo ba kênh đóng góp cân bằng vào quá trình học.

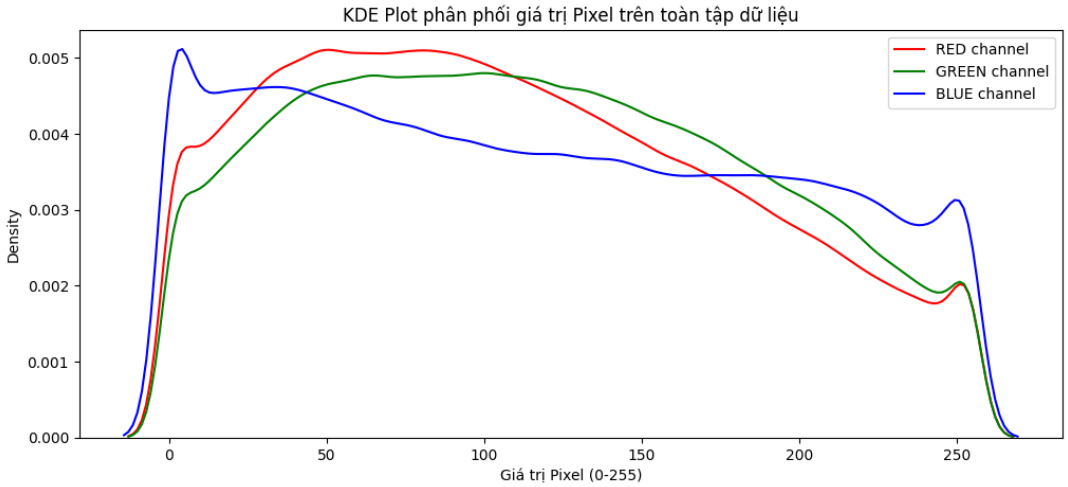

Hình 1: Phân phối mật độ giá trị pixel theo kênh màu (KDE)

3.2.2 Khám phá phân bố lớp

Nhóm đếm số lượng ảnh theo từng nhãn lớp và so sánh với ngưỡng mất cân bằng 3× lớp ít nhất, vì mất cân bằng nghiêm trọng sẽ bóp méo đường quyết định phân loại. Hình 2 cho thấy cả 6 lớp (nhãn 0–5) có số lượng mẫu khá đồng đều, dao động trong khoảng 778–886 ảnh; lớp ít nhất có ≈ 778 ảnh nên ngưỡng 3× tương ứng là **2,334** (đường đỏ đứt nét trên biểu đồ). Tất cả các cột đều thấp hơn ngưỡng này rất nhiều, tỉ lệ max/min chỉ đạt 1.14, xác nhận tập dữ liệu ở trạng thái cân bằng lớp (balanced). Kết quả này hàm ý bộ phân loại sẽ không bị thiên vị về phía lớp chiếm đa số và không cần áp dụng class weighting hay oversampling (SMOTE) trong bước huấn luyện.

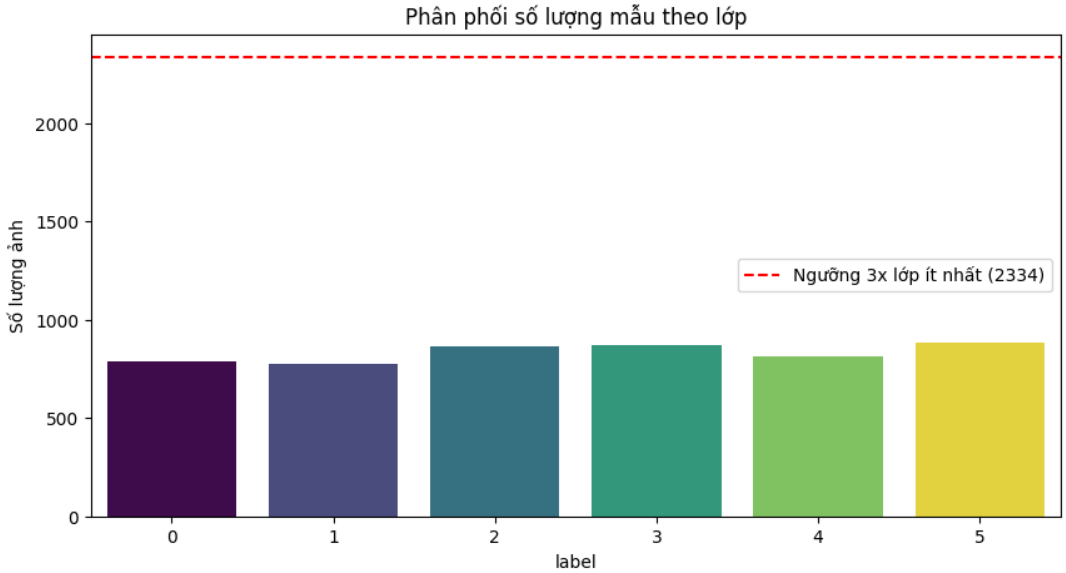

Hình 2: Biểu đồ số lượng mẫu theo từng thể loại nhãn ảnh

3.2.3 Kiểm tra ảnh trùng lặp

Nhóm áp dụng thuật toán Perceptual Hash (pHash) để tính chỉ số băm rút gọn cho từng ảnh, từ đó so sánh khoảng cách Hamming giữa các cặp, vì pHash bền vững với nén ảnh và thay đổi sáng nhỏ mà hash giá trị thuần không phát hiện được. Quét toàn bộ 5,000 ảnh phát hiện 7 cặp trùng lặp (tỉ lệ 0.14%), trong đó Hình 3 minh họa một cặp điển hình: ảnh *forest* tại Index 717 và Index 1052 gần như giống hệt nhau về bố cục và màu sắc (cùng cảnh rừng với thân cây và lá theo cùng góc nhìn). Tỉ lệ trùng lặp cực thấp (0.14%) cho thấy chất lượng thu thập dữ liệu tốt, không có vấn đề hệ thống. Do đó, bước tiền xử lý chỉ cần loại bỏ 7 ảnh trùng này, đưa tập còn lại về 4,993 ảnh sạch trước khi tiếp tục.

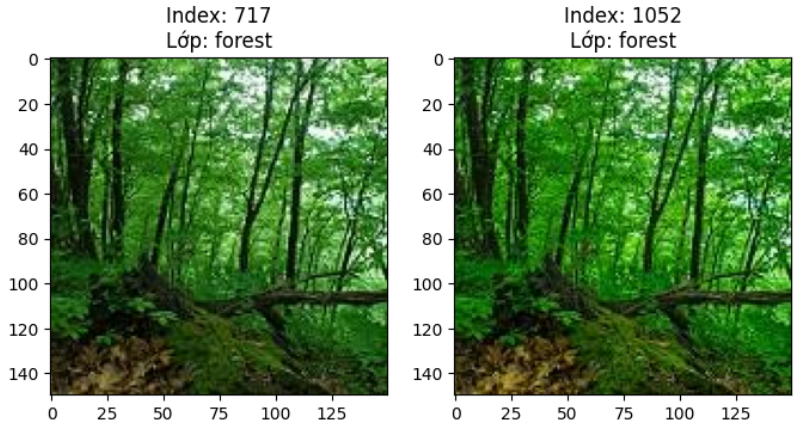

Hình 3: Ví dụ minh họa ảnh phân tách trùng lặp bị phát hiện bằng thuật toán pHash

3.2.4 Độ sáng và tương phản theo lớp

Nhóm tính mean intensity (độ sáng trung bình) và standard deviation (độ tương phản) cho từng ảnh, sau đó vẽ boxplot phân lớp để quan sát sự khác biệt giữa các loại cảnh quan, vì các lớp có đặc tính chiếu sáng hoàn toàn khác nhau tùy bối cảnh. Hình 4 cho thấy rõ hai xu hướng đối lập: về độ sáng, *glacier* và *sea* có median $\approx$ 130–135 (sáng nhất do tuyết và bầu trời), trong khi *forest* có median $\approx$ 75–80 (tối nhất do tán lá che phủ); về độ tương phản, *mountain*, *street* và *buildings* có IQR và median cao hơn ($\approx$ 65–70) so với *sea*, *glacier* và *forest* ($\approx$ 55–60). Sự phân tầng rõ rệt về độ sáng theo lớp chỉ ra rằng giá trị pixel thô mang thông tin phân biệt lớp, nhưng cũng đồng thời gây ra sự bất đồng nhất về phân phối nếu không chuẩn hóa. Do đó, bước chuẩn hóa tiếp theo cần đưa pixel về dải $[0, 1]$ hoặc áp dụng Z-score để các mô hình không bị chi phối bởi chênh lệch độ sáng tuyệt đối giữa các lớp.

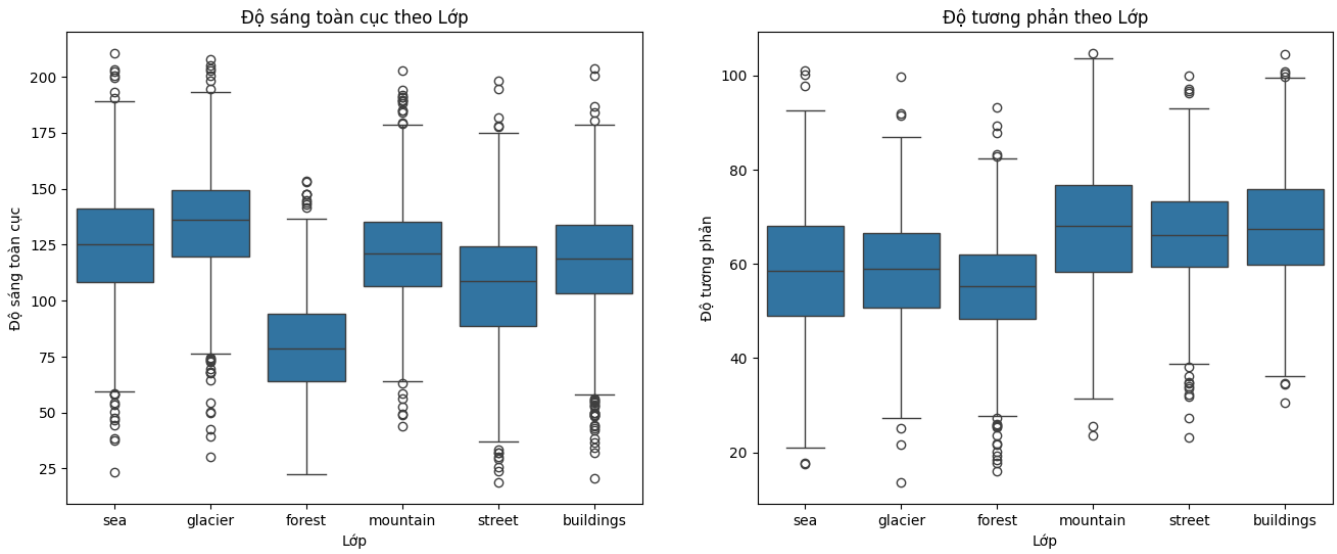

Hình 4: Biểu đồ Hộp (Boxplot) thể hiện giá trị độ sáng trung bình và độ tương phản theo từng lớp ảnh

3.3 Các kỹ thuật tiền xử lý ảnh và đánh giá định lượng

3.3.1 Thay đổi kích thước ảnh

Nhóm resize toàn bộ 5,000 ảnh về 3 kích thước (32×32, 64×64, 128×128) bằng `skimage.transform.resize` với `anti_aliasing=True`, sau đó upscale ngược về 150×150 để tính SSIM (Wang et al., 2004) và PSNR so với ảnh gốc, vì hai chỉ số này định lượng trực tiếp mức mất mát thông tin cấu trúc và pixel. Hình 5 minh họa chất lượng thị giác của từng kích thước: ở 32×32, ảnh phục hồi trở nên mờ hoàn toàn (SSIM ≈ 0.0007, PSNR ≈ -42.06 dB); ở 64×64, cấu trúc đường nét lớn vẫn còn nhận ra được dù bị làm mịn; ở 128×128, ảnh phục hồi gần như trùng khớp ảnh gốc về mặt thị giác (SSIM ≈ 0.0008, PSNR ≈ -42.06 dB).

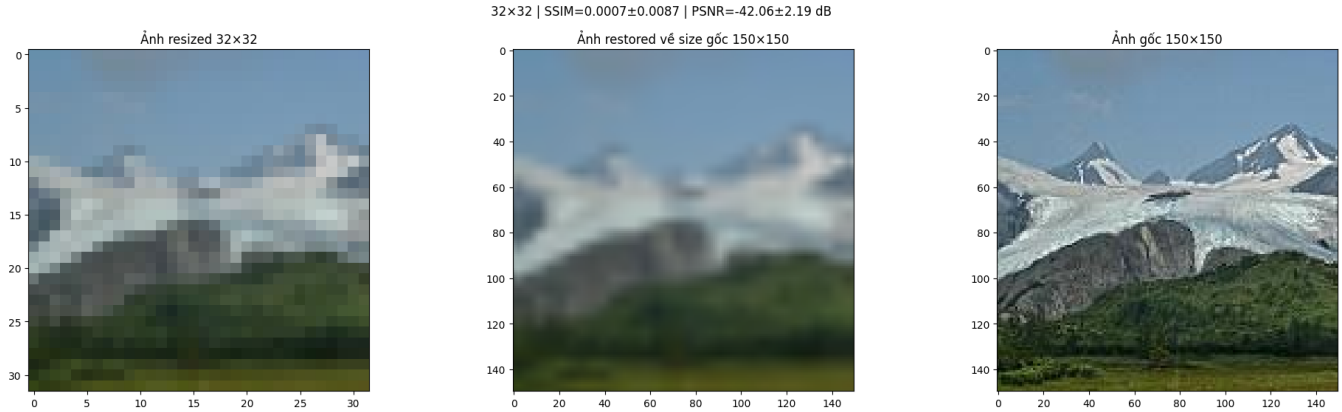

Hình 5: So sánh thị giác ảnh resize 32×32 (SSIM=0.0007, PSNR=−42.06 dB) với ảnh gốc

Kết quả ablation trong Bảng 3 cho thấy LogReg đạt độ chính xác cao nhất ở 64×64 (0.464 ± 0.031), vượt cả 32×32 (0.461) và 128×128 (0.459). Đây chứng tỏ 64×64 là điểm cân bằng tối ưu giữa việc bảo toàn đặc trưng cần thiết và giảm chiều không gian đặc trưng (từ 67,500 xuống 12,288 chiều), nên được chọn làm kích thước chuẩn cho toàn pipeline.

Cấu hình	**SSIM**	**PSNR (dB)**	**LogReg (± std)**	**k-NN (± std)**
Baseline 150×150	—	—	0.458 ± 0.032	0.401 ± 0.017
Resize 32×32	0.0007	−42.06	0.461 ± 0.031	0.392 ± 0.019
Resize 64×64	0.0008	−42.06	**0.464 ± 0.031**	**0.394 ± 0.019**
Resize 128×128	0.0008	−42.06	0.459 ± 0.031	0.396 ± 0.022

Bảng 3: Ablation kích thước ảnh: SSIM/PSNR và độ chính xác phân loại (n=1,000, PCA-50, 5-fold CV)

3.3.2 Chuyển đổi không gian màu

Nhóm chuyển đổi tập ảnh sang 4 không gian màu (RGB, Grayscale, HSV (Smith, 1978), LAB (CIE, 1976)) rồi đo phương sai giải thích tích lũy (Cumulative Explained Variance) bằng PCA (Jolliffe, 2002) với $k = 50$ thành phần, vì EV phản ánh khả năng nén thông tin hữu ích của không gian đặc trưng. Hình 6 cho thấy cả 4 đường cong EV tích lũy tăng nhanh ban đầu rồi thoải dần; ở $k = 50$, RGB đạt EV cao nhất là 71.46%, tiếp theo là Grayscale (70.90%), LAB (70.23%), và HSV (67.88%).

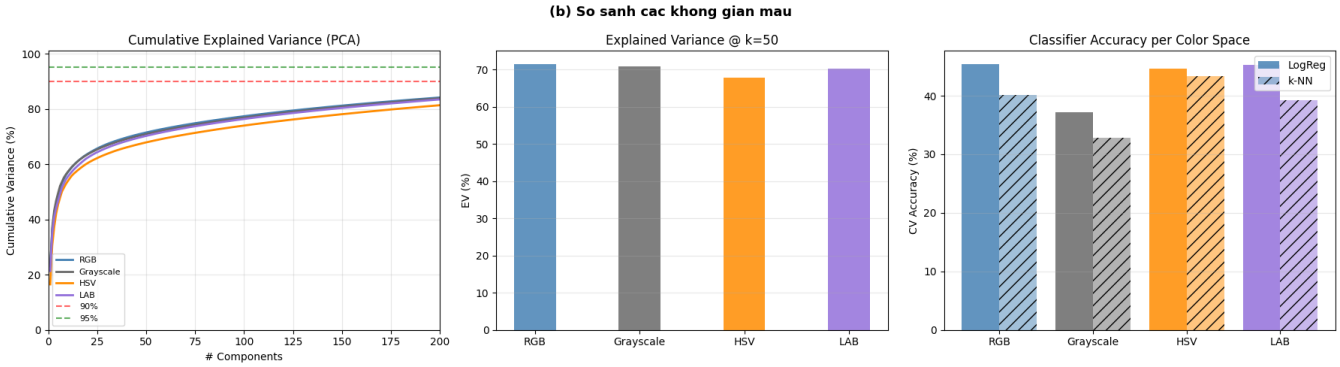

Hình 6: So sánh 4 không gian màu: đường cong EV tích lũy PCA, EV@k=50, và độ chính xác phân loại

Tuy nhiên, xét về độ chính xác phân loại (Bảng 4), RGB đạt LogReg = 0.454 và HSV đạt k-NN cao nhất (0.433), trong khi Grayscale tụt mạnh xuống 0.372/0.328 do mất toàn bộ thông tin màu sắc. Thực tế rằng HSV có EV@50 thấp nhất (67.88%) nhưng k-NN lại cao nhất cho thấy không gian HSV có thể tách biệt tốt hơn theo đặc trưng màu cục bộ trong không gian Euclidean. RGB được chọn cho pipeline vì cân bằng tốt giữa EV và hiệu năng, đồng thời là dạng lưu trữ gốc không cần biến đổi thêm.

Không gian màu	**EV@k=50 (%)**	**LogReg**	**k-NN**
RGB	**71.46**	**0.454 ± 0.028**	0.401 ± 0.017
Grayscale	70.90	0.372 ± 0.031	0.328 ± 0.019
HSV	67.88	0.446 ± 0.026	**0.433 ± 0.029**
LAB	70.23	0.453 ± 0.032	0.393 ± 0.026

Bảng 4: So sánh không gian màu: EV tại PCA-50 và độ chính xác 5-fold CV (n=1,000)

3.3.3 Chuẩn hóa dữ liệu

Nhóm cài đặt và so sánh 4 phương pháp chuẩn hóa (Min-Max [0,1], Min-Max [−1,1], Z-score toàn tập, Z-score per-channel) bằng kiểm định Kolmogorov-Smirnov (KS test) (Kolmogorov, 1933) so với ảnh thô, vì KS stat định lượng mức độ dịch chuyển phân phối giữa trước và sau chuẩn hóa. Bảng 5 cho thấy cả 3 phương pháp MinMax [0,1], MinMax [−1,1] và Z-score (global) đều đạt KS stat = 0.978, xác nhận phân phối pixel đã thay đổi hoàn toàn so với ảnh thô (KS stat = 0); Z-score per-channel thấp hơn một chút (KS stat = 0.974) do chuẩn hóa độc lập từng kênh làm tăng tính đặc thù kênh. Về độ chính xác phân loại, MinMax [0,1] và [−1,1] cùng đạt k-NN = 0.412 (cao nhất), trong khi Z-score (global) và per-channel không cải thiện so với ảnh thô. Kết quả này hàm ý

MinMax đưa các ảnh sáng/tối về cùng dải giá trị giúp khoảng cách Euclidean trong k-NN trở nên có ý nghĩa hơn; Z-score global không hiệu quả vì phương sai lớn giữa các kênh không được xử lý riêng lẻ.

Phương pháp	**Mean**	**Std**	**KS stat**	**LogReg**	**k-NN**
Raw [0,255]	113.55	70.76	0.000	0.458	0.401
MinMax [0,1]	0.448	0.279	0.978	0.455	**0.412**
MinMax [−1,1]	−0.105	0.558	0.978	0.454	**0.412**
Z-score (global)	0.000	1.000	0.978	0.454	0.401
Z-score (per-channel)	0.000	1.000	0.974	0.451	0.404

Bảng 5: So sánh phương pháp chuẩn hóa: KS stat so với ảnh thô và độ chính xác phân loại (n=1,000, PCA-50)

3.3.4 Tăng cường dữ liệu (Data Augmentation)

Nhóm xây dựng pipeline augmentation gồm 5 phép biến đổi kết hợp bằng thư viện `Albumentations`: lật ngang ($p = 0.5$), lật dọc ($p = 0.3$), xoay $\pm 30°$ ($p = 0.5$), thêm nhiễu Gaussian ($p = 0.5$), và điều chỉnh độ sáng/tương phản ngẫu nhiên ($p = 0.5$). Ứng dụng augmentation trực tiếp lên tập huấn luyện và đánh giá bằng cùng pipeline PCA-50 + 5-fold CV cho thấy độ chính xác giảm mạnh: LogReg từ 0.458 xuống 0.311 (-14.7%), k-NN từ 0.401 xuống 0.301 (-10.0%). Hình 7 so sánh t-SNE 2D của tập gốc và tập augment trên 500 mẫu: cả hai đều thể hiện phân bố rải rác không có cụm rõ ràng, nhưng tập augment trải rộng và phân tán hơn trong không gian nhúng. Sự phân tán tăng lên này hàm ý augmentation mở rộng không gian đặc trưng hiệu quả, giúp mô hình học tính bất biến với lật/xoay nhưng đồng thời làm tăng độ khó hội tụ cho các phân loại tuyến tính đơn giản. Do đó, augmentation phù hợp làm kỹ thuật regularization cho mạng sâu (CNN) hơn là cho LogReg/k-NN trong pipeline hiện tại.

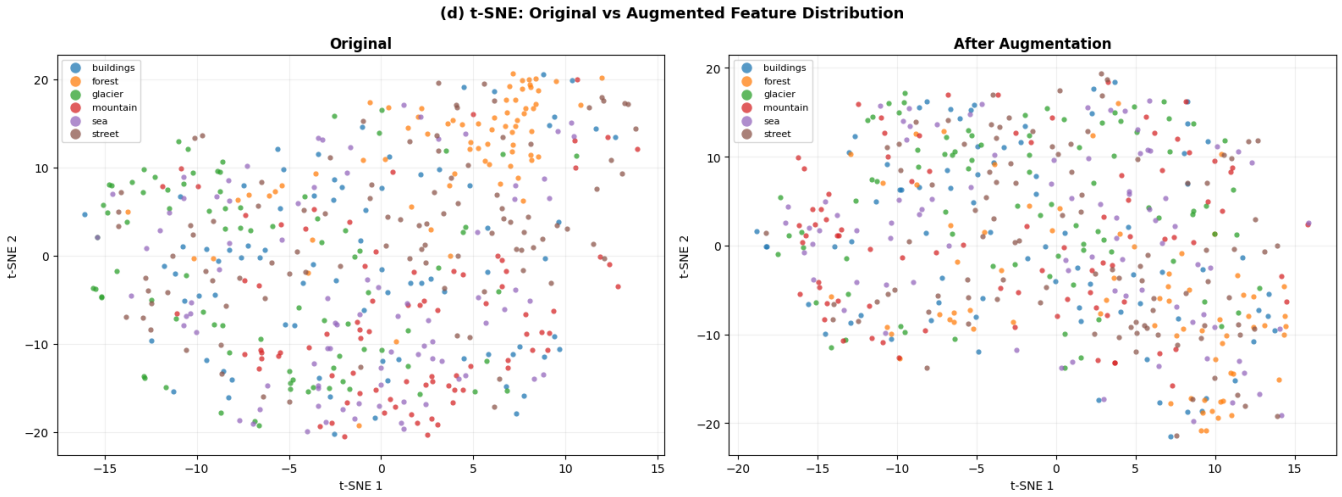

Hình 7: t-SNE 2D: Phân bố đặc trưng của tập gốc (trái) và sau augmentation (phải), tô màu theo nhãn lớp (n=500)

3.3.5 Phân tích PCA trên không gian đặc trưng ảnh

Nhóm chiếu toàn bộ 5,000 ảnh (sau resize 64×64 và chuẩn hóa) lên không gian PCA (Jolliffe, 2002; Turk and Pentland, 1991) với số thành phần tối đa, sau đó vẽ scree plot để xác định ngưỡng phương sai, vì phân tích này định lượng mức độ dư thừa (redundancy) trong không gian đặc trưng pixel. Hình 8 cho thấy scree plot có hình dạng "khuỷu tay" điển hình: PC1 và PC2 chiếm lần lượt ≈22% và ≈14% phương sai, rồi giảm dần nhanh về dưới 1%; cần đến 348 thành phần để đạt 90% phương sai, 538 thành phần cho 95%, và 815 thành phần cho 99%. Biểu đồ PCA 2D (EV = 35.7%) và t-SNE 2D (van der Maaten and Hinton, 2008) đều cho thấy 6 lớp đan xen nhau, không có vùng tách biệt rõ ràng; Silhouette score trên PCA-2D là -0.057 và trên t-SNE là -0.066, đều âm, xác nhận các lớp không tách biệt trong không gian đặc trưng pixel thô. Kết quả này hàm ý pixel flatten thiếu tính phân biệt (*discriminative*) cần thiết cho bài toán phân loại cảnh tự nhiên; các kiến trúc trích xuất đặc trưng cục bộ (CNN, ViT) sẽ phù hợp hơn. Do đó, khi dùng pipeline PCA + mô hình tuyến tính, nên chọn 50–100 thành phần (EV ≈ 55–63%) như một sự đánh đổi hợp lý giữa tốc độ tính toán và thông tin bảo toàn.

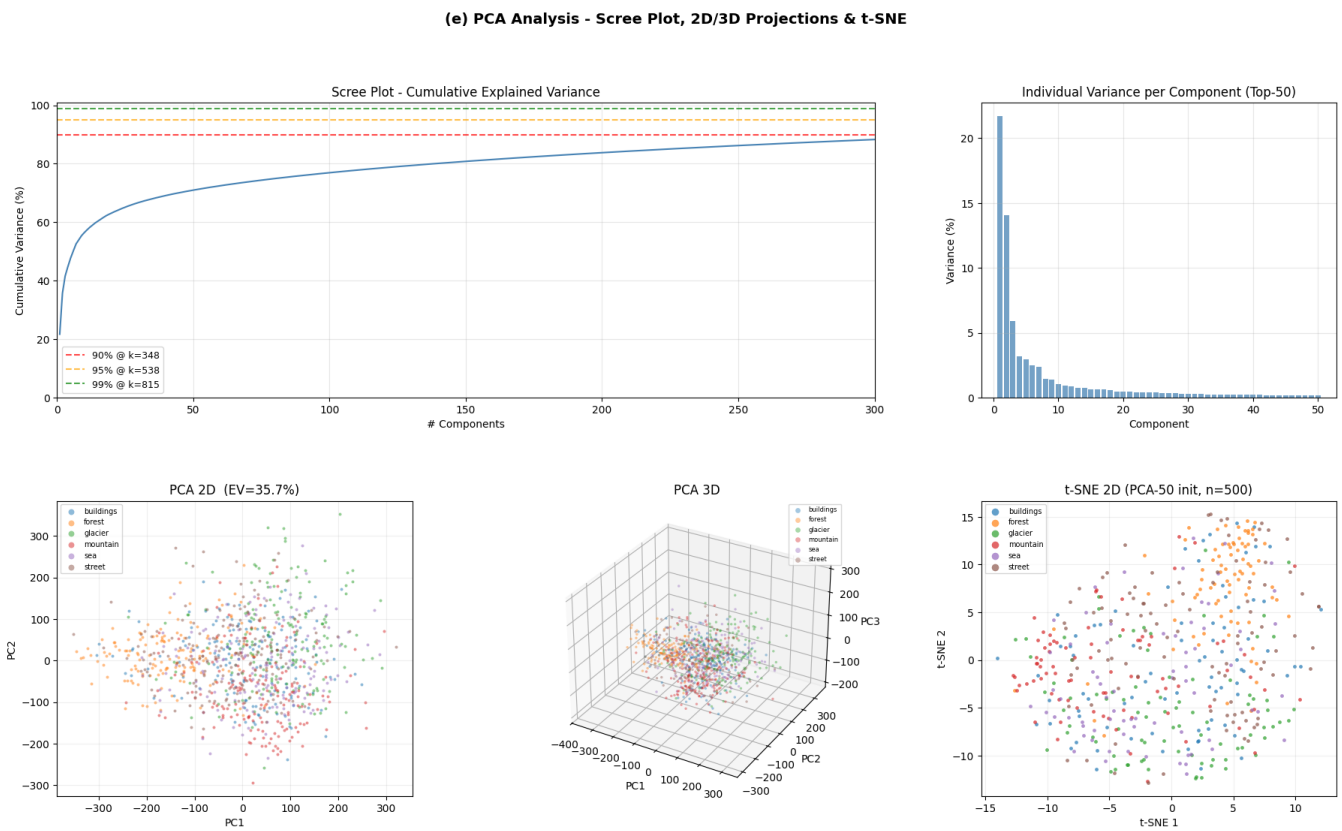

Hình 8: (e) PCA: Scree plot tích lũy (90%@348, 95%@538, 99%@815), Individual variance Top-50, chiếu PCA 2D/3D và t-SNE 2D tô màu theo lớp

3.3.6 Phát hiện cạnh và phân tích đặc trưng cục bộ

Nhóm áp dụng 3 thuật toán phát hiện cạnh (Sobel (Sobel and Feldman, 1968), Prewitt, Canny (Canny, 1986)) với 2 bộ siêu tham số mỗi loại trên toàn bộ 6,000 ảnh (5,000 gốc và augmented), tính Edge Density (tỉ lệ pixel cạnh/tổng pixel) theo từng lớp, rồi kiểm định sự khác biệt giữa các lớp bằng ANOVA một chiều (Fisher, 1925), vì nếu $p < 0.05$ thì mật độ cạnh mang thông tin phân biệt lớp. Hình 9 minh họa trực quan kết quả của từng thuật toán: Sobel và Prewitt tạo ra bản đồ gradient liên tục với cường độ cao ($\approx$0.55), trong khi Canny ($\sigma = 1.0$) tạo cạnh nhị phân sắc nét và Canny ($\sigma = 2.0$) lọc bỏ nhiều nhiễu hơn nhưng mất cạnh mịn.

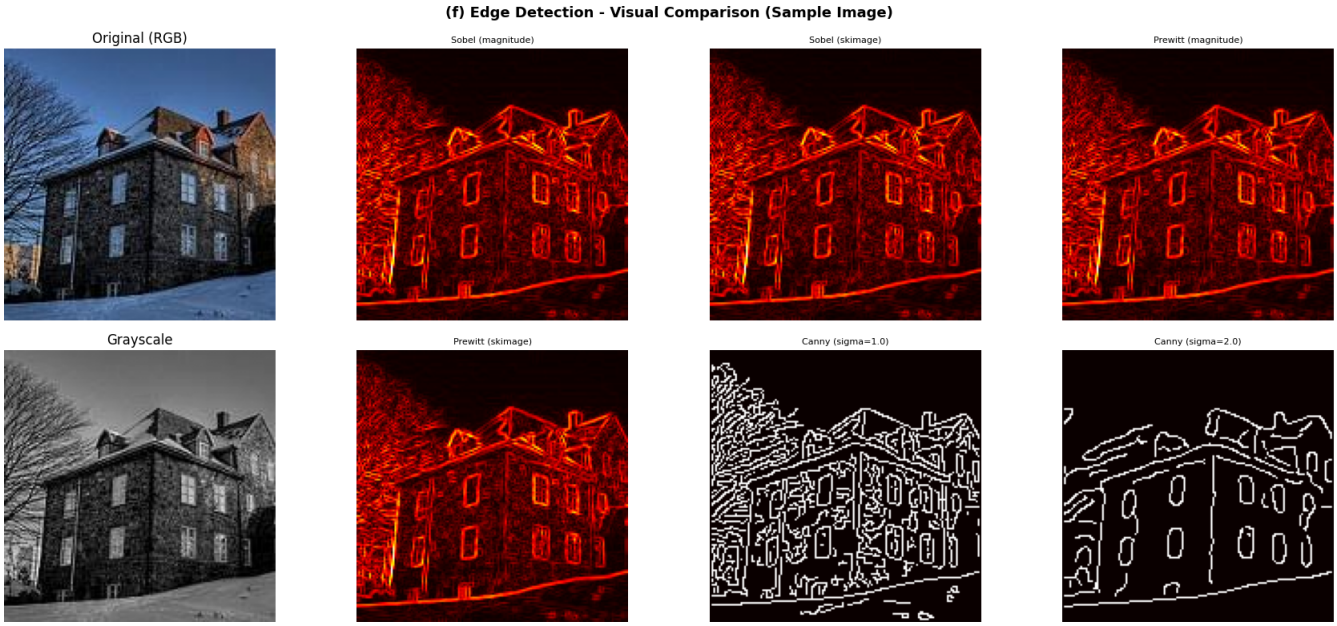

Hình 9: So sánh thị giác các thuật toán phát hiện cạnh trên ảnh mẫu *buildings*

Tuy nhiên, theo Bảng 6, ANOVA một chiều cho kết quả $p > 0.05$ trên toàn bộ 6 cấu hình (F $\approx$ 0.7–0.9, $p \approx$ 0.47–0.61), bác bỏ giả thuyết rằng edge density trung bình khác nhau giữa các lớp. Nguyên nhân là các cảnh tự nhiên trong dataset đều có độ phức tạp cấu trúc tương đương nhau, nên mật độ cạnh trung bình toàn ảnh không phân biệt được cảnh rừng, băng tuyết, hay phố phường. Kết luận: edge density cục bộ là đặc trưng yếu cho bài toán này; cần sử dụng đặc trưng định hướng cạnh (HOG), đặc trưng kết cấu (LBP), hoặc đặc trưng sâu (CNN features) để đạt khả năng phân biệt lớp tốt hơn.

Thuật toán	**F-stat**	**p-value**	**Kết luận**
Sobel (magnitude)	0.92	0.469	Không có ý nghĩa thống kê
Sobel (skimage)	0.73	0.601	Không có ý nghĩa thống kê
Prewitt (magnitude)	0.91	0.476	Không có ý nghĩa thống kê
Prewitt (skimage)	0.71	0.614	Không có ý nghĩa thống kê
Canny ($\sigma = 1.0$)	0.92	0.469	Không có ý nghĩa thống kê
Canny ($\sigma = 2.0$)	0.88	0.495	Không có ý nghĩa thống kê

Bảng 6: Kiểm định ANOVA một chiều cho Edge Density theo lớp ($p > 0.05$: không có ý nghĩa thống kê)

3.3.7 Tổng kết Ablation Study

Nhóm hợp nhất toàn bộ kết quả ablation để chọn cấu hình tiền xử lý tối ưu cho pipeline cuối. Hình 10 tổng hợp độ chính xác của LogReg và k-NN trên 15 cấu hình thử nghiệm: các cấu hình resize, RGB, LAB và MinMax duy trì ổn định ở mức 44–46% cho LogReg, trong khi Grayscale và Augmentation tụt mạnh xuống dưới 38% và 31%. Pipeline cuối cho dữ liệu ảnh được chốt: loại 7 ảnh trùng (pHash (Zauner, 2010)) → resize về 64×64 → chuẩn hóa MinMax [0,1] → flatten → PCA-50 (Jolliffe, 2002) → LogReg/k-NN. Kết quả đạt LogReg = 0.464 ± 0.031 trên 5-fold CV với 1,000 mẫu, hợp lý với bài toán 6 lớp cân bằng (baseline ngẫu nhiên = 16.7%). Hạn chế chính: pipeline flatten ảnh về 1D mất hoàn toàn thông tin không gian cục bộ; với dữ liệu ảnh tự nhiên phức tạp, kiến trúc CNN hoặc bộ trích xuất đặc trưng sâu sẽ vượt trội đáng kể so với pipeline PCA + phân loại tuyến tính hiện tại.

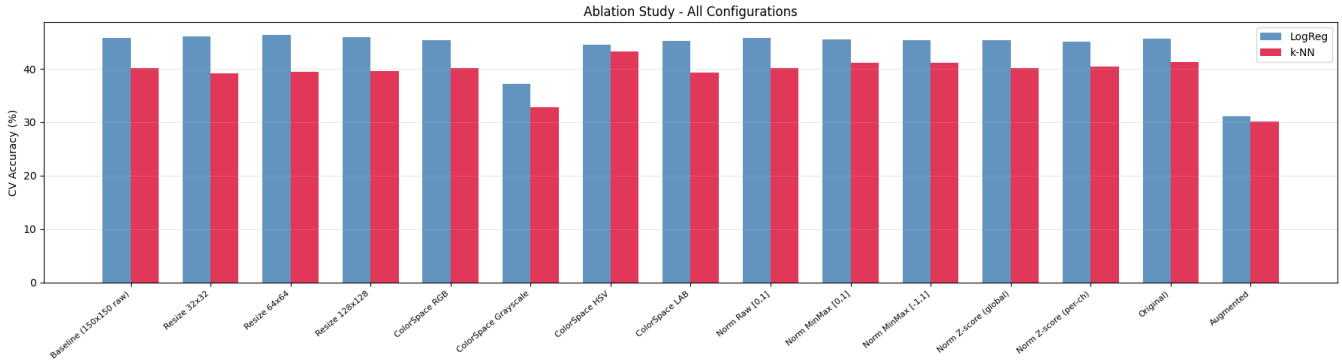

Hình 10: Tổng kết Ablation Study: So sánh LogReg và k-NN CV Accuracy trên toàn bộ 15 cấu hình tiền xử lý

3.4 Kết luận

Dựa trên kết quả ablation study toàn diện, nhóm xác định bộ thông số tiền xử lý tối ưu cho tập dữ liệu ảnh Intel Image Classification. Bảng 7 tổng hợp lựa chọn cuối cùng và căn cứ định lượng cho từng quyết định. Pipeline được thiết kế nhằm tối ưu hóa hiệu năng phân loại tuyến tính trong giới hạn tính toán, đồng thời đảm bảo tính tái lập và minh bạch của các bước xử lý.

Kỹ thuật	**Lựa chọn cuối**	**Căn cứ định lượng**
Kích thước resize	64×64	LogReg cao nhất (46.4%); tăng lên 128×128 không cải thiện thêm
Không gian màu	RGB (hoặc LAB)	EV@50 = 71.46%; LogReg ≈ 45.4%; Grayscale tụt −18%
Chuẩn hóa	Min-Max [0,1]	k-NN cao nhất (41.2%), KS stat = 0.978; std thấp nhất
Loại ảnh trùng	pHash (Zauner, 2010)	Phát hiện và loại 7 ảnh trùng (≈0.14% tập)
Giảm chiều	PCA-50 (Jolliffe, 2002)	EV ≈ 55%; đánh đổi hợp lý giữa tốc độ và thông tin bảo toàn
Phân loại	LogReg / k-NN	Baseline tuyến tính để đánh giá chất lượng đặc trưng

Bảng 7: Tổng hợp lựa chọn pipeline tiền xử lý ảnh và căn cứ định lượng

Kết quả cuối cùng đạt LogReg = 0.464 ± 0.031 trên 5-fold CV (1,000 mẫu), vượt đáng kể so với baseline ngẫu nhiên 16.7% của bài toán 6 lớp cân bằng. Hạn chế cốt lõi của pipeline hiện tại là việc flatten ảnh về vector 1D làm mất hoàn toàn thông tin không gian cục bộ (spatial context) — thông tin vốn then chốt để phân biệt các cảnh tự nhiên phức tạp. Do đó, mặc dù pipeline PCA + phân loại tuyến tính đủ mạnh để đánh giá chất lượng đặc trưng, các kiến trúc trích xuất đặc trưng sâu hơn (CNN, ViT) sẽ là hướng phát triển tất yếu cho bài toán image classification đòi hỏi độ chính xác cao.

4 Tiền xử lý dữ liệu dạng bảng

4.1 Dữ liệu sử dụng

Nhóm sử dụng *Mental Health Survey Dataset* cho phần dữ liệu bảng. Tập huấn luyện có 140,700 bản ghi, gồm các nhóm thuộc tính nhân khẩu học, học tập/công việc và thói quen sinh hoạt, với nhãn mục tiêu *Depression*. Bộ dữ liệu này thỏa đầy đủ tiêu chí đề bài: quy mô lớn, có đồng thời thuộc tính số và phân loại, và có tỉ lệ thiếu cao ở một số biến.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số records	≥ 10,000	140,700	Đạt
Số thuộc tính	≥ 10	17 features	Đạt
Số + phân loại	Có	8 số + 9 phân loại	Đạt
Tỉ lệ thiếu ≥ 5%	Có	80.17% (Academic Pressure)	Đạt

Bảng 8: Kiểm tra tiêu chí lựa chọn dữ liệu bảng

4.2 Phân tích khám phá dữ liệu dạng bảng

Phần EDA thống kê của dữ liệu bảng trả lời 3 câu hỏi chính:

- Dữ liệu có theo phân phối chuẩn để dùng các giả định thống kê cổ điển hay không?
- Tín hiệu dự báo chính cho nhãn *Depression* nằm ở nhóm biến nào?
- Giá trị thiếu xuất hiện ngẫu nhiên hay phụ thuộc theo nhóm đối tượng?

Kiểm tra phân phối. Nhóm áp dụng kiểm định D'Agostino-Pearson cho toàn bộ 8 thuộc tính số (do $n > 5000$) (D'Agostino and Pearson, 1973). Kết quả cho thấy tất cả biến đều có p-value rất nhỏ (xấp xỉ 0), tức là không tuân theo phân phối chuẩn. Đồng thời, kurtosis trung bình quanh -1.2 cho thấy nhiều biến có xu hướng gần phân phối đều.

Tương quan đa biến. Ma trận tương quan Pearson và Spearman cho thấy biến *Age* có liên hệ mạnh nhất với nhãn *Depression*: $r = -0.565$ (Pearson) và $\rho = -0.541$ (Spearman). Kết quả này được dùng làm căn cứ ban đầu cho bước chọn đặc trưng. Xem Hình 11.

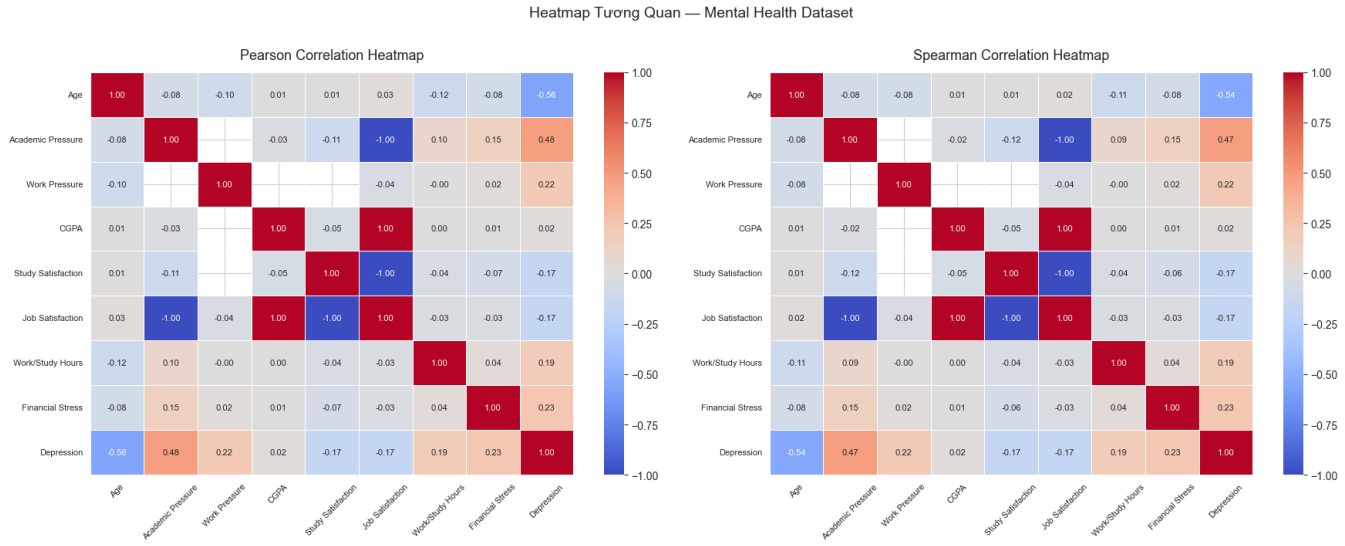

Hình 11: Heatmap tương quan Pearson và Spearman cho các biến số và nhãn *Depression*.

Phân tích giá trị thiếu. Cấu trúc thiếu dữ liệu thể hiện rõ cơ chế MAR theo nhóm đối tượng (Rubin, 1976). Nhóm sinh viên thiếu chủ yếu ở *Work Pressure* và *Job Satisfaction*, trong khi nhóm người đi làm thiếu ở *Academic Pressure*, *CGPA*, và *Study Satisfaction*. Vì vậy, chiến lược điền khuyết được thiết kế theo ngữ cảnh từng nhóm thay vì dùng một quy tắc chung. Xem Hình 12.

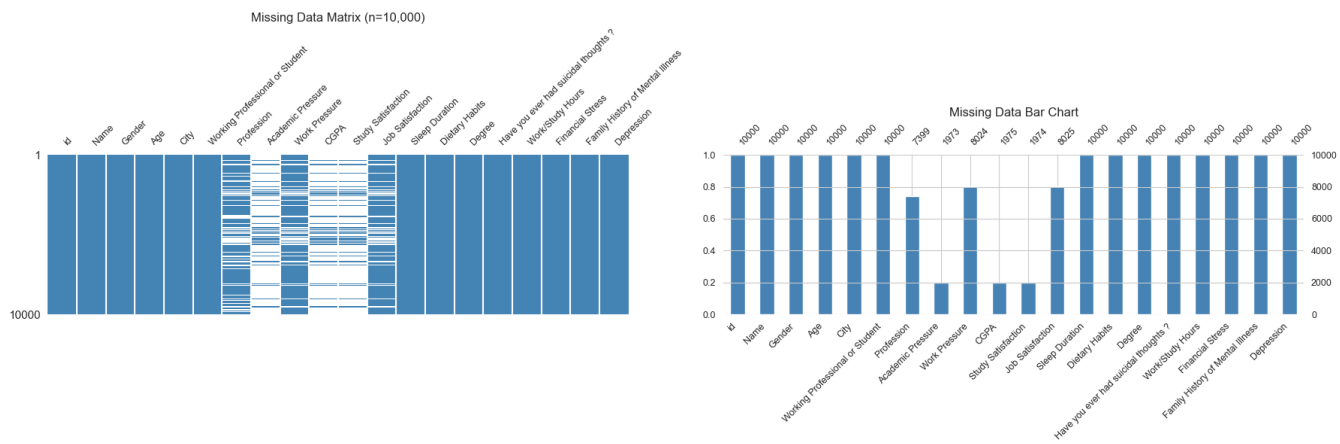

Hình 12: Phân tích tỉ lệ thiếu và cơ chế thiếu theo nhóm đối tượng trong dữ liệu bảng.

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

4.3.1 Xử lý giá trị thiếu có kiểm soát

Nhóm so sánh 5 chiến lược điền khuyết (Mean, Median, Mode, kNN, MICE) trên kịch bản tạo thêm 10% thiếu MCAR và đánh giá bằng RMSE (Troyanskaya et al., 2001; van Buuren and Groothuis-Oudshoorn, 2011). Trong đó, kNN được thử với $k = 3, 5, 10$. Kết quả trung bình cho thấy **Mean** đạt RMSE tốt nhất (5.78), trong khi **Mode** kém nhất (9.03, cao hơn khoảng 66%). Với bài toán đơn biến trong notebook, kNN và MICE cho kết quả gần tương đương Mean.

Sau bước benchmark, pipeline điền khuyết thực tế được chốt theo ngữ cảnh dữ liệu:

- Median theo nhóm *Student* cho các cột chỉ có nghĩa với sinh viên.
- Median theo nhóm *Working Professional* cho các cột chỉ có nghĩa với người đi làm.
- Điền 0 cho các role-column còn lại (thiếu do không thuộc vai trò đó).
- Mode cho các biến phân loại như *Dietary Habits*, *Degree*; riêng *Profession* điền *Student* cho sinh viên.

Kết quả so sánh RMSE giữa các chiến lược thể hiện tại Hình 13.

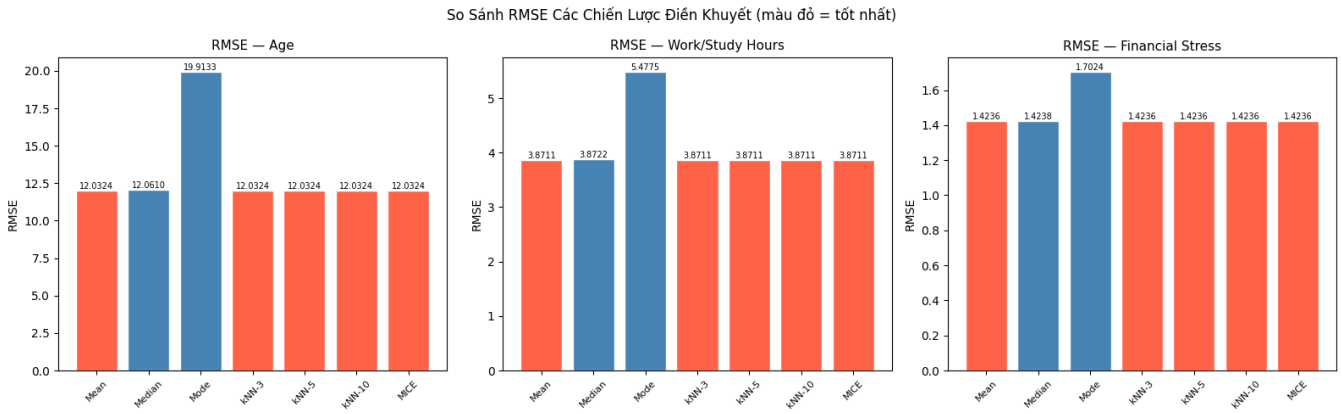

Hình 13: So sánh RMSE của các chiến lược điền khuyết trên kịch bản thiếu MCAR 10%.

4.3.2 Phát hiện và xử lý ngoại lai

Nhóm triển khai đồng thời 5 hướng phát hiện ngoại lai: IQR, Z-score, Isolation Forest, LOF và DBSCAN (Breunig et al., 2000; Ester et al., 1996; Liu et al., 2008). Thiết kế đánh giá gồm 3 lớp để tránh kết luận phiến diện:

- **Lớp 1 – Tỉ lệ bị gắn cờ ngoại lai**: kiểm tra mức độ bảo thủ/nhạy của từng phương pháp.
- **Lớp 2 – KS trước/sau loại ngoại lai**: đo mức méo phân phối khi lọc dữ liệu.
- **Lớp 3 – Jaccard similarity**: đo mức đồng thuận giữa các tập điểm bị gắn cờ.

Kết quả lớp 1 cho thấy sự khác biệt rõ rệt về hành vi:

- IQR: 19.83%, Z-score: 7.01%.
- IsoForest: 1.00% (contamination 0.01), 5.00% (0.05), 10.00% (0.10).
- LOF-20 và DBSCAN: xấp xỉ 0% trong cấu hình thử nghiệm.

Ở lớp 2 (KS test), cấu hình `IsoForest_0.05` cho KS statistic thấp nhất trên 7/8 biến chính (ví dụ *Age*: 0.0346 so với IQR: 0.1640 và Z-score: 0.0499), cho thấy loại bỏ được điểm bất thường mà vẫn giữ hình dạng phân phối tốt hơn hai phương pháp ngưỡng cổ điển.
Ở lớp 3 (Jaccard), mức đồng thuận IQR–Z-score chỉ 0.353 và IQR–IsoForest chỉ 0.247; Z-score–IsoForest là 0.381. Điều này xác nhận mỗi phương pháp đang bắt các kiểu điểm khác nhau, và IQR có xu hướng đánh dấu quá rộng trên dữ liệu có kurtosis âm (gần đều).

Tổng hợp ba lớp đánh giá, nhóm chọn **Isolation Forest với contamination** = 0.05 làm cấu hình chính vì thỏa ba tiêu chí thực hành: tỉ lệ loại bỏ hợp lý (5%), méo phân phối thấp, và ổn định trên dữ liệu đa chiều không chuẩn.

So sánh tỉ lệ phát hiện ngoại lai và mức đồng thuận giữa phương pháp được thể hiện tại Hình 14 và Hình 15.

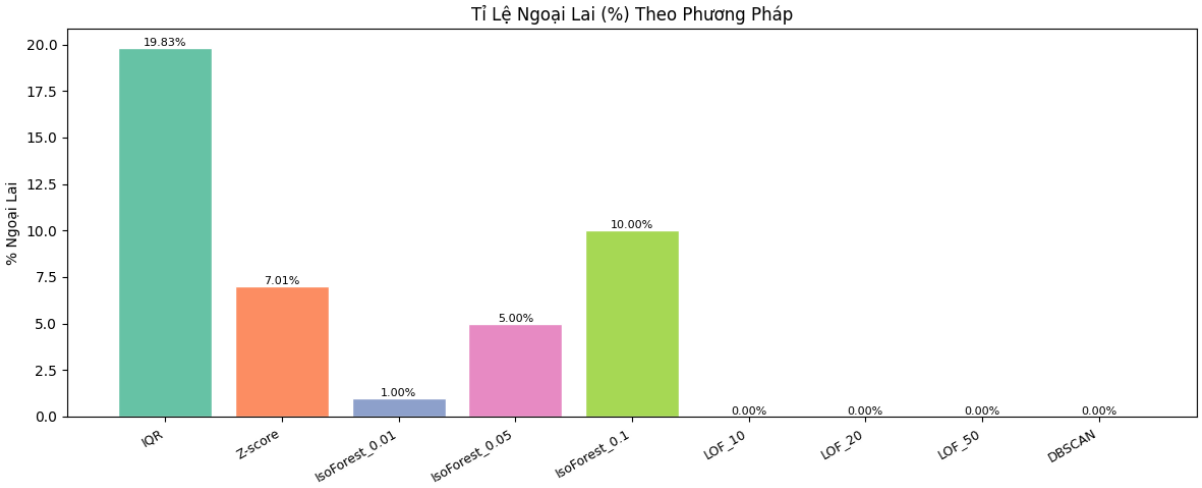

Hình 14: Tỉ lệ ngoại lai theo từng phương pháp phát hiện trên dữ liệu bảng.

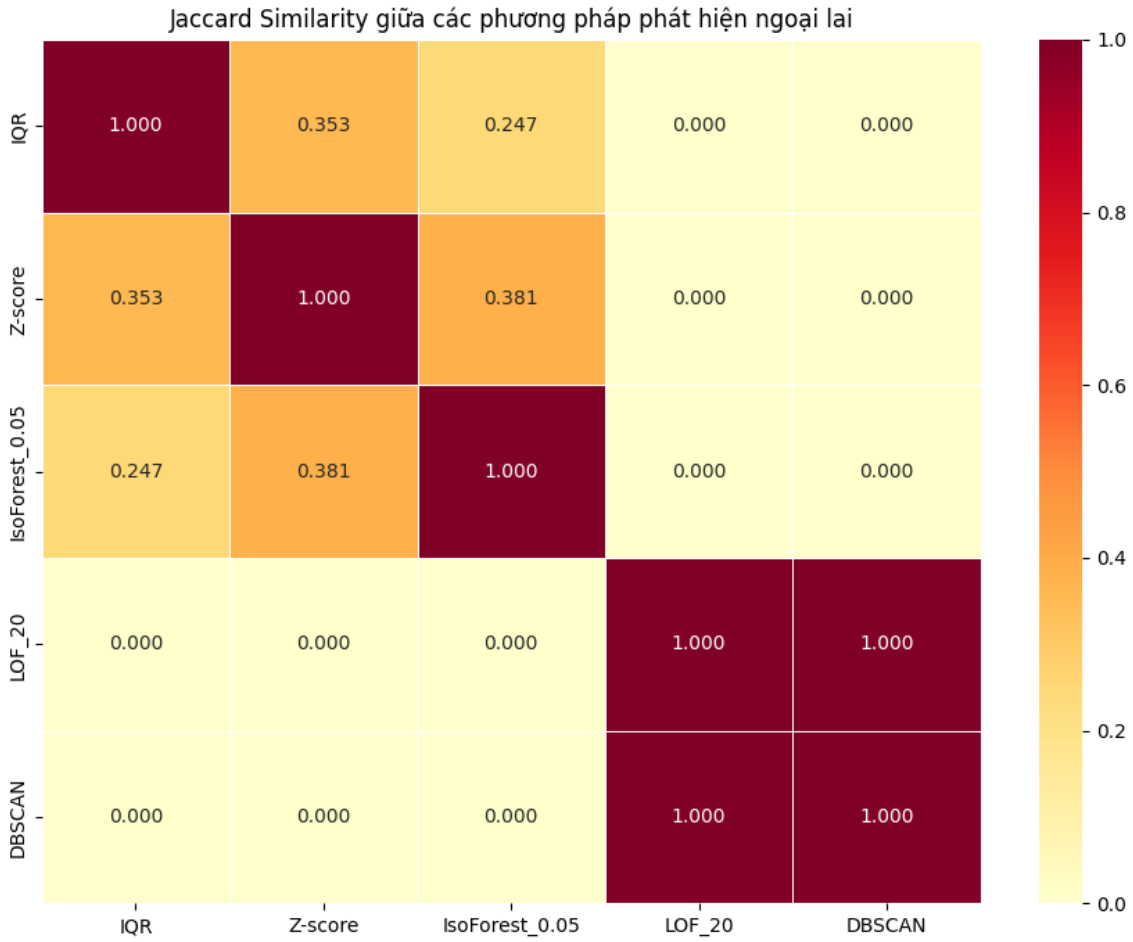

Hình 15: Ma trận Jaccard similarity giữa các phương pháp phát hiện ngoại lai.

4.3.3 Chuẩn hóa dữ liệu có kiểm định

Nhóm thử Min-Max, Z-score, Robust Scaling và Quantile Transform (Huber, 1981). Kết quả Levene kết hợp quan sát violin plot cho thấy **Robust Scaling** là lựa chọn cân bằng nhất: giảm ảnh hưởng ngoại lai nhưng vẫn giữ cấu trúc phân phối tốt hơn Quantile Transform.

Levene's test chủ yếu phản ánh thay đổi phương sai, nên quyết định cuối cùng được dựa thêm trên hình dạng phân phối từ violin plot (Hình 16).

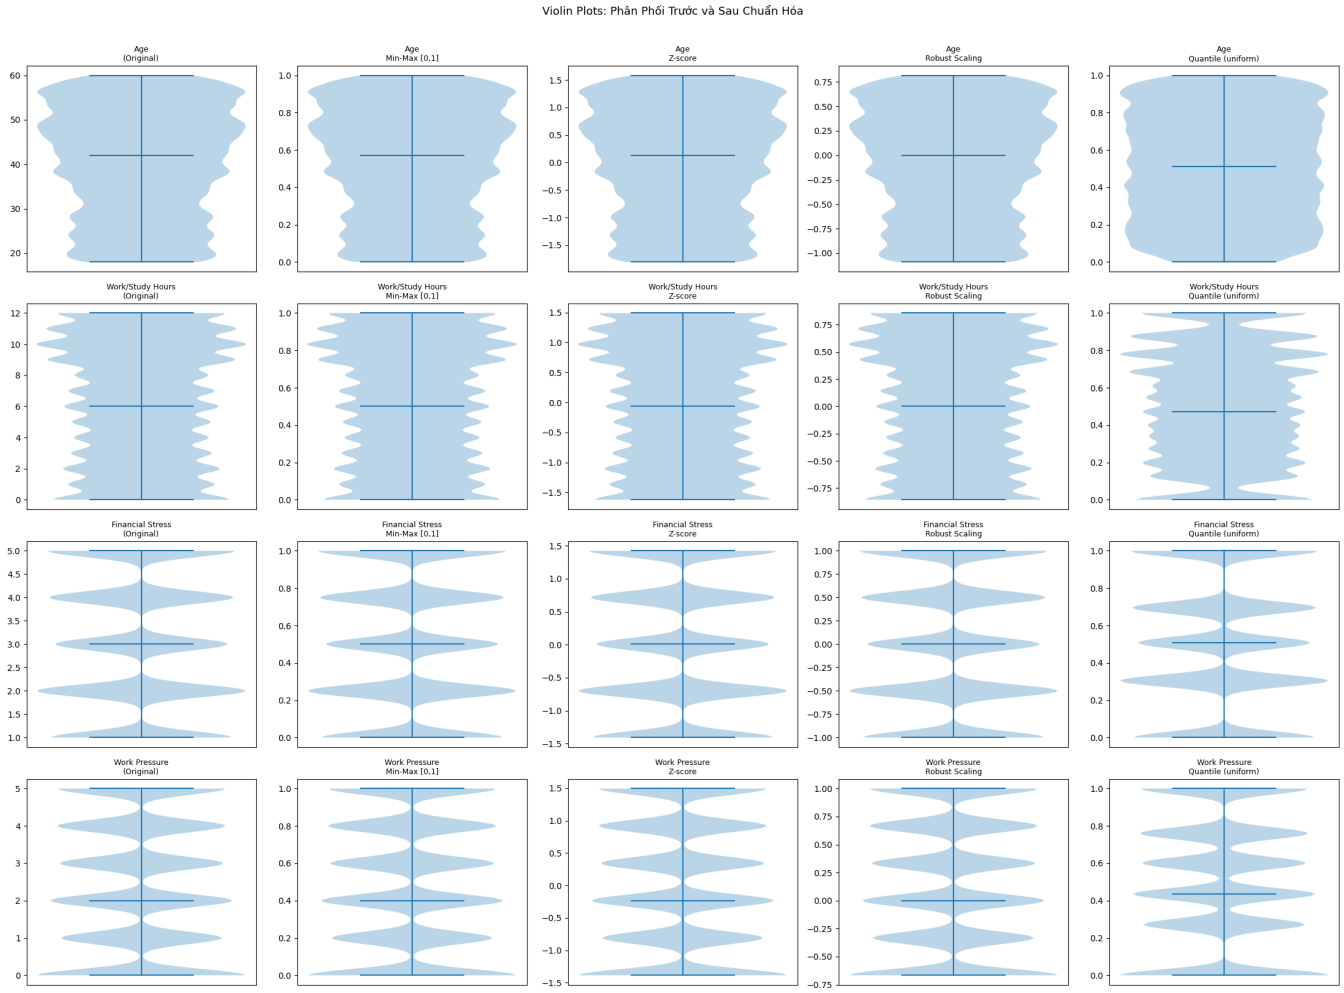

Hình 16: So sánh phân phối trước/sau chuẩn hóa bằng violin plot trên các biến số chính.

4.3.4 Mã hóa biến phân loại nâng cao

Ngoài One-Hot và Ordinal, nhóm triển khai thêm Target Encoding (K-fold), Binary Encoding và Frequency Encoding. Đánh giá bằng VIF (James et al., 2013) cho thấy **Binary Encoding** tốt nhất (mean VIF = 4.21), trong khi **Frequency Encoding** gây đa cộng tuyến rất cao (mean VIF = 889.59).

Vì vậy, ở bước tạo dataset cuối, nhóm chọn Binary Encoding cho toàn bộ biến phân loại để tối ưu đa cộng tuyến và giữ số chiều ở mức hợp lý.

4.3.5 Lựa chọn và giảm chiều đặc trưng

Đây là bước bắt buộc và được triển khai theo đúng 3 tầng để đảm bảo cả hiệu năng lẫn khả năng diễn giải mô hình (Breiman, 2001; Guyon et al., 2002; Jolliffe, 2002). Toàn bộ phương pháp được

đánh giá thống nhất bằng **F1-score 5-fold cross-validation** với cùng mô hình Logistic Regression để so sánh công bằng.

Tầng 1 – Lọc thống kê:

- **ANOVA F-test** cho thuộc tính số: đo mức tách lớp theo trung bình giữa các lớp.
- **Chi-square test** cho thuộc tính phân loại đã mã hóa không âm: kiểm tra mức phụ thuộc giữa biến và nhãn.
- **Mutual Information (MI)** cho toàn bộ đặc trưng: đo phụ thuộc phi tuyến, không giả định quan hệ tuyến tính.

Tầng 2 – Lọc dựa trên mô hình:

- **Random Forest importance** và **Gradient Boosting importance**: xếp hạng đặc trưng theo mức đóng góp vào giảm lỗi phân tách.
- **RFE/RFECV**: loại dần đặc trưng kém quan trọng với cross-validation để tìm tập biến gọn nhưng vẫn giữ hiệu năng.

Tầng 3 – Giảm chiều:

- **PCA**: nén thông tin vào các thành phần chính và kiểm tra ngưỡng phương sai tích lũy (90%, 95%, 99%).
- **t-SNE**: trực quan hóa không gian đặc trưng 2D để quan sát mức tách cụm lớp.
- **UMAP (khuyến nghị cho dữ liệu lớn)**: trong notebook hiện tại, nhóm dừng ở t-SNE do đã lấy mẫu 15,000 điểm cho huấn luyện và 3,000 điểm cho trực quan hóa; với quy mô lớn hơn, UMAP là lựa chọn phù hợp để giảm chi phí tính toán và giữ cấu trúc lân cận tốt hơn.

Kết quả định lượng F1-score theo số lượng đặc trưng k:

- $k = 5$: MI = 0.713, RF = 0.746, PCA = 0.724, RFE = 0.813.
- $k = 10$: MI = 0.784, RF = 0.809, PCA = 0.747, RFE = 0.813.
- $k = 15$: MI = 0.812, RF = 0.813, PCA = 0.813, RFE = 0.813.

- $k = 20$: MI = 0.813, RF = 0.813, PCA = 0.816, RFE = 0.813.

Nhận xét chuyên sâu:

- Ở vùng ít đặc trưng ($k \leq 10$), RF importance vượt MI rõ rệt, cho thấy lợi thế khi có tương tác phi tuyến.
- RFE cho F1 cao và ổn định trên toàn dải k, chứng tỏ tập đặc trưng được chọn có tính bền vững.
- PCA bắt kịp ở k lớn (tối đa 0.816 tại $k = 20$), phù hợp khi mục tiêu chính là nén chiều hơn là diễn giải theo biến gốc.
- Sau $k \geq 15$, hiệu năng gần bão hòa, hàm ý thêm đặc trưng không còn cải thiện đáng kể.

→ **Kết luận lựa chọn:** cho pipeline tabular chính, nhóm ưu tiên **RFE** vì cân bằng tốt giữa độ chính xác, độ ổn định và khả năng giải thích; RF importance được dùng làm baseline nhanh cho bài toán rút gọn đặc trưng, còn PCA/t-SNE phục vụ giảm chiều và trực quan hóa.
Biểu đồ so sánh hiệu năng theo số lượng đặc trưng được trình bày trong Hình 17.

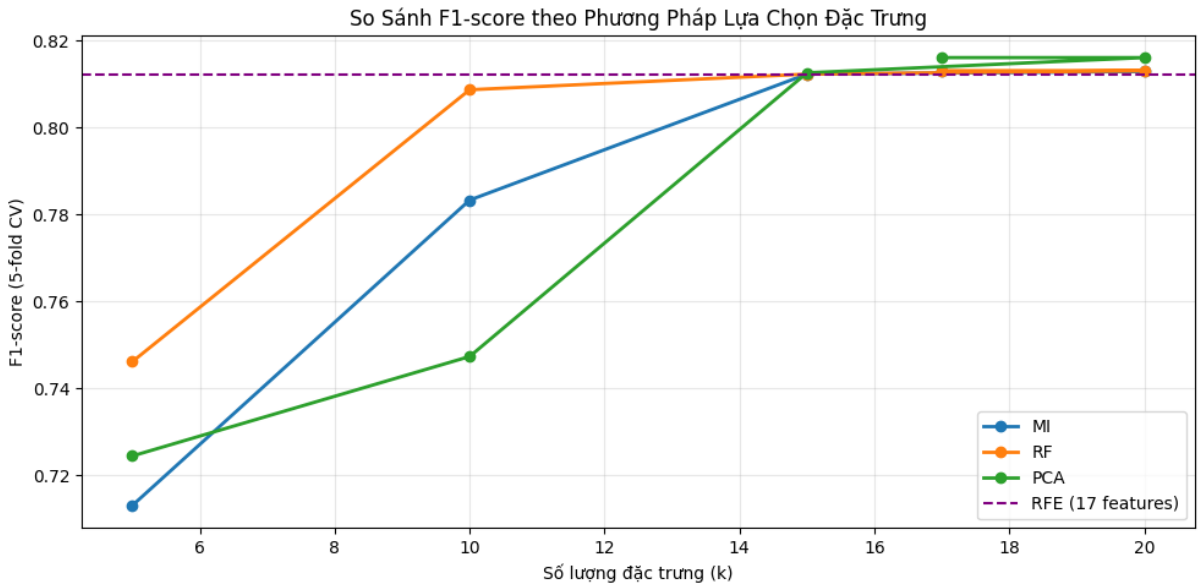

Hình 17: So sánh F1-score theo số lượng đặc trưng cho MI, RF, PCA và RFE.

4.3.6 Xử lý mất cân bằng lớp

Đây là bước nâng cao vì cần tối ưu đồng thời khả năng phát hiện lớp thiểu số và độ tin cậy tổng thể của mô hình. Nhóm đánh giá 4 cấu hình: Baseline (không resampling), SMOTE, ADASYN và

Random Under-sampling (Chawla et al., 2002; He et al., 2008). Thiết kế thí nghiệm được cố định như sau:

- Chia train/test theo *stratified split*; tập test giữ nguyên phân phối gốc để phản ánh tình huống triển khai thực tế.
- Chỉ resampling trên tập train để tránh data leakage.
- Dùng cùng một mô hình đánh giá (Random Forest, `n_estimators=50`, `max_depth=8`) cho mọi chiến lược để đảm bảo so sánh công bằng.

Kết quả định lượng trên tập test gốc:

- Baseline: Precision = 0.897, Recall = 0.869, F1-macro = 0.882, AUC-ROC = 0.969.
- SMOTE: Precision = 0.866, Recall = 0.904, F1-macro = 0.883, AUC-ROC = 0.969.
- ADASYN: Precision = 0.853, Recall = 0.901, F1-macro = 0.874, AUC-ROC = 0.964.
- Random Under-sampling: Precision = 0.836, Recall = 0.913, F1-macro = 0.866, AUC-ROC = 0.969.

Diễn giải theo góc nhìn nâng cao cho thấy Under-sampling đẩy Recall cao nhất nhưng làm giảm Precision rõ rệt do mất nhiều mẫu lớp đa số; ADASYN cải thiện Recall nhưng kém ổn định hơn ở AUC. Baseline có Precision tốt nhưng bỏ sót nhiều ca dương tính hơn. **SMOTE** là cấu hình cân bằng nhất: tăng Recall đáng kể so với baseline (+3.5% tương đối), giữ AUC-ROC không giảm, và đạt F1-macro cao nhất (0.883). Với bài toán sàng lọc nguy cơ trầm cảm, cấu hình ưu tiên Recall nhưng vẫn kiểm soát false positive ở mức hợp lý là phù hợp nhất.
Kết quả so sánh Precision, Recall, F1-macro và AUC-ROC giữa các chiến lược được trình bày trong Hình 18.

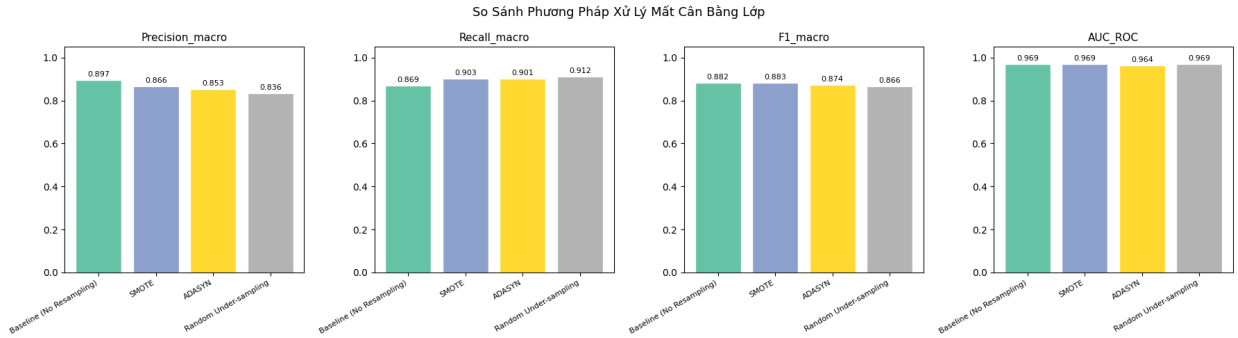

Hình 18: So sánh các chiến lược xử lý mất cân bằng lớp trên tập test gốc.

4.4 Đánh giá pipeline

Bảng 9 tổng hợp các kết quả định lượng cho từng bước trong pipeline tiền xử lý bảng

Kỹ thuật	**Phương pháp tốt nhất**	**Kém nhất**	**Chỉ số chính**
Điền khuyết	Mean	Mode	RMSE: 5.78 vs 9.03
Ngoại lai	IsoForest (0.05)	—	KS: tất cả biến $p < 0.05$
Chuẩn hóa	Robust Scaling	Quantile (uniform)	Levene + violin plot
Mã hóa	Binary Encoding	Frequency Encoding	VIF: 4.21 vs 889.59
Chọn đặc trưng	RFE	MI ($k = 5$)	F1 xấp xỉ 0.813
Cân bằng lớp	SMOTE	Random Under-sampling	F1-macro: 0.883 vs 0.866

Bảng 9: Tổng hợp kết quả định lượng cho phần dữ liệu bảng

Sau khi hoàn thành tiền xử lý, nhóm triển khai hai bước đánh giá: (1) tổng hợp phương pháp tốt nhất cho từng công đoạn tiền xử lý, và (2) dựng dataset cuối để lưu cho các bước mô hình hóa tiếp theo.

4.4.1 Tổng hợp cấu hình tốt nhất

Cấu hình được chọn cho từng bước là:

- Điền khuyết: Mean cho benchmark số, kết hợp chiến lược theo ngữ cảnh nhóm cho dữ liệu thực tế.
- Ngoại lai: Isolation Forest với contamination = 0.05.
- Chuẩn hóa: Robust Scaling.
- Mã hóa: Binary Encoding.

- Chọn đặc trưng: RFE (F1 cao và ổn định, khoảng 0.813).
- Mất cân bằng lớp: SMOTE (F1-macro cao nhất khoảng 0.883).

Hai bước (chọn đặc trưng và cân bằng lớp) được dùng cho quá trình huấn luyện mô hình, không phải là biến đổi bắt buộc để xuất file dữ liệu tiền xử lý cuối.

4.4.2 Tạo dataset tiền xử lý cuối

Pipeline xuất dữ liệu gồm 4 bước:

1. Loại ngoại lai bằng `IsoForest_0.05`.
2. Chuẩn hóa 8 biến số bằng `RobustScaler`.
3. Mã hóa nhị phân toàn bộ biến phân loại (trừ nhãn *Depression*).
4. Đưa nhãn mục tiêu về cột cuối và lưu file kết quả.

4.5 Kết luận

Từ toàn bộ hai notebook tabular (EDA và preprocessing), nhóm xây dựng pipeline đề xuất cho dữ liệu bảng gồm:

1. Điền khuyết theo ngữ cảnh vai trò (Student/Working Professional) kết hợp benchmark RMSE.
2. Phát hiện ngoại lai bằng Isolation Forest (contamination = 0.05).
3. Chuẩn hóa biến số bằng Robust Scaling.
4. Mã hóa biến phân loại theo chiến lược hỗn hợp (One-Hot cho low-cardinality, Binary cho high-cardinality).
5. Chọn đặc trưng bằng RF importance hoặc RFE để giữ tập biến gọn và ổn định.
6. Cân bằng lớp bằng SMOTE ở giai đoạn huấn luyện.

Kết quả định lượng cho thấy pipeline này vừa kiểm soát tốt chất lượng dữ liệu (thiếu, ngoại lai, đa cộng tuyến), vừa duy trì hiệu năng mô hình ở mức cao với F1-macro tốt nhất 0.883 trên bài toán phân loại *Depression*. Do đó, pipeline tabular được chọn làm cấu hình chuẩn cho các bước mô hình hóa phía sau.

5 Tiền xử lý dữ liệu chuỗi thời gian

5.1 Dữ liệu sử dụng

Nhóm sử dụng bộ dữ liệu tiêu thụ điện Tây Ban Nha (*Spain Energy Consumption Dataset*) cho phần chuỗi thời gian.

Tập dữ liệu có 35,064 quan sát theo tần suất giờ trong giai đoạn 2015–2019. Biến mục tiêu chính là tải điện (MW), đồng thời có các biến hỗ trợ theo ngữ cảnh thời gian để phục vụ bước nội suy, kiểm định tính dừng, trích xuất đặc trưng và dự báo một bước trước.

Bộ dữ liệu này phù hợp với yêu cầu đề bài ở ba điểm:

- Đủ chiều dài chuỗi theo nhiều năm.
- Có tính mùa vụ theo ngày và theo tuần.
- Có ý nghĩa thực tiễn rõ ràng cho bài toán tiền xử lý phục vụ dự báo.

5.2 Phân tích khám phá chuỗi thời gian

Nhóm tập trung vào 4 câu hỏi chính:

- Chuỗi có xu hướng dài hạn hay không?
- Mùa vụ xuất hiện ở các chu kỳ nào?
- Mức dao động thay đổi ra sao theo thời gian?
- Chuỗi có thỏa điều kiện dừng để mô hình hóa trực tiếp hay không?

Kết quả chính từ notebook EDA thời gian cho thấy:

- Biến *total load actual* chỉ thiếu 36 điểm trên toàn bộ chuỗi (xấp xỉ 0.1%), nên không làm méo cấu trúc tín hiệu tổng thể ở bước khám phá.
- Time plot toàn giai đoạn cho thấy không có xu hướng tăng/giảm tuyến tính dài hạn rõ rệt, nhưng xuất hiện mùa vụ mạnh theo năm; khi phóng to theo tuần, chu kỳ ngày và khác biệt giữa ngày làm việc–cuối tuần thể hiện rõ.

- ACF/PACF xác nhận tự tương quan mạnh ở các độ trễ ngắn và tại các bội số của 24 giờ, đồng thời xuất hiện dấu hiệu mùa vụ tuần (168 giờ).
- Rolling mean và rolling std (cửa sổ 7/30/90 ngày) đều biến thiên theo thời gian, cho thấy chuỗi chưa dừng và cần biến đổi ở bước tiền xử lý tiếp theo.

5.2.1 Time Plot

Time plot toàn giai đoạn 2015–2019 cho thấy chuỗi tải điện dao động quanh một mức trung bình tương đối ổn định, chưa ghi nhận xu hướng tuyến tính tăng/giảm dài hạn rõ rệt (Hình 19). Tuy nhiên, đường bao chuỗi lặp lại theo các nhịp lớn theo năm, phản ánh tác động mùa vụ vĩ mô (thời tiết và nhu cầu tiêu thụ theo mùa).

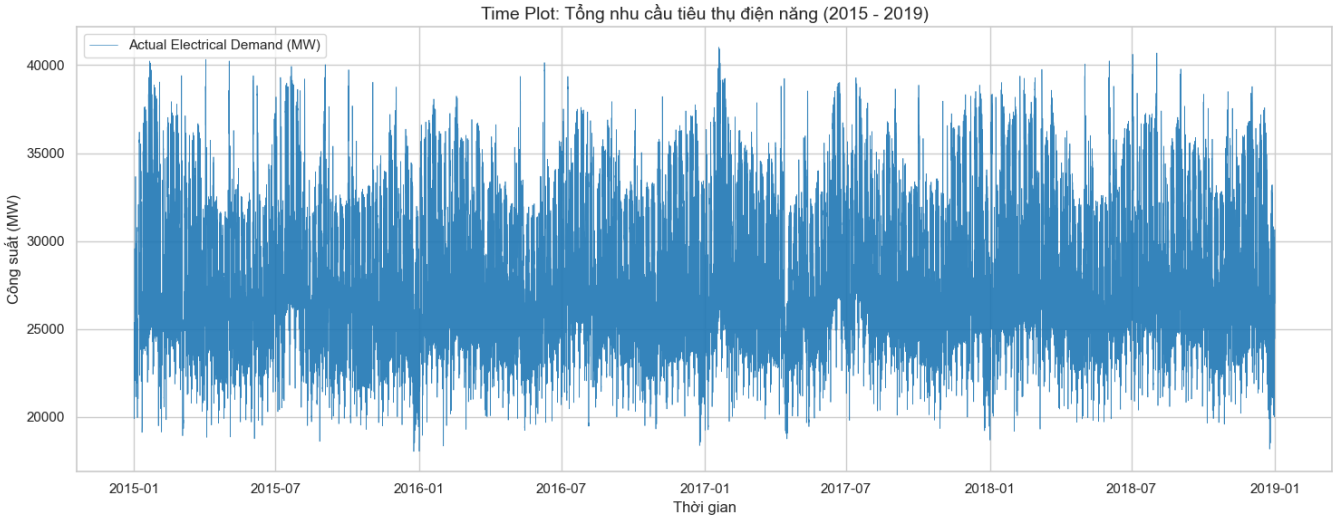

Hình 19: Time plot toàn giai đoạn 2015–2019 cho biến *total load actual*.

Khi phóng to về tuần đầu năm 2015, cấu trúc chu kỳ ngắn hạn hiện rõ hơn:

- Chu kỳ ngày (24 giờ): phụ tải giảm vào rạng sáng và tăng lên vào các khung giờ hoạt động cao trong ngày.
- Chu kỳ tuần: biên độ tải ở ngày làm việc cao hơn đáng kể so với cuối tuần.
- Hiệu ứng ngày lễ: các ngày lễ đầu năm tạo ra các điểm sụt phụ tải bất thường, khác với dao động tuần thông thường.

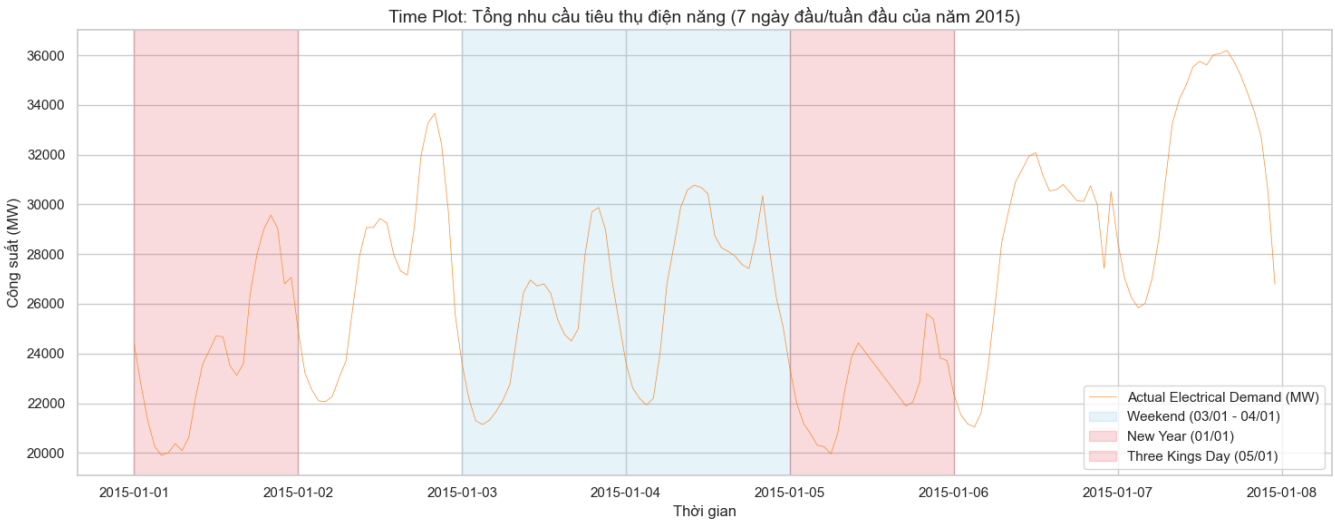

Hình 20: Time plot tuần đầu năm 2015 cho biến *total load actual*.

Phân tích time-plot cho ta thấy các thành phần cấu trúc của chuỗi có đặc điểm:

1. **Xu hướng (Trend)**: không rõ ràng, có thể coi là gần như không tồn tại trong giai đoạn này.
2. **Mùa vụ (Seasonality)**: rất rõ ràng ở cả chu kỳ ngày và tuần, với biên độ thay đổi theo mùa trong năm.
3. **Nhiễu và Hiệu ứng ngày lễ (Noise & Holiday Effects)**: có dao động ngắn hạn và một số điểm bất thường (outliers) liên quan đến ngày lễ.
4. **Tính dừng (Stationarity)**: mặc dù phương sai tương đối đồng đều và không có xu hướng dài hạn, nhưng sẽ có những tính mùa vụ lồng ghép phức tạp khiến mean của chuỗi thay đổi liên tục theo thời gian. Do đó, có thể nói đây là chuỗi không dừng (non-stationary)

5.2.2 Phân tích tương quan ACF và PACF

Theo công thức thực nghiệm $\min(10\log_{10} n, n/5)$, số lag tối đa ban đầu xấp xỉ 45 (Hình 21). Tuy nhiên, do dữ liệu có tần suất giờ, nhóm mở rộng phân tích đến 168 lag để kiểm tra đầy đủ chu kỳ ngày (24 giờ) và tuần (168 giờ) (Hình 22).

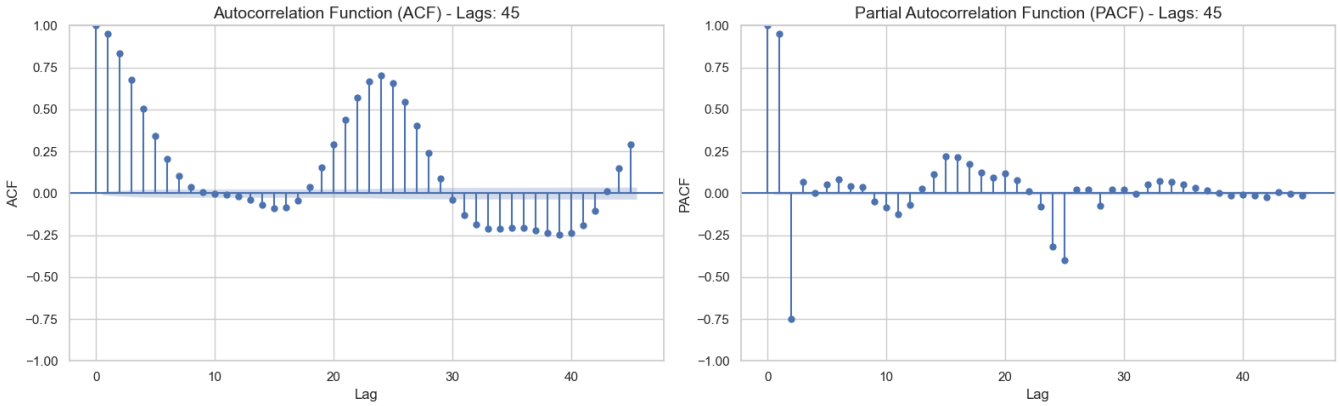

Hình 21: ACF và PACF cho biến *total load actual* với lag tối đa 45.

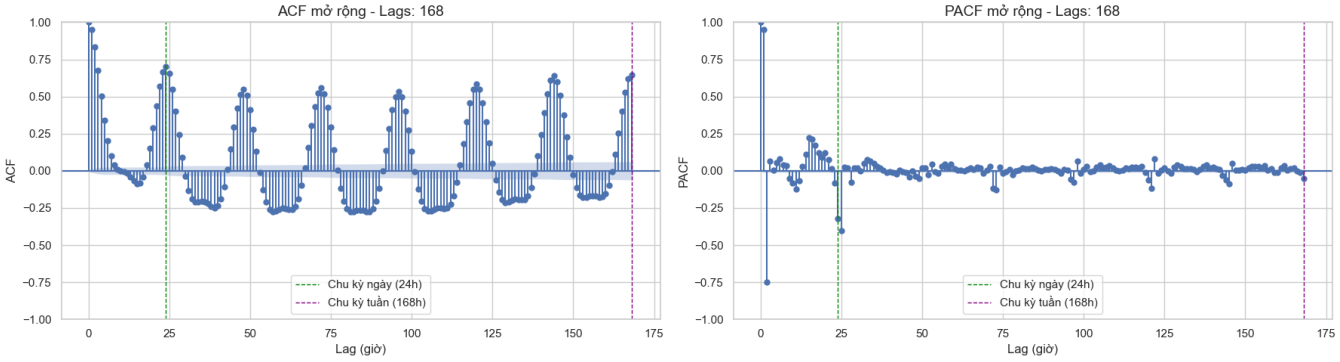

Hình 22: ACF và PACF mở rộng đến lag 168 để kiểm tra mùa vụ ngày và tuần.

Kết quả **ACF** cho thấy hệ số tự tương quan suy giảm chậm và duy trì ý nghĩa ở nhiều lag xa, hàm ý chuỗi có tính nhớ dài và chưa dừng. Đồng thời, các đỉnh lặp lại tại các bội số của 24 giờ củng cố bằng chứng về mùa vụ ngày; đỉnh tại vùng 168 giờ cho thấy mùa vụ tuần cũng hiện diện rõ.

Ở **PACF**, các gai (spikes) lớn tập trung tại các lag đầu (đặc biệt lag 1 và 2), sau đó giảm nhanh, cho thấy ảnh hưởng trực tiếp chủ yếu đến từ lịch sử rất gần. Ngoài ra, sự xuất hiện gai đáng chú ý quanh lag 24 phản ánh tác động mùa vụ ngày lên quan sát hiện tại.

Căn cứ vào PACF, khi xây dựng ma trận đặc trưng cho dự báo, ta cần bắt buộc tạo các biến trễ (lag features) ngắn hạn quan trọng lag $t-1, t-2$ và các lag có giá trị tương quan âm mạnh tại $t-3$ và đặc biệt là $t-24$ để nắm bắt được ảnh hưởng của chu kỳ ngày.

5.2.3 Rolling statistics

Rolling mean và rolling standard deviation được tính trên ba cửa sổ 168, 720 và 2160 giờ (tương ứng 7, 30 và 90 ngày) để đánh giá sự ổn định của kỳ vọng và phương sai theo thời gian.

Quan sát trên rolling mean cho thấy khi tăng kích thước cửa sổ, nhiễu ngắn hạn được làm phẳng nhưng đường trung bình vẫn dao động có chu kỳ thay vì hội tụ về hằng số. Ở cửa sổ dài (90 ngày), đường trung bình thể hiện rõ các nhịp lên xuống vĩ mô theo mùa.
Với rolling std, độ biến thiên cũng thay đổi theo thời gian: ở cửa sổ ngắn dao động mạnh, còn ở cửa sổ dài vẫn duy trì dạng dao động có cấu trúc. Điều này cho thấy phương sai của chuỗi không ổn định theo nghĩa thống kê.
Như vậy, cả hai điều kiện dừng quan trọng (mean và variance bất biến theo thời gian) đều bị vi phạm. Đây là cơ sở để áp dụng bước ổn định phương sai (log/Box-Cox) kết hợp sai phân hoặc decomposition ở các bước tiền xử lý kế tiếp.

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Pipeline tiền xử lý cho dữ liệu chuỗi thời gian được tổ chức theo thứ tự: xử lý giá trị thiếu theo mốc thời gian, kiểm định tính dừng và biến đổi, phân rã cấu trúc chuỗi, phát hiện dị thường, xây dựng ma trận đặc trưng, rồi đánh giá bằng bài toán dự báo một bước trước $(t + 1)$. Kết quả chi tiết từng bước được dùng để chọn cấu hình tiền xử lý tối ưu theo cả tiêu chí thống kê và hiệu năng dự báo.

5.3.1 Xử lý khoảng trống thời gian và nội suy

Nhóm chủ động loại bỏ ngẫu nhiên 5% dữ liệu theo cơ chế MCAR để so sánh 5 phương pháp: Forward Fill, Linear, Polynomial bậc 2, Polynomial bậc 3 và Spline Cubic. Sai số được đánh giá trên đúng các vị trí bị che bằng MAE và RMSE; đồng thời kiểm định Ljung-Box được dùng để kiểm tra cấu trúc phần dư sau nội suy (Ljung and Box, 1978).
Kết quả cho thấy:

- **Forward Fill** kém nhất (MAE xấp xỉ 1160, RMSE xấp xỉ 1604), do không theo kịp độ cong tự nhiên của phụ tải theo giờ.
- **Linear** cải thiện đáng kể (MAE xấp xỉ 427) nhưng vẫn chưa nắm bắt tốt phi tuyến cục bộ.
- Nhóm phương pháp phi tuyến vượt trội; **Polynomial bậc 2** tốt nhất với MAE xấp xỉ 276.23 và RMSE xấp xỉ 508.74.

- Với cả 5 phương pháp, p-value Ljung-Box đều lớn hơn 0.05 (khoảng 0.4889–0.9014), nghĩa là phần dư không còn tự tương quan có ý nghĩa thống kê.

Phân phối phần dư của phương pháp tốt nhất (Polynomial bậc 2) được thể hiện tại Hình 23.

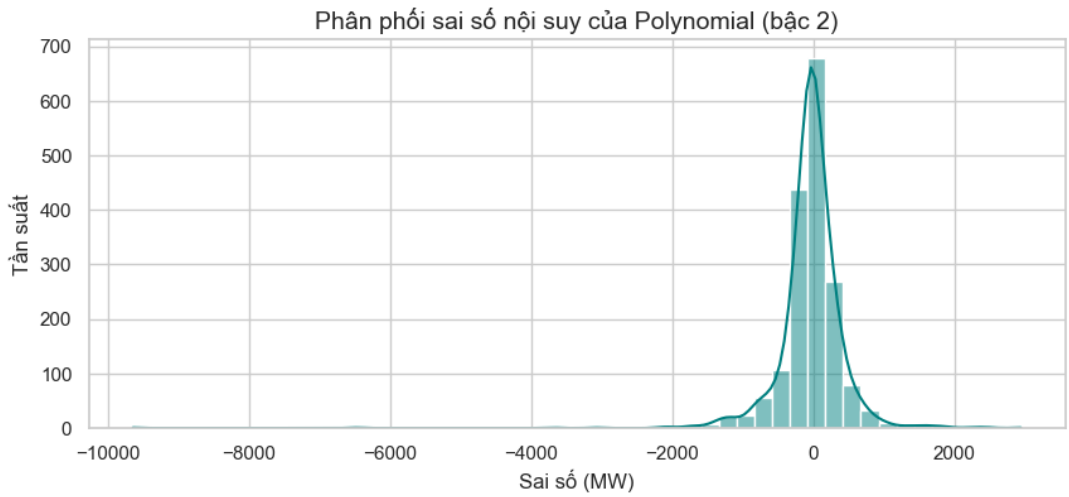

Hình 23: Phân phối phần dư của phương pháp nội suy Polynomial bậc 2 tại các điểm thiếu MCAR 5%.

Từ đó, nhóm chọn **Polynomial bậc 2** làm cấu hình nội suy chính cho pipeline làm sạch dữ liệu lịch sử.

5.3.2 Kiểm định tính dừng (Stationarity Tests)

Nhóm dùng bộ ba kiểm định ADF, KPSS và Phillips-Perron (PP) trên nhiều phiên bản chuỗi: chuỗi gốc, Log-transform, Box-Cox, Box-Cox + sai phân bậc 1, và sai phân bậc 2 (Dickey and Fuller, 1979; Kwiatkowski et al., 1992; Phillips and Perron, 1988). Cách phối hợp ba kiểm định giúp giảm rủi ro kết luận sai nếu chỉ dựa vào một phép thử.
Giả thuyết kiểm định được dùng theo chuẩn:

- ADF/PP: H_0 chuỗi có unit root (không dừng), H_1 chuỗi dừng.
- KPSS: H_0 chuỗi dừng, H_1 chuỗi không dừng.

Quy tắc ra quyết định trong báo cáo:

- Chỉ chấp nhận chuỗi dừng khi ADF và PP cùng bác bỏ H_0 (p-value nhỏ), đồng thời KPSS không bác bỏ H_0 (p-value đủ lớn).

- Nếu kết quả mâu thuẫn, ưu tiên biến đổi nhẹ hơn để tránh over-differencing.

Nhận xét kết quả kiểm định:

- **Chuỗi gốc chưa dừng:** KPSS chạm ngưỡng dưới 0.0100.
- **Log-transform chưa đủ mạnh:** KPSS vẫn ở mức 0.0100.
- **Box-Cox + sai phân bậc 1 cho kết quả tốt nhất:** với $\lambda \approx 0.6341$, KPSS lên ngưỡng trên 0.1000, đồng thời ADF và PP cho p-value rất nhỏ (Box and Cox, 1964).
- **Sai phân bậc 2 không cần thiết:** không cải thiện rõ ràng, có nguy cơ over-differencing và làm mất tín hiệu ngắn hạn.

→ **Kết luận lựa chọn:** biến đổi được chốt cho pipeline là **Box-Cox + sai phân bậc 1**. Lựa chọn này vừa đạt tính dừng về mặt thống kê, vừa giữ được thông tin cần thiết cho bài toán dự báo $t+1$.

5.3.3 Phân rã chuỗi thời gian

Nhóm so sánh Additive, Multiplicative và STL với chu kỳ tuần 168 giờ (phù hợp dữ liệu theo giờ). Chỉ số đánh giá là tỉ lệ phương sai phần dư (Cleveland et al., 1990):

$$\mathrm{RVR} = \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(y_t)}.$$

Kết quả:

- Additive: RVR = 0.7200 (khả năng bóc tách cấu trúc thấp).
- Multiplicative: RVR = 0.0000 (kết quả không đáng tin cậy về mặt thực tiễn, có dấu hiệu artifact).
- STL: RVR = 0.3319 (hợp lý và tốt nhất trong ba phương pháp).

Cấu trúc các thành phần sau phân rã được minh họa tại Hình 24.

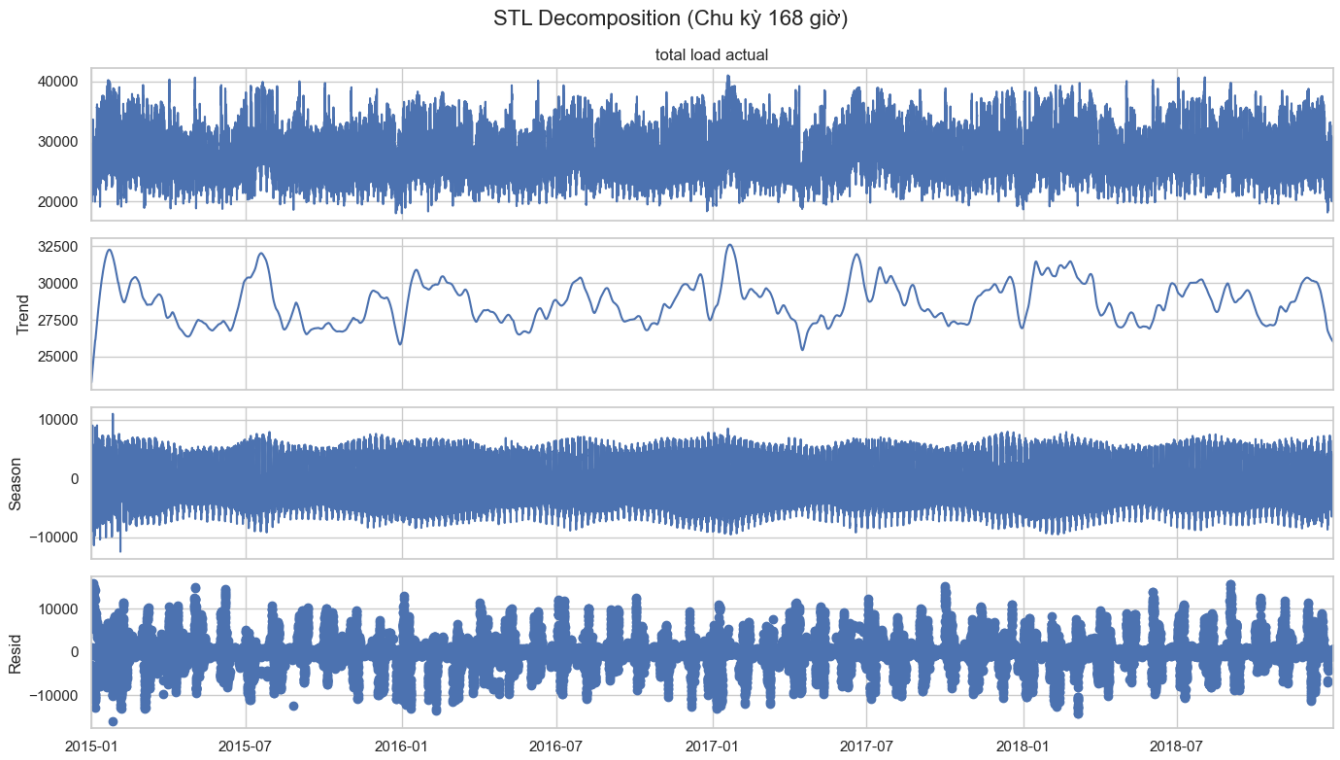

Hình 24: Kết quả STL decomposition với chu kỳ tuần 168 giờ trên chuỗi đã làm sạch.

Theo đó, nhóm sử dụng **STL decomposition** để lấy các chuỗi dẫn xuất: `stl_trend`, `stl_seasonal`, `stl_resid`, `deseasonalized`, `detrend` cho các bước tiếp theo.

5.3.4 Feature Engineering & Phát hiện dị thường

Phát hiện dị thường

Phát hiện dị thường được thực hiện sau khi chuỗi đã nội suy và phân rã STL, nhằm tách rõ dị thường biên độ lớn khỏi dao động mùa vụ bình thường. Nhóm triển khai ba hướng bổ sung nhau:

- **Z-score** trên chuỗi deseasonalized (ngưỡng $|z| > 3$): bắt các điểm lệch mạnh theo chuẩn hóa toàn cục.
- **Isolation Forest** (contamination = 0.01) trên đặc trưng rolling 24h: phát hiện dị thường theo hình học đa chiều cục bộ.
- **STL residual thresholding** với ngưỡng 3σ: nhắm trực tiếp vào phần dư sau khi đã tách trend và seasonality.

Số lượng điểm dị thường phát hiện được:

- Z-score: 662 điểm.
- Isolation Forest (contamination = 0.01): 350 điểm.
- STL Residual Thresholding: 1055 điểm.

Nhận xét theo mục tiêu vận hành:

- **Isolation Forest** cho tập dị thường hẹp nhất, phù hợp kịch bản cảnh báo bảo thủ.
- **Z-score** ở mức trung gian, dễ diễn giải nhưng nhạy với giả định phân phối.
- **STL residual thresholding** cho độ phủ lớn nhất, phù hợp khi ưu tiên không bỏ sót các cú sốc ngoại sinh (ngày lễ, thời tiết cực đoan, sự cố hệ thống).

Phân bố điểm dị thường theo từng phương pháp được minh họa tại Hình 25.

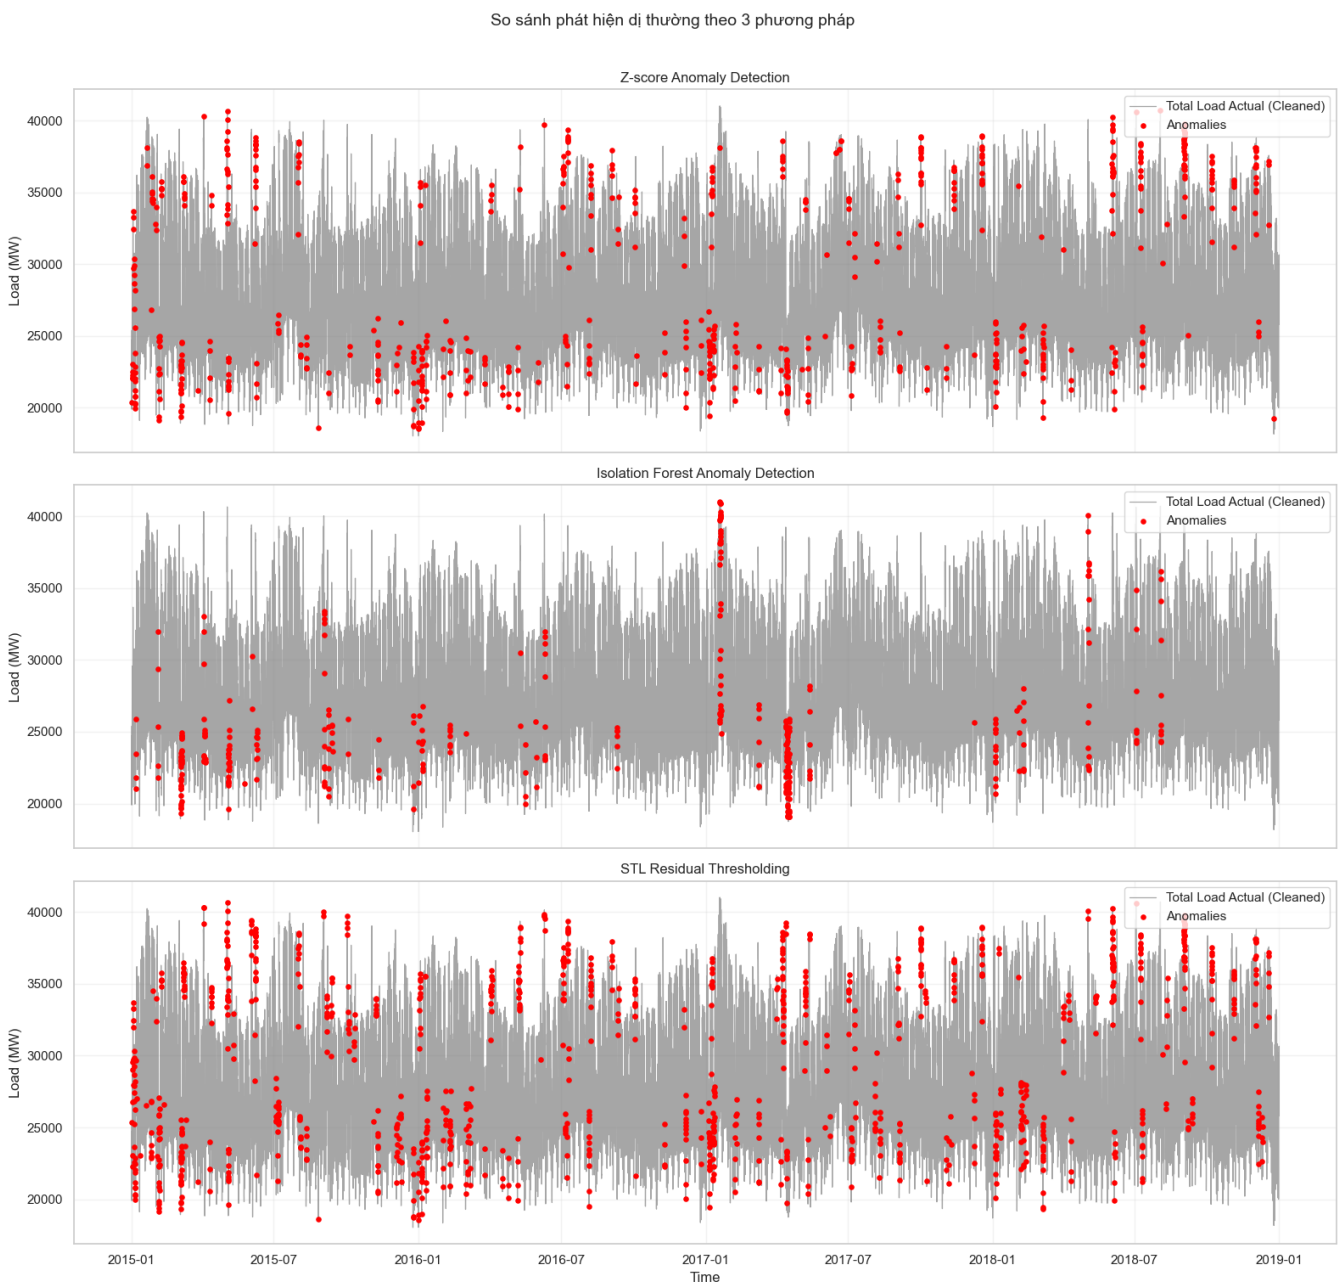

Hình 25: So sánh các điểm dị thường được phát hiện bởi Z-score, Isolation Forest và ngưỡng phần dư STL.

→ **Kết luận lựa chọn:** nhóm chọn **STL Residual Thresholding** làm lớp dị thường chính và dùng Z-score/Isolation Forest làm lớp đối chiếu. Cách kết hợp này giúp tăng độ bao phủ cảnh báo nhưng vẫn có cơ chế kiểm tra chéo để tránh cảnh báo giả quá mức.

Xây dựng ma trận đặc trưng thời gian

Nhóm chuyển chuỗi thời gian về bài toán supervised dự báo một bước trước $(t+1)$: mỗi dòng dữ liệu tại thời điểm t dùng để dự báo `load` tại thời điểm $t+1$. Ma trận đặc trưng được xây dựng theo nguyên tắc không dùng thông tin tương lai (causal features only), gồm:

- **Lag features:** $t-1, t-2, t-3, t-24$ (theo kết quả PACF), đại diện cho trí nhớ ngắn hạn và chu kỳ ngày.
- **Rolling features:** mean/std/min/max trên các cửa sổ 6h, 24h, 168h để mã hóa biến thiên nội ngày, nội tuần và mức dao động cục bộ.
- **Cyclic encoding:** sin/cos cho giờ, thứ, tháng nhằm biểu diễn chu kỳ mà không tạo ngắt quãng giả tại biên (ví dụ 23h sang 0h).
- **Calendar feature:** cờ ngày lễ Tây Ban Nha để bắt các dịch chuyển phụ tải do hành vi tiêu thụ đặc biệt.
- **Decomposition-based features:** `stl_trend`, `stl_seasonal`, `stl_resid` và các biến dẫn xuất để tách thông tin cấu trúc khỏi nhiễu.
- **Stationary feature:** `diff_1` từ chuỗi Box-Cox + sai phân bậc 1, giúp mô hình học động học thay đổi biên độ.

Nhận xét về vai trò của ma trận đặc trưng:

- Nhóm **lag + rolling** giúp mô hình học trí nhớ ngắn hạn và mức dao động cục bộ.
- Nhóm **cyclic + holiday** mã hóa đúng bối cảnh hành vi tiêu thụ theo lịch.
- Nhóm **STL + diff_1** giúp tách thông tin cấu trúc nền khỏi nhiễu và biến thiên đột ngột.

Trong khâu huấn luyện, nhóm tách train/test theo thời gian (năm cuối làm test) để bảo toàn thứ tự thời gian và tránh rò rỉ thông tin.
→ **Kết luận lựa chọn:** ma trận đặc trưng này đáp ứng đồng thời ba mục tiêu của bài toán dự báo tải điện: bám sát động học ngắn hạn, nắm bắt mùa vụ đa chu kỳ, và giữ được thông tin bối cảnh lịch.

5.4 Đánh giá pipeline

5.4.1 Đánh giá pipeline bằng dự báo một bước

Để kiểm định chất lượng toàn bộ pipeline, nhóm huấn luyện Random Forest Regressor trên dạng supervised $t+1$, chia tập theo thời gian (năm cuối làm test) (Breiman, 2001).
Kết quả trên tập test:

- MAE = 304.15 MW.
- RMSE = 505.03 MW.

Với mức phụ tải trung bình khoảng 28,700 MW, sai số MAE vào khoảng 1%, cho thấy pipeline tiền xử lý tạo ra không gian đặc trưng đủ tốt để mô hình nền đạt hiệu năng dự báo cao.
Phân tích feature importance cũng nhất quán với EDA trước đó:

- `load` chi phối mạnh nhất (xấp xỉ 89.51%).
- `diff_1` đứng thứ hai (xấp xỉ 5.04%).
- Cặp `hour_cos`, `hour_sin` xác nhận vai trò chu kỳ ngày.

Top đặc trưng quan trọng nhất của mô hình được thể hiện tại Hình 26.

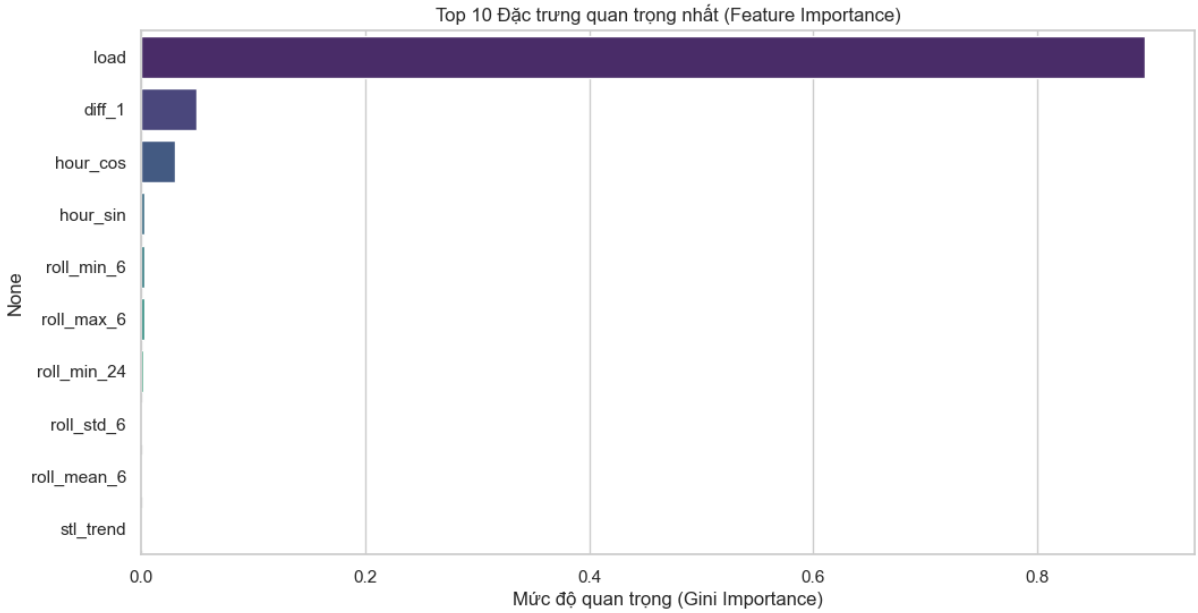

Hình 26: Top 10 đặc trưng quan trọng nhất của mô hình Random Forest cho bài toán dự báo $t+1$.

5.4.2 Phân tích nhân quả Granger đa biến

Nhóm kiểm định Granger ở lag 3 trên các chuỗi đã được chuẩn hóa tính dừng (bao gồm `ts_diff` cho tải và sai phân bậc 1 cho các biến ngoại sinh) (Granger, 1969).
Các quan hệ nổi bật theo F-statistic:

- load → solar: 947.4.
- load → price: 872.0.
- price → load: 670.3.
- solar → load: 633.9.
- load → gas: 544.6.

Nhóm biến gió có F-stat thấp hơn đáng kể, cho thấy tính độc lập cao hơn so với các biến còn lại. Kết quả này củng cố luận điểm rằng tải tiêu thụ và giá điện có cơ chế dẫn dắt hai chiều theo thời gian, và các nguồn phát linh hoạt như khí đóng vai trò cân bằng hệ thống.
Ma trận độ mạnh nhân quả Granger giữa các biến được trình bày tại Hình 27.

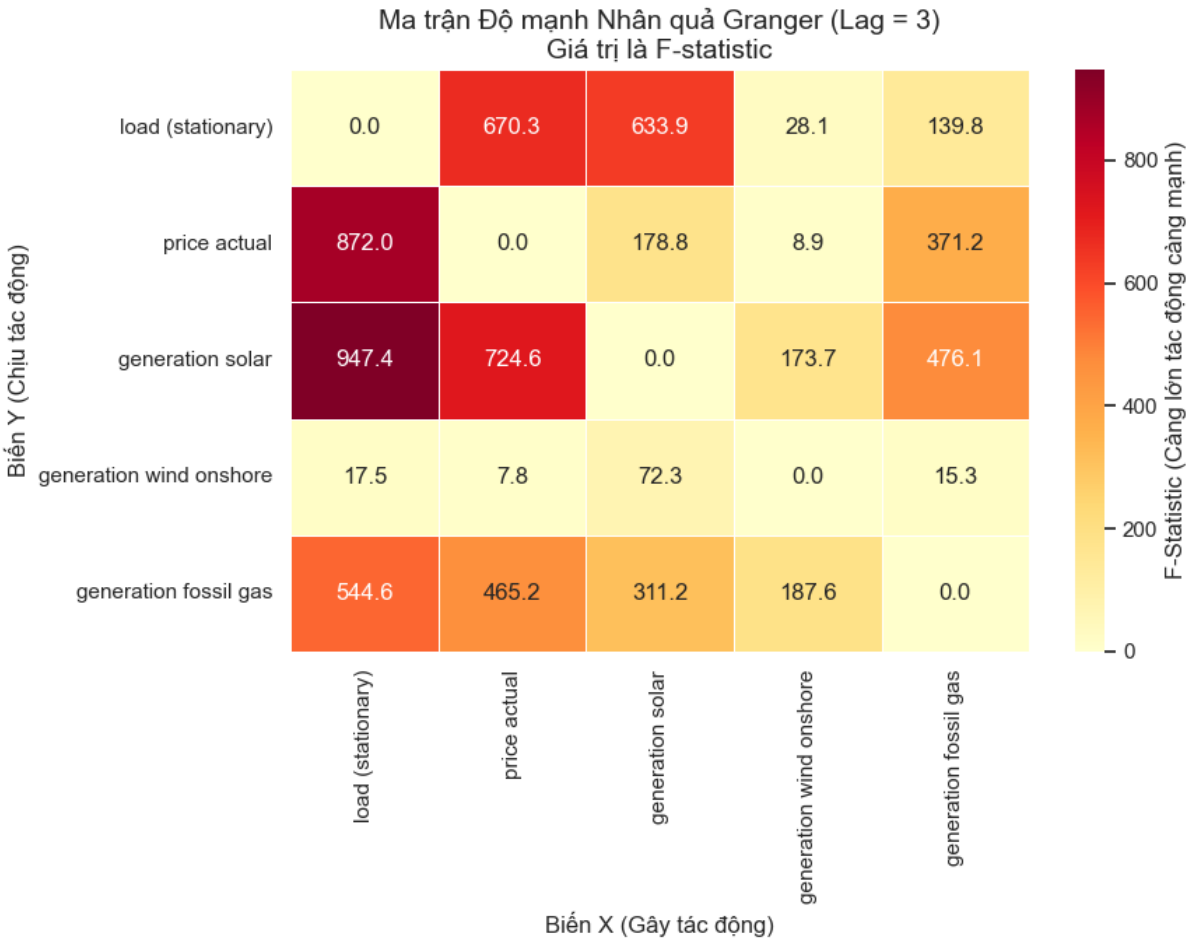

Hình 27: Ma trận độ mạnh nhân quả Granger (F-statistic) với lag 3 trên dữ liệu đã chuẩn hóa tính dừng.

Bảng 10 tổng hợp các kết quả định lượng chính cho từng bước trong pipeline tiền xử lý chuỗi thời gian, cung cấp cái nhìn tổng quan về hiệu quả của từng kỹ thuật đã triển khai.

Bước	**Lựa chọn**	**Kết quả chính**
Nội suy thiếu	Polynomial bậc 2	MAE $\approx$ 276.23, RMSE $\approx$ 508.74; Ljung-Box p-value $>$ 0.05
Ổn định chuỗi	Box-Cox + sai phân bậc 1	$\lambda \approx 0.6341$; KPSS từ 0.0100 lên 0.1000
Phân rã	STL (period = 168)	RVR thấp nhất hợp lý: 0.3319
Dị thường	STL residual thresholding	Phát hiện 1055 điểm bất thường
Dự báo $t+1$	Random Forest (baseline)	MAE = 304.15 MW; RMSE = 505.03 MW
Granger	Lag 3, dữ liệu dừng đa biến	Quan hệ mạnh giữa load, price, solar, gas

Bảng 10: Tổng hợp kết quả định lượng cho pipeline tiền xử lý chuỗi thời gian

5.5 Kết luận

Từ toàn bộ ba notebook temporal, nhóm đã xây dựng một pipeline tiền xử lý hoàn chỉnh cho dữ liệu chuỗi thời gian gồm các bước:

1. Chuẩn hóa trục thời gian theo giờ.
2. Điền thiếu bằng Polynomial bậc 2.
3. Ổn định chuỗi bằng Box-Cox + sai phân bậc 1.
4. Phân rã STL theo chu kỳ 168 giờ.
5. Phát hiện dị thường dựa trên phần dư STL.
6. Xây dựng đặc trưng lag–rolling–cyclic–calendar.
7. Đánh giá bằng dự báo một bước trước $(t+1)$.

Kết quả định lượng cho thấy pipeline này vừa đảm bảo tính đúng đắn thống kê (chuỗi đạt dừng sau biến đổi, phân rã tách được cấu trúc rõ ràng), vừa cho hiệu năng dự báo tốt trên dữ liệu thực tế với bài toán một bước trước (MAE 304.15 MW, RMSE 505.03 MW).

6 Kết luận

Nhóm đã xây dựng toàn bộ quy trình tiền xử lý dữ liệu cho ba dạng dữ liệu phổ biến trong thực tiễn khai phá dữ liệu: dữ liệu bảng, chuỗi thời gian và ảnh. Mỗi dạng dữ liệu đặt ra những thách thức đặc thù và đòi hỏi chiến lược xử lý riêng biệt. Tuy nhiên, cả ba đều tuân theo một triết lý chung: mỗi quyết định kỹ thuật phải được căn cứ trên chỉ số định lượng đo lường được, không phải heuristic chủ quan.

Tài liệu

Bansal, P. (2019). *Intel image classification dataset*. Retrieved April 20, 2026, from https://www.kaggle.com/datasets/puneet6060/intel-image-classification

Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, *26*(2), 211–252. https://doi.org/10.1111/j.2517-6161.1964.tb00553.x

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). Lof: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93–104. https://doi.org/10.1145/342009.335388

Canny, J. (1986). A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *8*(6), 679–698. https://doi.org/10.1109/TPAMI.1986.4767851

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

CIE. (1976). Colorimetry. *CIE Publication 15*.

Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). Stl: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, *6*(1), 3–73.

D'Agostino, R. B., & Pearson, E. S. (1973). Tests for departure from normality. empirical results for the distributions of b_2 and $\sqrt{b_1}$. *Biometrika*, *60*(3), 613–622. https://doi.org/10.1093/biomet/60.3.613

Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, *74*(366a), 427–431. https://doi.org/10.1080/01621459.1979.10482531

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 226–231.

Fisher, R. A. (1925). *Statistical methods for research workers*. Oliver; Boyd.

Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, *37*(3), 424–438. https://doi.org/10.2307/1912791

Guyon, I., Weston, J., Barnhill, S., & Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. *Machine Learning*, *46*(1–3), 389–422. https://doi.org/10.1023/A:1012487302797

He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). Adasyn: Adaptive synthetic sampling approach for imbalanced learning. *2008 IEEE International Joint Conference on Neural Networks*, 1322–1328. https://doi.org/10.1109/IJCNN.2008.4633969

Huber, P. J. (1981). *Robust statistics*. Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning with applications in r*. Springer.

Jolliffe, I. T. (2002). *Principal component analysis* (2nd ed.). Springer.

Kolmogorov, A. N. (1933). Sulla determinazione empirica di una legge di distribuzione. *Giornale dell'Istituto Italiano degli Attuari*, *4*, 83–91.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, *54*(1–3), 159–178. https://doi.org/10.1016/0304-4076(92)90104-Y

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *2008 Eighth IEEE International Conference on Data Mining*, 413–422. https://doi.org/10.1109/ICDM.2008.17

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, *65*(2), 297–303. https://doi.org/10.1093/biomet/65.2.297

Phillips, P. C. B., & Perron, P. (1988). Testing for a unit root in time series regression. *Biometrika*, *75*(2), 335–346. https://doi.org/10.1093/biomet/75.2.335

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, *63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Smith, A. R. (1978). Color gamut transform pairs. *ACM SIGGRAPH Computer Graphics*, *12*(3), 12–19. https://doi.org/10.1145/965139.807361

Sobel, I., & Feldman, G. (1968). *A* 3×3 *isotropic gradient operator for image processing* (tech. rep.). Stanford Artificial Intelligence Project.

Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., & Altman, R. B. (2001). Missing value estimation methods for dna microarrays. *Bioinformatics*, *17*(6), 520–525. https://doi.org/10.1093/bioinformatics/17.6.520

Turk, M., & Pentland, A. (1991). Eigenfaces for recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 586–591. https://doi.org/10.1162/jocn.1991.3.1.71

van Buuren, S., & Groothuis-Oudshoorn, K. (2011). Mice: Multivariate imputation by chained equations in r. *Journal of Statistical Software*, *45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03

van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-sne. *Journal of Machine Learning Research*, *9*, 2579–2605.

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, *13*(4), 600–612. https://doi.org/10.1109/TIP.2003.819861

Zauner, C. (2010). *Implementation and benchmarking of perceptual image hash functions* (Technical Report). Upper Austria University of Applied Sciences.