ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Đồ án 1

Đề tài: Tiền xử lý dữ liệu

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

22120457 - Khưu Hải Châu

23122006 - Lưu Thượng Hồng

23122020 - Nguyễn Thiên Ấn

23122034 - Lê Nguyên Khang

23122036 - Nguyễn Ngọc Khoa

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhựt Nam

Ngày 18 tháng 4 năm 2026

Mục lục

1 Giới thiệu **1**

2 Phân công công việc **1**

3 Tiền xử lý dữ liệu ảnh **1**

3.1 Dữ liệu sử dụng 1

3.2 Phân tích khám phá và chất lượng dữ liệu 1

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 2

3.4 Kết luận cho pipeline dữ liệu ảnh 2

4 Tiền xử lý dữ liệu dạng bảng **3**

4.1 Dữ liệu sử dụng 3

4.2 Phân tích thống kê khám phá (EDA chuyên sâu) 3

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 4

4.4 Kết luận cho pipeline dữ liệu bảng 5

5 Tiền xử lý dữ liệu chuỗi thời gian **5**

5.1 Dữ liệu sử dụng 5

5.2 Phân tích khám phá chuỗi thời gian 6

5.2.1 Time Plot 6

5.2.2 Phân tích tương quan ACF và PACF 8

5.2.3 Rolling statistics 9

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 10

5.3.1 Xử lý khoảng trống thời gian và nội suy 10

5.3.2 Kiểm định tính dừng và biến đổi chuỗi 11

5.3.3 Phân rã chuỗi thời gian 12

5.4 Feature Engineering & Phát hiện dị thường 13

5.4.1 Phát hiện dị thường 13

5.4.2 Xây dựng ma trận đặc trưng thời gian 14

5.5 Đánh giá pipeline 15

5.5.1 Đánh giá pipeline bằng dự báo một bước 15

5.5.2 Phân tích nhân quả Granger đa biến 16
5.6 Kết luận 18

6 Kết luận **19**

Tài liệu **20**

1 Giới thiệu

Báo cáo này trình bày quá trình tiền xử lý dữ liệu cho ba nhóm bài toán của đồ án: **dữ liệu ảnh**, **dữ liệu bảng** và **dữ liệu chuỗi thời gian**. Trọng tâm của nhóm là triển khai các kỹ thuật theo đề bài, đo lường định lượng tác động của từng bước, thảo luận và đưa ra lựa chọn cuối cùng dựa trên bằng chứng thực nghiệm.

2 Phân công công việc

MSSV	Họ và tên	Công việc
22120457	Khưu Hải Châu	Phân tích dữ liệu ảnh
23122006	Lưu Thượng Hồng	Viết báo cáo
23122020	Nguyễn Thiên Ấn	Viết báo cáo
23122034	Lê Nguyên Khang	Phân tích dữ liệu dạng bảng
23122036	Nguyễn Ngọc Khoa	Phân tích dữ liệu chuỗi thời gian

Bảng 1: Phân công công việc của nhóm

3 Tiền xử lý dữ liệu ảnh

3.1 Dữ liệu sử dụng

Nhóm sử dụng tập ảnh phong cảnh gồm 6 lớp: *buildings, forest, glacier, mountain, sea, street.* Tập dữ liệu gốc có 5,000 ảnh RGB kích thước 150×150, tương ứng nhãn dạng số với 6 lớp.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số ảnh	$\geq$ 5,000	5,000	Đạt
Kích thước ảnh	Đồng nhất	150×150×3	Đạt
Số lớp	$\geq$ 5	6 lớp	Đạt

Bảng 2: Kiểm tra tiêu chí lựa chọn dữ liệu ảnh

3.2 Phân tích khám phá và chất lượng dữ liệu

Phân bố lớp. Tập dữ liệu có phân bố khá đều giữa các lớp. Số ảnh theo lớp lần lượt là: buildings (789), forest (778), glacier (863), mountain (870), sea (814), street (886). Tỉ lệ lớp lớn nhất/lớp nhỏ nhất là 1.14, nhỏ hơn ngưỡng 3, do đó dữ liệu được xem là cân bằng.

Phát hiện ảnh trùng. Nhóm dùng perceptual hash (pHash) để dò ảnh trùng hoặc gần trùng. Kết quả phát hiện 7 ảnh trùng trên 5,000 ảnh (0.14%). Sau khi loại trùng, tập dữ liệu còn 4,993 ảnh.

Độ sáng và tương phản toàn cục. Trên tập đã loại trùng, thống kê mức sáng và độ tương phản cho thấy biên độ biến thiên lớn, phù hợp với đặc thù dữ liệu cảnh ngoài trời.

Thuộc tính	**Độ lệch chuẩn**	**Nhỏ nhất**	**Lớn nhất**
Độ sáng toàn cục	30.8812	18.6553	210.4190
Độ tương phản	13.1707	13.6147	104.6476

Bảng 3: Thống kê độ sáng và độ tương phản trên 4,993 ảnh

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Ablation theo kích thước ảnh. Nhóm đánh giá pipeline cổ điển *flatten + PCA-100 + Logistic Regression / k-NN* bằng 5-fold CV trên mẫu con 2,500 ảnh để chọn kích thước resize phù hợp.

Cấu hình	**LogReg (mean ± std)**	**k-NN (mean ± std)**
Baseline 150×150	0.4924 ± 0.0195	0.4640 ± 0.0194
Resize 32×32	0.4836 ± 0.0205	0.4676 ± 0.0165
Resize 64×64	**0.4936 ± 0.0177**	**0.4672 ± 0.0186**
Resize 128×128	0.4884 ± 0.0162	0.4648 ± 0.0207

Bảng 4: So sánh ablation theo kích thước ảnh (n=2,500, PCA-100, 5-fold CV)

Dựa trên kết quả trên, nhóm chọn kích thước 64×64 cho các bước xử lý và mô hình hóa tiếp theo vì cho hiệu năng tổng thể tốt nhất trong các cấu hình thử nghiệm.

3.4 Kết luận cho pipeline dữ liệu ảnh

Pipeline đề xuất cho dữ liệu ảnh gồm: (i) loại ảnh trùng bằng pHash, (ii) resize ảnh về 64×64, (iii) chuẩn bị đặc trưng phù hợp mô hình (ví dụ flatten + PCA cho mô hình cổ điển). Quy trình này giữ được cân bằng lớp, giảm nhiễu dữ liệu trùng và tối ưu chi phí tính toán so với dùng ảnh gốc 150×150.

4 Tiền xử lý dữ liệu dạng bảng

4.1 Dữ liệu sử dụng

Nhóm sử dụng *Mental Health Survey Dataset* cho phần dữ liệu bảng. Tập dữ liệu được lưu tại `data/raw/mental_health_train.csv` và `data/raw/mental_health_test.csv`. Tập huấn luyện có 140,700 bản ghi, gồm các nhóm thuộc tính nhân khẩu học, học tập/công việc và thói quen sinh hoạt, với nhãn mục tiêu *Depression*. Bộ dữ liệu này thỏa đầy đủ tiêu chí đề bài: quy mô lớn, có đồng thời thuộc tính số và phân loại, và có tỉ lệ thiếu cao ở một số biến.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số records	$\geq$ 10,000	140,700	Đạt
Số thuộc tính	$\geq$ 10	17 features	Đạt
Số + phân loại	Có	8 số + 9 phân loại	Đạt
Tỉ lệ thiếu $\geq$ 5%	Có	80.17% (Academic Pressure)	Đạt

Bảng 5: Kiểm tra tiêu chí lựa chọn dữ liệu bảng

4.2 Phân tích thống kê khám phá (EDA chuyên sâu)

Kiểm tra phân phối. Nhóm áp dụng kiểm định D'Agostino-Pearson cho toàn bộ 8 thuộc tính số (do $n > 5000$). Kết quả cho thấy tất cả biến đều có p-value xấp xỉ 0, tức là không tuân theo phân phối chuẩn. Đồng thời, kurtosis trung bình quanh -1.2 cho thấy dữ liệu có xu hướng gần đều.

Tương quan đa biến. Ma trận tương quan Pearson và Spearman chỉ ra biến *Age* có liên hệ mạnh nhất với nhãn *Depression* với $r = -0.565$ (Pearson) và $\rho = -0.541$ (Spearman). Kết quả này được dùng làm căn cứ ban đầu cho bước chọn đặc trưng ở phần sau.

Phân tích giá trị thiếu. Cấu trúc thiếu dữ liệu thể hiện rõ cơ chế MAR theo nhóm đối tượng: nhóm sinh viên thiếu chủ yếu ở *Work Pressure* và *Job Satisfaction*, trong khi nhóm người đi làm thiếu ở *Academic Pressure*, *CGPA*, và *Study Satisfaction*. Vì vậy, chiến lược điền khuyết được thiết kế theo ngữ cảnh từng nhóm thay vì dùng một quy tắc đồng nhất cho toàn bộ tập.

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Xử lý giá trị thiếu có kiểm soát

Nhóm so sánh 7 chiến lược điền khuyết trên kịch bản tạo thêm 10% thiếu MCAR và đánh giá bằng RMSE. Kết quả trung bình cho thấy **Mean** đạt RMSE tốt nhất (5.78), trong khi **Mode** kém nhất (9.03, cao hơn khoảng 66%). Với bài toán đơn biến, kNN và MICE cho kết quả gần tương đương Mean.

Phát hiện và xử lý ngoại lai

Các phương pháp IQR, Z-score, Isolation Forest, LOF và DBSCAN đều được triển khai và so sánh. Nhóm chọn **Isolation Forest** với contamination = 0.05 làm cấu hình chính vì ổn định trên dữ liệu không chuẩn. Kiểm định KS trước/sau khi loại ngoại lai cho 8 biến đều có $p < 0.05$, cho thấy việc loại ngoại lai làm thay đổi phân phối một cách có ý nghĩa thống kê.

Chuẩn hóa dữ liệu có kiểm định

Nhóm thử Min-Max, Z-score, Robust Scaling và Quantile Transform. Kết quả Levene kết hợp quan sát violin plot cho thấy **Robust Scaling** là lựa chọn cân bằng nhất: giảm ảnh hưởng ngoại lai nhưng vẫn giữ cấu trúc phân phối tốt hơn Quantile Transform.

Mã hóa biến phân loại nâng cao

Ngoài One-Hot và Ordinal, nhóm triển khai thêm Target Encoding (K-fold), Binary Encoding và Frequency Encoding. Đánh giá bằng VIF cho thấy **Binary Encoding** tốt nhất (mean VIF = 4.21), trong khi **Frequency Encoding** gây đa cộng tuyến rất cao (mean VIF = 889.59).

Lựa chọn và giảm chiều đặc trưng

Nhóm đánh giá MI, RF importance, RFE và PCA bằng F1-score cross-validation 5-fold. Ở mức $k = 10$, RF đạt F1 = 0.809 (cao hơn MI với F1 = 0.784). Khi $k \geq 15$, hiệu năng bão hòa quanh F1 ≈ 0.813, cho thấy số đặc trưng hữu ích thực tế không cần quá lớn.

Xử lý mất cân bằng lớp

Trên tập test giữ nguyên phân phối gốc, **SMOTE** đạt F1-macro cao nhất (0.883), nhỉnh hơn baseline (0.882) và ADASYN (0.874). Baseline vẫn có AUC-ROC cao (0.969), nhưng SMOTE cho cân bằng Precision–Recall tốt hơn cho bài toán phát hiện lớp thiểu số.

Kỹ thuật	**Phương pháp tốt nhất**	**Kém nhất**	**Chỉ số chính**
Điền khuyết	Mean	Mode	RMSE: 5.78 vs 9.03
Ngoại lai	IsoForest (0.05)	—	KS: tất cả biến $p < 0.05$
Chuẩn hóa	Robust Scaling	Quantile (uniform)	Levene + violin plot
Mã hóa	Binary Encoding	Frequency Encoding	VIF: 4.21 vs 889.59
Chọn đặc trưng	RF importance ($k = 10$)	MI ($k = 5$)	F1: 0.809 vs 0.713
Cân bằng lớp	SMOTE	Random Under-sampling	F1-macro: 0.883 vs 0.866

Bảng 6: Tổng hợp kết quả định lượng cho phần dữ liệu bảng

4.4 Kết luận cho pipeline dữ liệu bảng

Từ các kết quả trên, pipeline đề xuất cho dữ liệu bảng gồm: điền khuyết theo ngữ cảnh dữ liệu, phát hiện ngoại lai bằng Isolation Forest (0.05), chuẩn hóa bằng Robust Scaling, mã hóa ưu tiên Binary cho biến nhiều mức, chọn đặc trưng theo RF importance/RFE, và cân bằng lớp bằng SMOTE khi huấn luyện.

5 Tiền xử lý dữ liệu chuỗi thời gian

5.1 Dữ liệu sử dụng

Nhóm sử dụng bộ dữ liệu tiêu thụ điện Tây Ban Nha (*Spain Energy Consumption Dataset*) cho phần chuỗi thời gian.

Tập dữ liệu có 35.064 quan sát theo tần suất giờ trong giai đoạn 2015–2019. Biến mục tiêu chính là tải điện (MW), đồng thời có các biến hỗ trợ theo ngữ cảnh thời gian để phục vụ bước nội suy, kiểm định tính dừng, trích xuất đặc trưng và dự báo một bước trước.

Bộ dữ liệu này phù hợp với yêu cầu đề bài ở ba điểm:

- Đủ chiều dài chuỗi theo nhiều năm.
- Có tính mùa vụ theo ngày và theo tuần.

- Có ý nghĩa thực tiễn rõ ràng cho bài toán tiền xử lý phục vụ dự báo.

5.2 Phân tích khám phá chuỗi thời gian

Nhóm tập trung vào 4 câu hỏi chính:

- Chuỗi có xu hướng dài hạn hay không?
- Mùa vụ xuất hiện ở các chu kỳ nào?
- Mức dao động thay đổi ra sao theo thời gian?
- Chuỗi có thỏa điều kiện dừng để mô hình hóa trực tiếp hay không?

Kết quả chính từ notebook EDA thời gian cho thấy:

- Biến *total load actual* chỉ thiếu 36 điểm trên toàn bộ chuỗi (xấp xỉ 0.1%), nên không làm méo cấu trúc tín hiệu tổng thể ở bước khám phá.
- Time plot toàn giai đoạn cho thấy không có xu hướng tăng/giảm tuyến tính dài hạn rõ rệt, nhưng xuất hiện mùa vụ mạnh theo năm; khi phóng to theo tuần, chu kỳ ngày và khác biệt giữa ngày làm việc–cuối tuần thể hiện rõ.
- ACF/PACF xác nhận tự tương quan mạnh ở các độ trễ ngắn và tại các bội số của 24 giờ, đồng thời xuất hiện dấu hiệu mùa vụ tuần (168 giờ).
- Rolling mean và rolling std (cửa sổ 7/30/90 ngày) đều biến thiên theo thời gian, cho thấy chuỗi chưa dừng và cần biến đổi ở bước tiền xử lý tiếp theo.

5.2.1 Time Plot

Time plot toàn giai đoạn 2015–2019 cho thấy chuỗi tải điện dao động quanh một mức trung bình tương đối ổn định, chưa ghi nhận xu hướng tuyến tính tăng/giảm dài hạn rõ rệt (Hình 1). Tuy nhiên, đường bao chuỗi lặp lại theo các nhịp lớn theo năm, phản ánh tác động mùa vụ vĩ mô (thời tiết và nhu cầu tiêu thụ theo mùa).

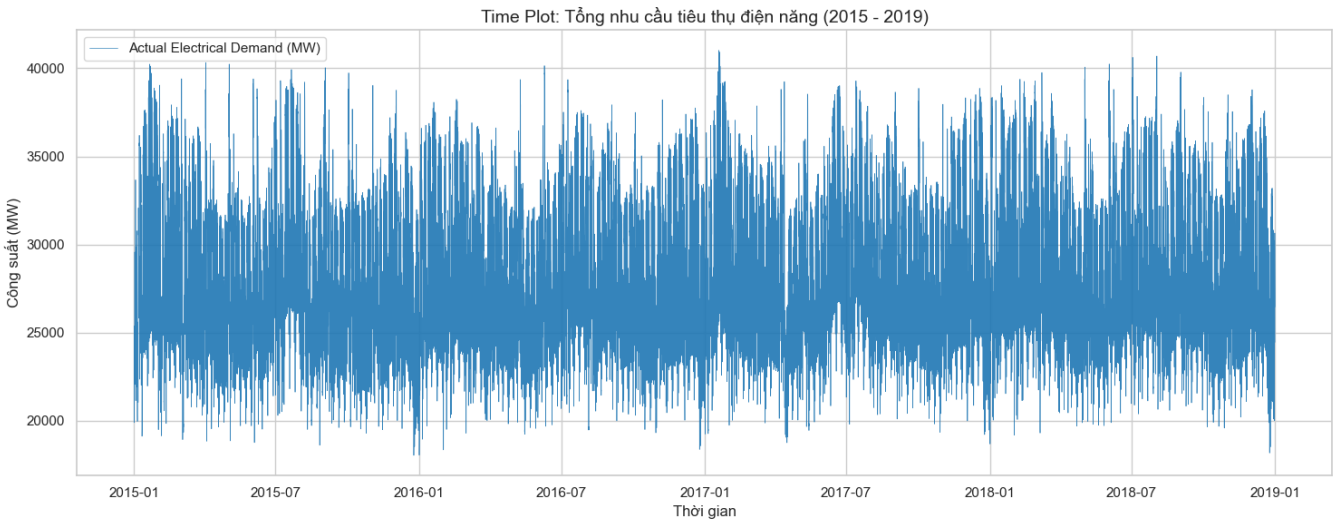

Hình 1: Time plot toàn giai đoạn 2015–2019 cho biến *total load actual*.

Khi phóng to về tuần đầu năm 2015, cấu trúc chu kỳ ngắn hạn hiện rõ hơn:

- Chu kỳ ngày (24 giờ): phụ tải giảm vào rạng sáng và tăng lên vào các khung giờ hoạt động cao trong ngày.
- Chu kỳ tuần: biên độ tải ở ngày làm việc cao hơn đáng kể so với cuối tuần.
- Hiệu ứng ngày lễ: các ngày lễ đầu năm tạo ra các điểm sụt phụ tải bất thường, khác với dao động tuần thông thường.

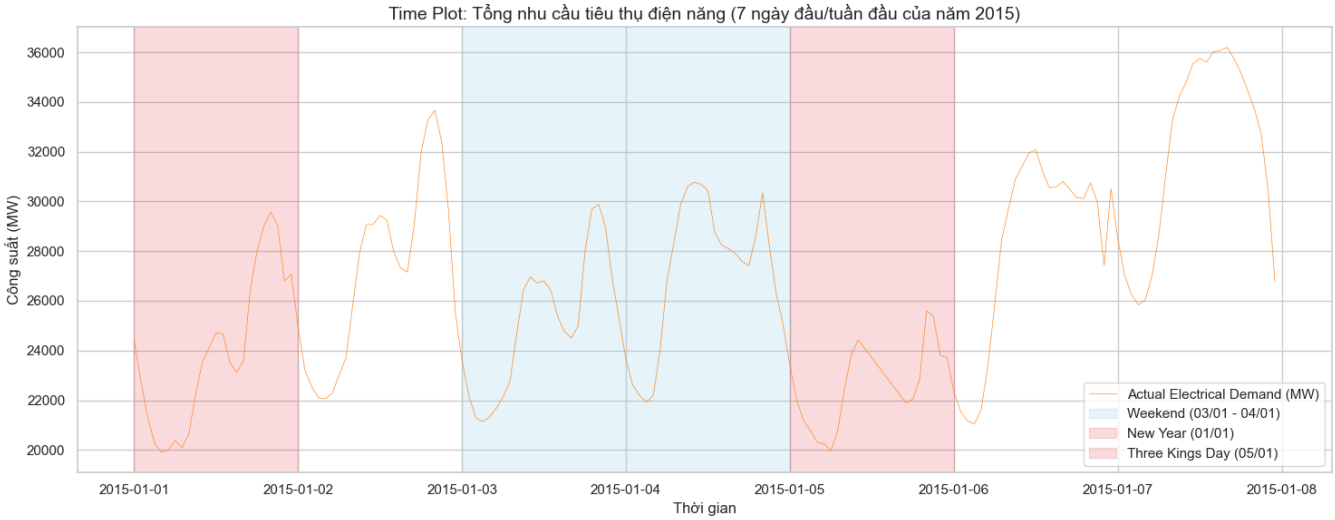

Hình 2: Time plot tuần đầu năm 2015 cho biến *total load actual*.

Phân tích time-plot cho ta thấy các thành phần cấu trúc của chuỗi có đặc điểm:

1. **Xu hướng (Trend)**: không rõ ràng, có thể coi là gần như không tồn tại trong giai đoạn này.

2. **Mùa vụ (Seasonality)**: rất rõ ràng ở cả chu kỳ ngày và tuần, với biên độ thay đổi theo mùa trong năm.

3. **Nhiễu và Hiệu ứng ngày lễ (Noise & Holiday Effects)**: có dao động ngắn hạn và một số điểm bất thường (outliers) liên quan đến ngày lễ.

4. **Tính dừng (Stationarity)**: mặc dù phương sai tương đối đồng đều và không có xu hướng dài hạn, nhưng sẽ có những tính mùa vụ lồng ghép phức tạp khiến mean của chuỗi thay đổi liên tục theo thời gian. Do đó, có thể nói đây là chuỗi không dừng (non-stationary)

5.2.2 Phân tích tương quan ACF và PACF

Theo công thức thực nghiệm $\min(10\log_{10} n, n/5)$, số lag tối đa ban đầu xấp xỉ 45 (Hình 3). Tuy nhiên, do dữ liệu có tần suất giờ, nhóm mở rộng phân tích đến 168 lag để kiểm tra đầy đủ chu kỳ ngày (24 giờ) và tuần (168 giờ) (Hình 4).

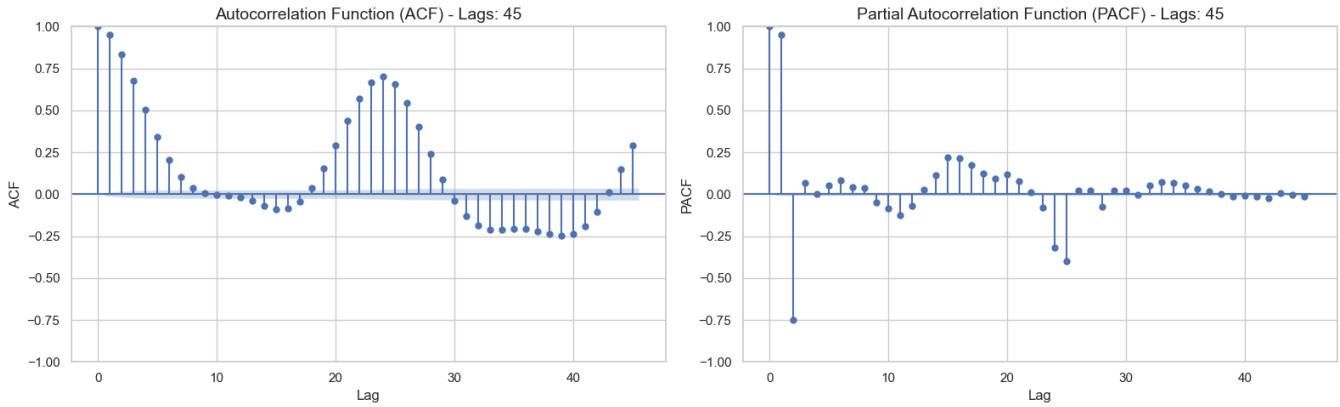

Hình 3: ACF và PACF cho biến *total load actual* với lag tối đa 45.

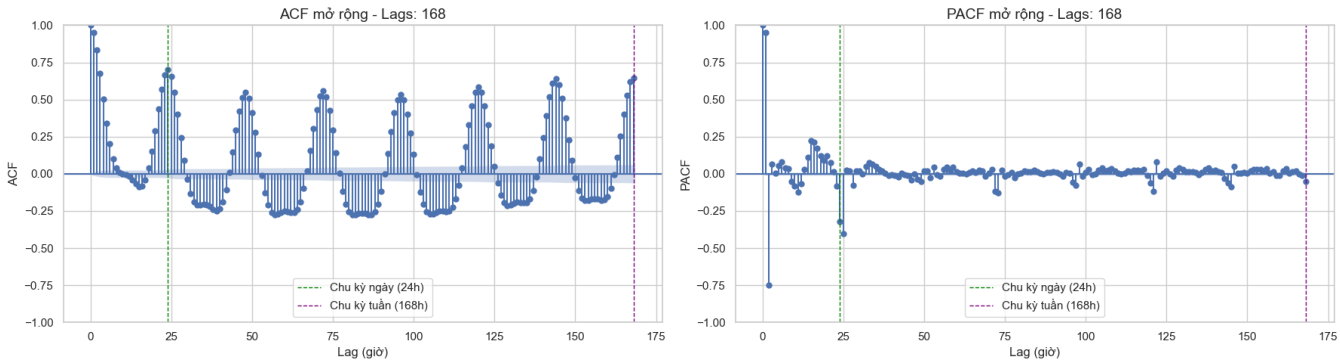

Hình 4: ACF và PACF mở rộng đến lag 168 để kiểm tra mùa vụ ngày và tuần.

Kết quả **ACF** cho thấy hệ số tự tương quan suy giảm chậm và duy trì ý nghĩa ở nhiều lag xa, hàm ý chuỗi có tính nhớ dài và chưa dừng. Đồng thời, các đỉnh lặp lại tại các bội số của 24 giờ củng cố bằng chứng về mùa vụ ngày; đỉnh tại vùng 168 giờ cho thấy mùa vụ tuần cũng hiện diện rõ.

Ở **PACF**, các gai (spikes) lớn tập trung tại các lag đầu (đặc biệt lag 1 và 2), sau đó giảm nhanh, cho thấy ảnh hưởng trực tiếp chủ yếu đến từ lịch sử rất gần. Ngoài ra, sự xuất hiện gai đáng chú ý quanh lag 24 phản ánh tác động mùa vụ ngày lên quan sát hiện tại.

Căn cứ vào PACF, khi xây dựng ma trận đặc trưng cho dự báo, ta cần bắt buộc tạo các biến trễ (lag features) ngắn hạn quan trọng lag $t-1, t-2$ và các lag có giá trị tương quan âm mạnh tại $t-3$ và đặc biệt là $t-24$ để nắm bắt được ảnh hưởng của chu kỳ ngày.

5.2.3 Rolling statistics

Rolling mean và rolling standard deviation được tính trên ba cửa sổ 168, 720 và 2160 giờ (tương ứng 7, 30 và 90 ngày) để đánh giá sự ổn định của kỳ vọng và phương sai theo thời gian.

Quan sát trên rolling mean cho thấy khi tăng kích thước cửa sổ, nhiễu ngắn hạn được làm phẳng nhưng đường trung bình vẫn dao động có chu kỳ thay vì hội tụ về hằng số. Ở cửa sổ dài (90 ngày), đường trung bình thể hiện rõ các nhịp lên xuống vĩ mô theo mùa.

Với rolling std, độ biến thiên cũng thay đổi theo thời gian: ở cửa sổ ngắn dao động mạnh, còn ở cửa sổ dài vẫn duy trì dạng dao động có cấu trúc. Điều này cho thấy phương sai của chuỗi không ổn định theo nghĩa thống kê.

Như vậy, cả hai điều kiện dừng quan trọng (mean và variance bất biến theo thời gian) đều bị vi phạm. Đây là cơ sở để áp dụng bước ổn định phương sai (log/Box-Cox) kết hợp sai phân hoặc decomposition ở các bước tiền xử lý kế tiếp.

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Pipeline tiền xử lý cho dữ liệu chuỗi thời gian được tổ chức theo thứ tự: xử lý giá trị thiếu theo mốc thời gian, kiểm định tính dừng và biến đổi, phân rã cấu trúc chuỗi, phát hiện dị thường, xây dựng ma trận đặc trưng, rồi đánh giá bằng bài toán dự báo một bước trước $(t + 1)$. Kết quả chi tiết từng bước được dùng để chọn cấu hình tiền xử lý tối ưu theo cả tiêu chí thống kê và hiệu năng dự báo.

5.3.1 Xử lý khoảng trống thời gian và nội suy

Nhóm chủ động loại bỏ ngẫu nhiên 5% dữ liệu theo cơ chế MCAR để so sánh 5 phương pháp: Forward Fill, Linear, Polynomial bậc 2, Polynomial bậc 3 và Spline Cubic. Sai số được đánh giá trên đúng các vị trí bị che bằng MAE và RMSE; đồng thời kiểm định Ljung-Box được dùng để kiểm tra cấu trúc phần dư sau nội suy Ljung and Box, 1978; statsmodels developers, 2025a.
Kết quả cho thấy:

- **Forward Fill** kém nhất (MAE xấp xỉ 1160, RMSE xấp xỉ 1604), do không theo kịp độ cong tự nhiên của phụ tải theo giờ.
- **Linear** cải thiện đáng kể (MAE xấp xỉ 427) nhưng vẫn chưa nắm bắt tốt phi tuyến cục bộ.
- Nhóm phương pháp phi tuyến vượt trội; **Polynomial bậc 2** tốt nhất với MAE xấp xỉ 276.23 và RMSE xấp xỉ 508.74.
- Với cả 5 phương pháp, p-value Ljung-Box đều lớn hơn 0.05 (khoảng 0.4889–0.9014), nghĩa là phần dư không còn tự tương quan có ý nghĩa thống kê.

Phân phối phần dư của phương pháp tốt nhất (Polynomial bậc 2) được thể hiện tại Hình 5.

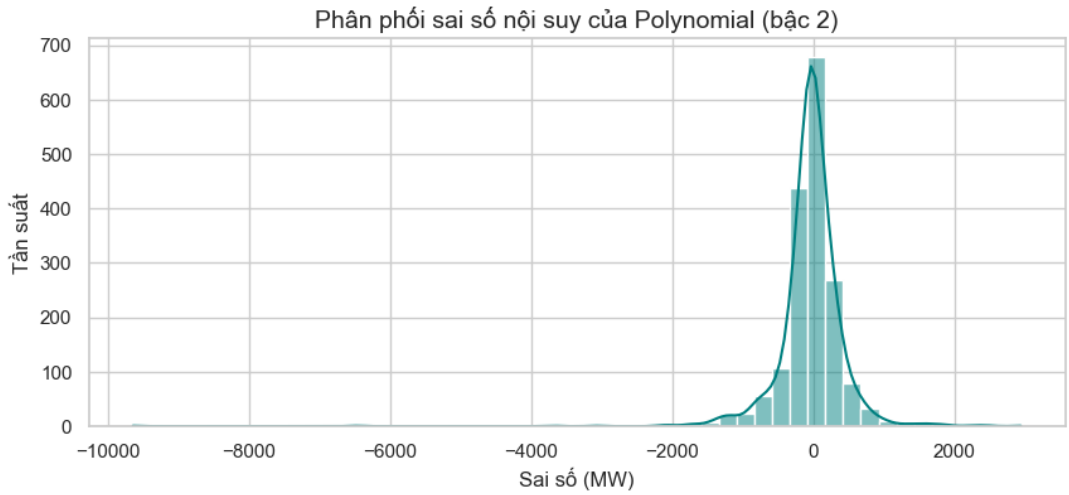

Hình 5: Phân phối phần dư của phương pháp nội suy Polynomial bậc 2 tại các điểm thiếu MCAR 5%.

Từ đó, nhóm chọn **Polynomial bậc 2** làm cấu hình nội suy chính cho pipeline làm sạch dữ liệu lịch sử.

5.3.2 Kiểm định tính dừng và biến đổi chuỗi

Nhóm áp dụng ba kiểm định ADF, KPSS và Phillips-Perron (PP) đồng thời trên chuỗi gốc và các phiên bản biến đổi Dickey and Fuller, 1979; Kwiatkowski et al., 1992; Phillips and Perron, 1988; statsmodels developers, 2025c, 2025d.

Các kết quả chính:

- Chuỗi gốc chưa dừng; KPSS cho p-value chạm ngưỡng dưới 0.0100.
- Biến đổi Logarithm đơn thuần chưa đủ; KPSS vẫn ở mức 0.0100.
- Box-Cox tự chọn tham số $\lambda \approx 0.6341$, sau đó sai phân bậc 1 giúp chuỗi đạt dừng: KPSS chạm ngưỡng trên 0.1000, trong khi ADF và PP cho p-value rất nhỏ Box and Cox, 1964; SciPy Community, 2025.
- Sai phân bậc 2 không cần thiết vì có nguy cơ over-differencing và làm mất tín hiệu hữu ích.

Vì vậy, biến đổi được chốt cho bước sau là **Box-Cox + sai phân bậc 1**.

5.3.3 Phân rã chuỗi thời gian

Nhóm so sánh Additive, Multiplicative và STL với chu kỳ tuần 168 giờ (phù hợp dữ liệu theo giờ). Chỉ số đánh giá là tỉ lệ phương sai phần dư Cleveland et al., 1990; statsmodels developers, 2025b:

$$\mathrm{RVR} = \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(y_t)}.$$

Kết quả:

- Additive: RVR = 0.7200 (khả năng bóc tách cấu trúc thấp).
- Multiplicative: RVR = 0.0000 (kết quả không đáng tin cậy về mặt thực tiễn, có dấu hiệu artifact).
- STL: RVR = 0.3319 (hợp lý và tốt nhất trong ba phương pháp).

Cấu trúc các thành phần sau phân rã được minh họa tại Hình 6.

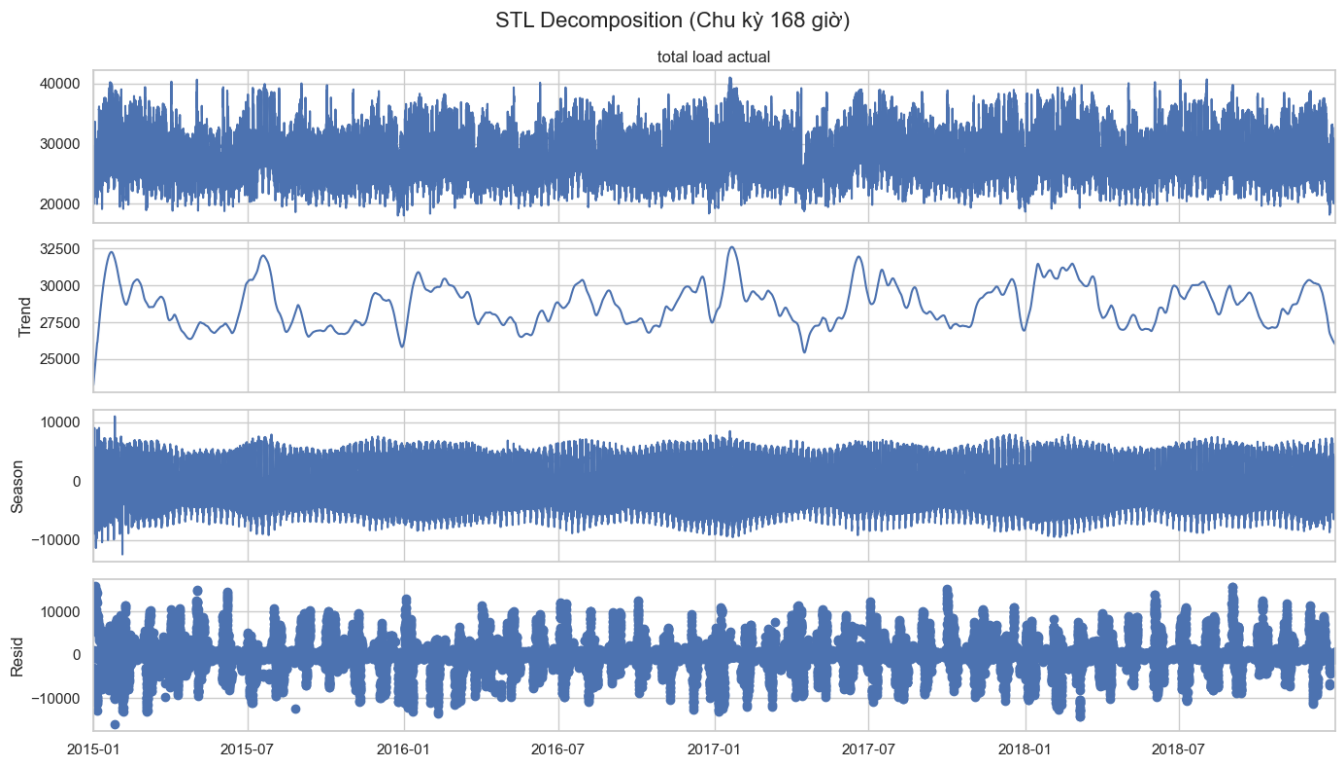

Hình 6: Kết quả STL decomposition với chu kỳ tuần 168 giờ trên chuỗi đã làm sạch.

Theo đó, nhóm sử dụng **STL decomposition** để lấy các chuỗi dẫn xuất: `stl_trend`, `stl_seasonal`, `stl_resid`, `deseasonalized`, `detrend` cho các bước tiếp theo.

5.4 Feature Engineering & Phát hiện dị thường

5.4.1 Phát hiện dị thường

Trên dữ liệu đã làm sạch, nhóm triển khai ba hướng: Z-score trên chuỗi deseasonalized, Isolation Forest trên đặc trưng rolling 24h, và ngưỡng 3σ trên phần dư STL.
Số lượng điểm dị thường phát hiện được:

- Z-score: 662 điểm.
- Isolation Forest (contamination = 0.01): 350 điểm.
- STL Residual Thresholding: 1055 điểm.

Phân bố điểm dị thường theo từng phương pháp được minh họa tại Hình 7.

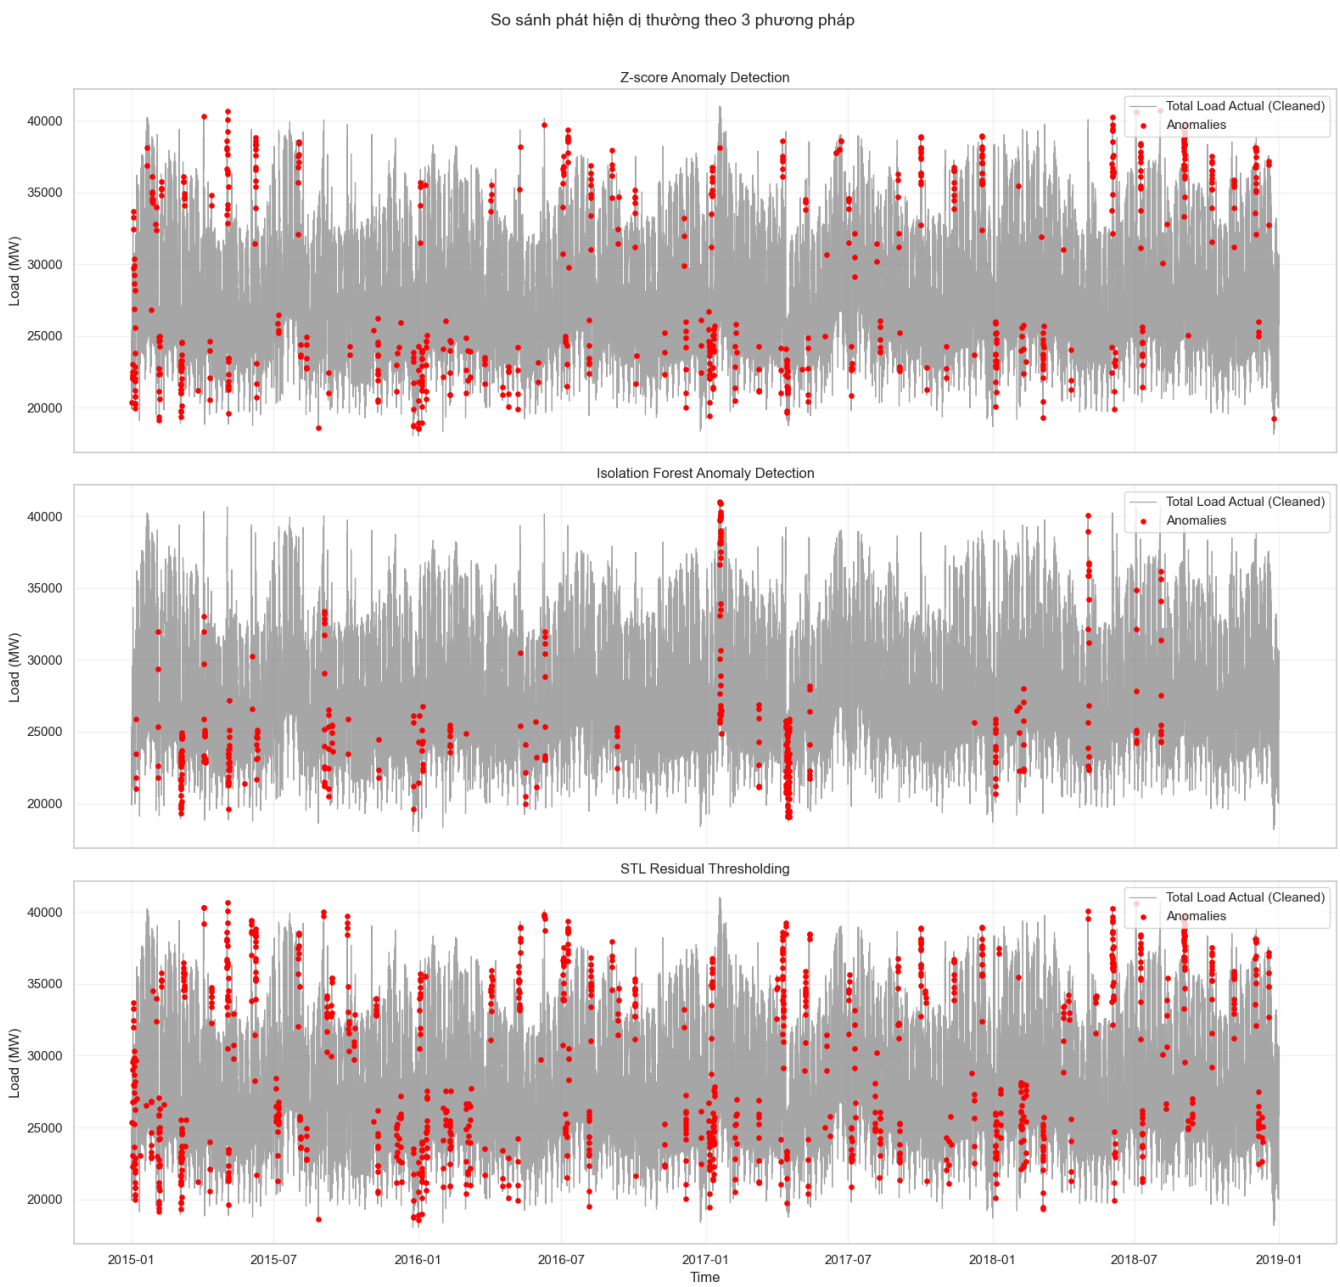

Hình 7: So sánh các điểm dị thường được phát hiện bởi Z-score, Isolation Forest và ngưỡng phần dư STL.

STL Residual Thresholding nhạy nhất với các cú sốc ngoại sinh (ngày lễ, thời tiết cực đoan) và được chọn làm lớp phát hiện dị thường chính để phục vụ phân tích rủi ro.

5.4.2 Xây dựng ma trận đặc trưng thời gian

Từ dữ liệu sau tiền xử lý, nhóm xây dựng bộ đặc trưng cho dự báo $t + 1$ gồm:

- **Lag features:** $t-1, t-2, t-3, t-24$ (theo PACF).
- **Rolling features:** mean/std/min/max tại các cửa sổ 6h, 24h, 168h.
- **Cyclic encoding:** sin/cos cho giờ trong ngày, thứ trong tuần, tháng trong năm.
- **Calendar feature:** cờ ngày lễ Tây Ban Nha.
- **Decomposition-based features:** thành phần trend/seasonal từ STL.
- **Stationary feature:** chuỗi sai phân bậc 1 sau Box-Cox.

Việc kết hợp các lớp đặc trưng này giúp mô hình đồng thời học được động học ngắn hạn, cấu trúc chu kỳ và biến thiên theo bối cảnh lịch.

5.5 Đánh giá pipeline

5.5.1 Đánh giá pipeline bằng dự báo một bước

Để kiểm định chất lượng toàn bộ pipeline, nhóm huấn luyện Random Forest Regressor trên dạng supervised $t+1$, chia tập theo thời gian (năm cuối làm test) Breiman, 2001; scikit-learn developers, 2026.

Kết quả trên tập test:

- MAE = 304.15 MW.
- RMSE = 505.03 MW.

Với mức phụ tải trung bình khoảng 28,700 MW, sai số MAE vào khoảng 1%, cho thấy pipeline tiền xử lý tạo ra không gian đặc trưng đủ tốt để mô hình nền đạt hiệu năng dự báo cao.

Phân tích feature importance cũng nhất quán với EDA trước đó:

- `load` chi phối mạnh nhất (xấp xỉ 89.51%).
- `diff_1` đứng thứ hai (xấp xỉ 5.04%).
- Cặp `hour_cos`, `hour_sin` xác nhận vai trò chu kỳ ngày.

Top đặc trưng quan trọng nhất của mô hình được thể hiện tại Hình 8.

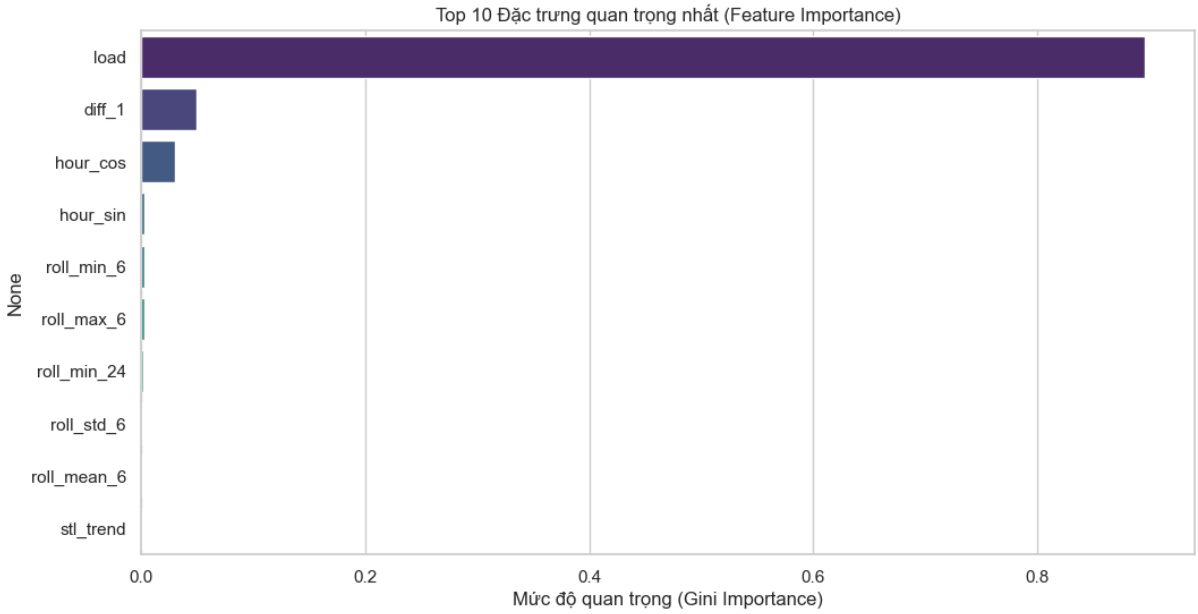

Hình 8: Top 10 đặc trưng quan trọng nhất của mô hình Random Forest cho bài toán dự báo $t + 1$.

5.5.2 Phân tích nhân quả Granger đa biến

Nhóm kiểm định Granger ở lag 3 trên các chuỗi đã được chuẩn hóa tính dừng (bao gồm `ts_diff` cho tải và sai phân bậc 1 cho các biến ngoại sinh) Granger, 1969.

Các quan hệ nổi bật theo F-statistic:

- load → solar: 947.4.
- load → price: 872.0.
- price → load: 670.3.
- solar → load: 633.9.
- load → gas: 544.6.

Nhóm biến gió có F-stat thấp hơn đáng kể, cho thấy tính độc lập cao hơn so với các biến còn lại. Kết quả này củng cố luận điểm rằng tải tiêu thụ và giá điện có cơ chế dẫn dắt hai chiều theo thời gian, và các nguồn phát linh hoạt như khí đóng vai trò cân bằng hệ thống.

Ma trận độ mạnh nhân quả Granger giữa các biến được trình bày tại Hình 9.

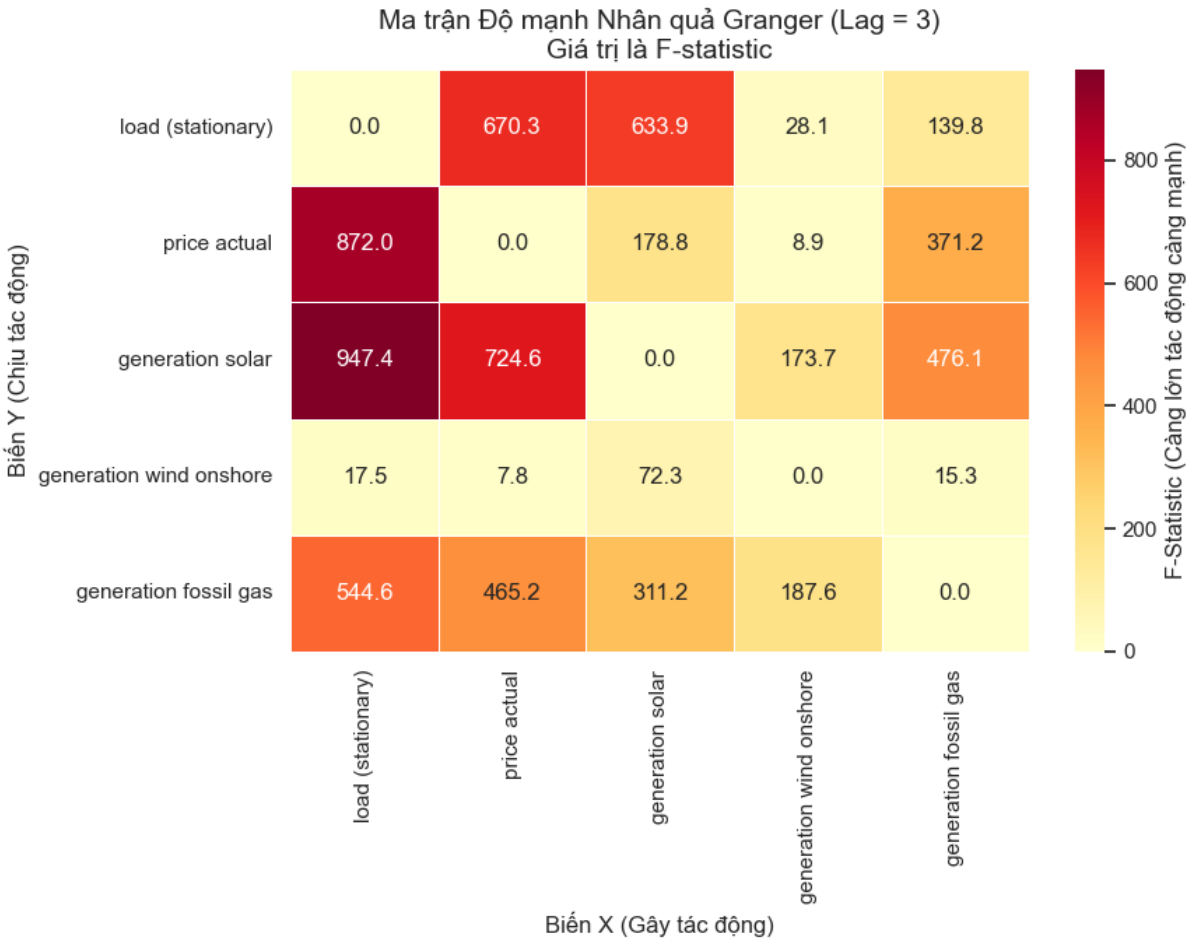

Hình 9: Ma trận độ mạnh nhân quả Granger (F-statistic) với lag 3 trên dữ liệu đã chuẩn hóa tính dừng.

Bảng 7 tổng hợp các kết quả định lượng chính cho từng bước trong pipeline tiền xử lý chuỗi thời gian, cung cấp cái nhìn tổng quan về hiệu quả của từng kỹ thuật đã triển khai.

Bước	**Lựa chọn**	**Kết quả chính**
Nội suy thiếu	Polynomial bậc 2	MAE $\approx$ 276.23, RMSE $\approx$ 508.74; Ljung-Box p-value $>$ 0.05
Ổn định chuỗi	Box-Cox + sai phân bậc 1	$\lambda \approx 0.6341$; KPSS từ 0.0100 lên 0.1000
Phân rã	STL (period = 168)	RVR thấp nhất hợp lý: 0.3319
Dị thường	STL residual thresholding	Phát hiện 1055 điểm bất thường
Dự báo $t+1$	Random Forest (baseline)	MAE = 304.15 MW; RMSE = 505.03 MW
Granger	Lag 3, dữ liệu dừng đa biến	Quan hệ mạnh giữa load, price, solar, gas

Bảng 7: Tổng hợp kết quả định lượng cho pipeline tiền xử lý chuỗi thời gian

5.6 Kết luận

Từ toàn bộ ba notebook temporal, nhóm đã xây dựng một pipeline tiền xử lý hoàn chỉnh cho dữ liệu chuỗi thời gian gồm các bước:

1. Chuẩn hóa trục thời gian theo giờ.
2. Điền thiếu bằng Polynomial bậc 2.
3. Ổn định chuỗi bằng Box-Cox + sai phân bậc 1.
4. Phân rã STL theo chu kỳ 168 giờ.
5. Phát hiện dị thường dựa trên phần dư STL.
6. Xây dựng đặc trưng lag–rolling–cyclic–calendar.
7. Đánh giá bằng dự báo một bước trước $(t+1)$.

Kết quả định lượng cho thấy pipeline này vừa đảm bảo tính đúng đắn thống kê (chuỗi đạt dừng sau biến đổi, phân rã tách được cấu trúc rõ ràng), vừa cho hiệu năng dự báo tốt trên dữ liệu thực tế với bài toán một bước trước (MAE 304.15 MW, RMSE 505.03 MW).

6 Kết luận

Tài liệu

Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, *26*(2), 211–252. https://doi.org/10.1111/j.2517-6161.1964.tb00553.x

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). Stl: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, *6*(1), 3–73.

Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, *74*(366a), 427–431. https://doi.org/10.1080/01621459.1979.10482531

Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, *37*(3), 424–438. https://doi.org/10.2307/1912791

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, *54*(1–3), 159–178. https://doi.org/10.1016/0304-4076(92)90104-Y

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, *65*(2), 297–303. https://doi.org/10.1093/biomet/65.2.297

Phillips, P. C. B., & Perron, P. (1988). Testing for a unit root in time series regression. *Biometrika*, *75*(2), 335–346. https://doi.org/10.1093/biomet/75.2.335

scikit-learn developers. (2026). *Sklearn.ensemble.randomforestregressor*. Retrieved April 18, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

SciPy Community. (2025). *Scipy.stats.boxcox*. Retrieved April 18, 2026, from https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.boxcox.html

statsmodels developers. (2025a). *Statsmodels.stats.diagnostic.acorr_ljungbox*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.acorr_ljungbox.html

statsmodels developers. (2025b). *Statsmodels.tsa.seasonal.stl*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.STL.html

statsmodels developers. (2025c). *Statsmodels.tsa.stattools.adfuller*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.adfuller.html

statsmodels developers. (2025d). *Statsmodels.tsa.stattools.kpss*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.kpss.html