ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Đồ án 1

Đề tài: Tiền xử lý dữ liệu

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

22120457 - Khưu Hải Châu

23122006 - Lưu Thượng Hồng

23122020 - Nguyễn Thiên Ấn

23122034 - Lê Nguyên Khang

23122036 - Nguyễn Ngọc Khoa

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhựt Nam

Ngày 18 tháng 4 năm 2026

Mục lục

1 Giới thiệu **1**

2 Phân công công việc **1**

3 Tiền xử lý dữ liệu ảnh **1**

3.1 Dữ liệu sử dụng 1

3.2 Phân tích khám phá và chất lượng dữ liệu 1

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 2

3.4 Kết luận cho pipeline dữ liệu ảnh 2

4 Tiền xử lý dữ liệu dạng bảng **3**

4.1 Dữ liệu sử dụng 3

4.2 Phân tích khám phá dữ liệu dạng bảng 3

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 4

4.3.1 Xử lý giá trị thiếu có kiểm soát 4

4.3.2 Phát hiện và xử lý ngoại lai 5

4.3.3 Chuẩn hóa dữ liệu có kiểm định 7

4.3.4 Mã hóa biến phân loại nâng cao 8

4.3.5 Lựa chọn và giảm chiều đặc trưng 8

4.3.6 Xử lý mất cân bằng lớp 10

4.4 Đánh giá pipeline 12

4.4.1 Tổng hợp cấu hình tốt nhất 12

4.4.2 Tạo dataset tiền xử lý cuối 13

4.5 Kết luận 13

5 Tiền xử lý dữ liệu chuỗi thời gian **14**

5.1 Dữ liệu sử dụng 14

5.2 Phân tích khám phá chuỗi thời gian 14

5.2.1 Time Plot 15

5.2.2 Phân tích tương quan ACF và PACF 16

5.2.3 Rolling statistics 17

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 18
5.3.1 Xử lý khoảng trống thời gian và nội suy 18
5.3.2 Kiểm định tính dừng (Stationarity Tests) 19
5.3.3 Phân rã chuỗi thời gian 20
5.3.4 Feature Engineering & Phát hiện dị thường 21
5.4 Đánh giá pipeline 25
5.4.1 Đánh giá pipeline bằng dự báo một bước 25
5.4.2 Phân tích nhân quả Granger đa biến 26
5.5 Kết luận 28

6 Kết luận **29**

Tài liệu **30**

1 Giới thiệu

Báo cáo này trình bày quá trình tiền xử lý dữ liệu cho ba nhóm bài toán của đồ án: **dữ liệu ảnh**, **dữ liệu bảng** và **dữ liệu chuỗi thời gian**. Trọng tâm của nhóm là triển khai các kỹ thuật theo đề bài, đo lường định lượng tác động của từng bước, thảo luận và đưa ra lựa chọn cuối cùng dựa trên bằng chứng thực nghiệm.

2 Phân công công việc

MSSV	Họ và tên	Công việc
22120457	Khưu Hải Châu	Phân tích dữ liệu ảnh
23122006	Lưu Thượng Hồng	Viết báo cáo
23122020	Nguyễn Thiên Ấn	Viết báo cáo
23122034	Lê Nguyên Khang	Phân tích dữ liệu dạng bảng
23122036	Nguyễn Ngọc Khoa	Phân tích dữ liệu chuỗi thời gian

Bảng 1: Phân công công việc của nhóm

3 Tiền xử lý dữ liệu ảnh

3.1 Dữ liệu sử dụng

Nhóm sử dụng tập ảnh phong cảnh gồm 6 lớp: *buildings, forest, glacier, mountain, sea, street.* Tập dữ liệu gốc có 5,000 ảnh RGB kích thước 150×150, tương ứng nhãn dạng số với 6 lớp.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số ảnh	$\geq$ 5,000	5,000	Đạt
Kích thước ảnh	Đồng nhất	150×150×3	Đạt
Số lớp	$\geq$ 5	6 lớp	Đạt

Bảng 2: Kiểm tra tiêu chí lựa chọn dữ liệu ảnh

3.2 Phân tích khám phá và chất lượng dữ liệu

Phân bố lớp. Tập dữ liệu có phân bố khá đều giữa các lớp. Số ảnh theo lớp lần lượt là: buildings (789), forest (778), glacier (863), mountain (870), sea (814), street (886). Tỉ lệ lớp lớn nhất/lớp nhỏ nhất là 1.14, nhỏ hơn ngưỡng 3, do đó dữ liệu được xem là cân bằng.

Phát hiện ảnh trùng. Nhóm dùng perceptual hash (pHash) để dò ảnh trùng hoặc gần trùng. Kết quả phát hiện 7 ảnh trùng trên 5,000 ảnh (0.14%). Sau khi loại trùng, tập dữ liệu còn 4,993 ảnh.

Độ sáng và tương phản toàn cục. Trên tập đã loại trùng, thống kê mức sáng và độ tương phản cho thấy biên độ biến thiên lớn, phù hợp với đặc thù dữ liệu cảnh ngoài trời.

Thuộc tính	**Độ lệch chuẩn**	**Nhỏ nhất**	**Lớn nhất**
Độ sáng toàn cục	30.8812	18.6553	210.4190
Độ tương phản	13.1707	13.6147	104.6476

Bảng 3: Thống kê độ sáng và độ tương phản trên 4,993 ảnh

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Ablation theo kích thước ảnh. Nhóm đánh giá pipeline cổ điển *flatten + PCA-100 + Logistic Regression / k-NN* bằng 5-fold CV trên mẫu con 2,500 ảnh để chọn kích thước resize phù hợp.

Cấu hình	**LogReg (mean ± std)**	**k-NN (mean ± std)**
Baseline 150×150	0.4924 ± 0.0195	0.4640 ± 0.0194
Resize 32×32	0.4836 ± 0.0205	0.4676 ± 0.0165
Resize 64×64	**0.4936 ± 0.0177**	**0.4672 ± 0.0186**
Resize 128×128	0.4884 ± 0.0162	0.4648 ± 0.0207

Bảng 4: So sánh ablation theo kích thước ảnh (n=2,500, PCA-100, 5-fold CV)

Dựa trên kết quả trên, nhóm chọn kích thước 64×64 cho các bước xử lý và mô hình hóa tiếp theo vì cho hiệu năng tổng thể tốt nhất trong các cấu hình thử nghiệm.

3.4 Kết luận cho pipeline dữ liệu ảnh

Pipeline đề xuất cho dữ liệu ảnh gồm: (i) loại ảnh trùng bằng pHash, (ii) resize ảnh về 64×64, (iii) chuẩn bị đặc trưng phù hợp mô hình (ví dụ flatten + PCA cho mô hình cổ điển). Quy trình này giữ được cân bằng lớp, giảm nhiễu dữ liệu trùng và tối ưu chi phí tính toán so với dùng ảnh gốc 150×150.

4 Tiền xử lý dữ liệu dạng bảng

4.1 Dữ liệu sử dụng

Nhóm sử dụng *Mental Health Survey Dataset* cho phần dữ liệu bảng. Tập huấn luyện có 140.700 bản ghi, gồm các nhóm thuộc tính nhân khẩu học, học tập/công việc và thói quen sinh hoạt, với nhãn mục tiêu *Depression*. Bộ dữ liệu này thỏa đầy đủ tiêu chí đề bài: quy mô lớn, có đồng thời thuộc tính số và phân loại, và có tỉ lệ thiếu cao ở một số biến.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số records	$\geq$ 10,000	140,700	Đạt
Số thuộc tính	$\geq$ 10	17 features	Đạt
Số + phân loại	Có	8 số + 9 phân loại	Đạt
Tỉ lệ thiếu $\geq$ 5%	Có	80.17% (Academic Pressure)	Đạt

Bảng 5: Kiểm tra tiêu chí lựa chọn dữ liệu bảng

4.2 Phân tích khám phá dữ liệu dạng bảng

Phần EDA thống kê của dữ liệu bảng trả lời 3 câu hỏi chính:

- Dữ liệu có theo phân phối chuẩn để dùng các giả định thống kê cổ điển hay không?
- Tín hiệu dự báo chính cho nhãn *Depression* nằm ở nhóm biến nào?
- Giá trị thiếu xuất hiện ngẫu nhiên hay phụ thuộc theo nhóm đối tượng?

Kiểm tra phân phối. Nhóm áp dụng kiểm định D'Agostino-Pearson cho toàn bộ 8 thuộc tính số (do $n > 5000$) (D'Agostino and Pearson, 1973; SciPy Community, 2025b). Kết quả cho thấy tất cả biến đều có p-value rất nhỏ (xấp xỉ 0), tức là không tuân theo phân phối chuẩn. Đồng thời, kurtosis trung bình quanh -1.2 cho thấy nhiều biến có xu hướng gần phân phối đều.

Tương quan đa biến. Ma trận tương quan Pearson và Spearman cho thấy biến *Age* có liên hệ mạnh nhất với nhãn *Depression*: $r = -0.565$ (Pearson) và $\rho = -0.541$ (Spearman). Kết quả này được dùng làm căn cứ ban đầu cho bước chọn đặc trưng. Xem Hình 1.

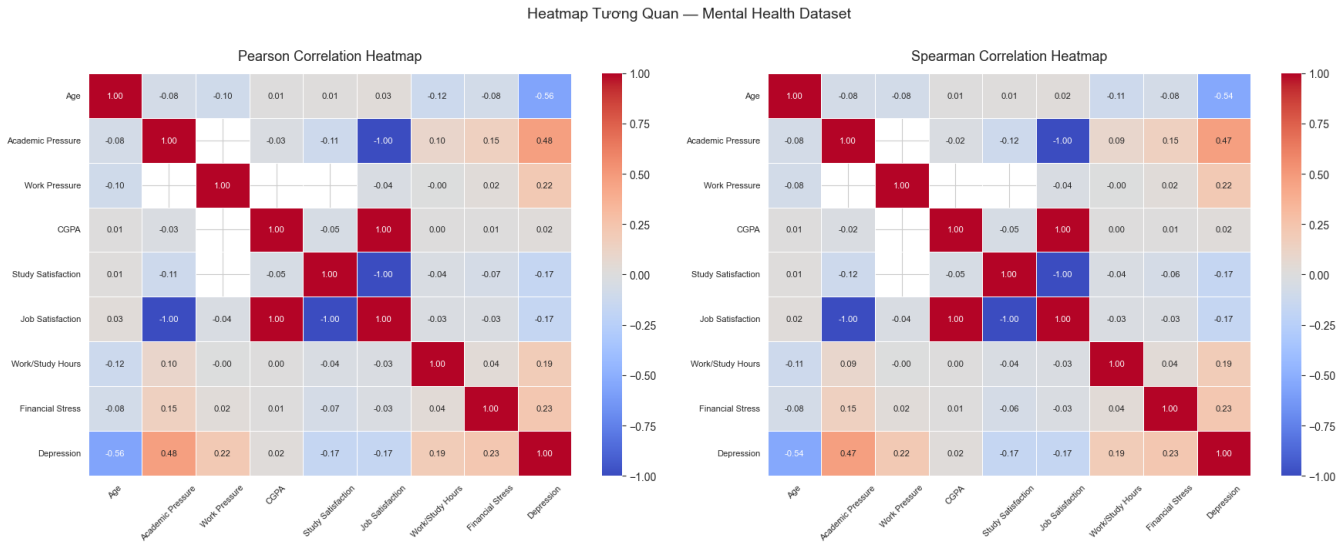

Hình 1: Heatmap tương quan Pearson và Spearman cho các biến số và nhãn *Depression*.

Phân tích giá trị thiếu. Cấu trúc thiếu dữ liệu thể hiện rõ cơ chế MAR theo nhóm đối tượng (Rubin, 1976). Nhóm sinh viên thiếu chủ yếu ở *Work Pressure* và *Job Satisfaction*, trong khi nhóm người đi làm thiếu ở *Academic Pressure*, *CGPA*, và *Study Satisfaction*. Vì vậy, chiến lược điền khuyết được thiết kế theo ngữ cảnh từng nhóm thay vì dùng một quy tắc chung. Xem Hình 2.

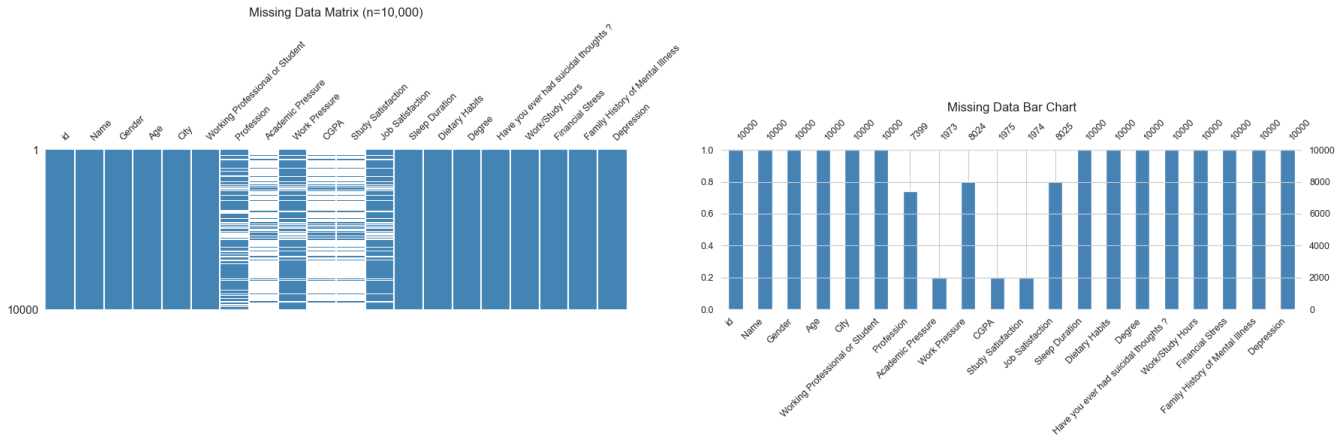

Hình 2: Phân tích tỉ lệ thiếu và cơ chế thiếu theo nhóm đối tượng trong dữ liệu bảng.

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

4.3.1 Xử lý giá trị thiếu có kiểm soát

Nhóm so sánh 5 chiến lược điền khuyết (Mean, Median, Mode, kNN, MICE) trên kịch bản tạo thêm 10% thiếu MCAR và đánh giá bằng RMSE (Troyanskaya et al., 2001; van Buuren and Groothuis-

Oudshoorn, 2011). Trong đó, kNN được thử với $k = 3, 5, 10$. Kết quả trung bình cho thấy **Mean** đạt RMSE tốt nhất (5.78), trong khi **Mode** kém nhất (9.03, cao hơn khoảng 66%). Với bài toán đơn biến trong notebook, kNN và MICE cho kết quả gần tương đương Mean.
Sau bước benchmark, pipeline điền khuyết thực tế được chốt theo ngữ cảnh dữ liệu:

- Median theo nhóm *Student* cho các cột chỉ có nghĩa với sinh viên.
- Median theo nhóm *Working Professional* cho các cột chỉ có nghĩa với người đi làm.
- Điền 0 cho các role-column còn lại (thiếu do không thuộc vai trò đó).
- Mode cho các biến phân loại như *Dietary Habits*, *Degree*; riêng *Profession* điền *Student* cho sinh viên.

Kết quả so sánh RMSE giữa các chiến lược thể hiện tại Hình 3.

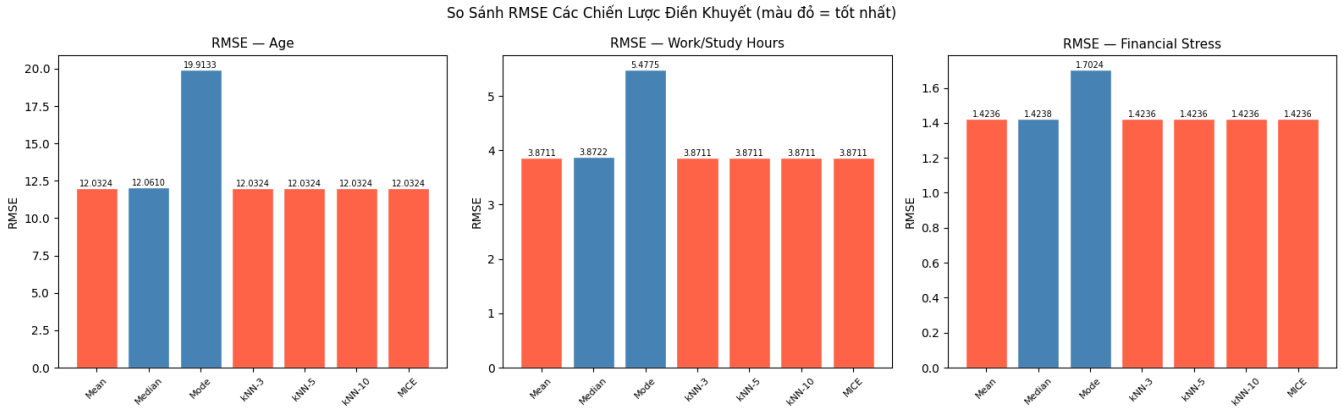

Hình 3: So sánh RMSE của các chiến lược điền khuyết trên kịch bản thiếu MCAR 10%.

4.3.2 Phát hiện và xử lý ngoại lai

Nhóm triển khai đồng thời 5 hướng phát hiện ngoại lai: IQR, Z-score, Isolation Forest, LOF và DBSCAN (Breunig et al., 2000; Ester et al., 1996; Liu et al., 2008). Thiết kế đánh giá gồm 3 lớp để tránh kết luận phiến diện:

- **Lớp 1 – Tỉ lệ bị gắn cờ ngoại lai**: kiểm tra mức độ bảo thủ/nhạy của từng phương pháp.
- **Lớp 2 – KS trước/sau loại ngoại lai**: đo mức méo phân phối khi lọc dữ liệu.
- **Lớp 3 – Jaccard similarity**: đo mức đồng thuận giữa các tập điểm bị gắn cờ.

Kết quả lớp 1 cho thấy sự khác biệt rõ rệt về hành vi:

- IQR: 19.83%, Z-score: 7.01%.
- IsoForest: 1.00% (contamination 0.01), 5.00% (0.05), 10.00% (0.10).
- LOF-20 và DBSCAN: xấp xỉ 0% trong cấu hình thử nghiệm.

Ở lớp 2 (KS test), cấu hình `IsoForest_0.05` cho KS statistic thấp nhất trên 7/8 biến chính (ví dụ *Age*: 0.0346 so với IQR: 0.1640 và Z-score: 0.0499), cho thấy loại bỏ được điểm bất thường mà vẫn giữ hình dạng phân phối tốt hơn hai phương pháp ngưỡng cổ điển.
Ở lớp 3 (Jaccard), mức đồng thuận IQR–Z-score chỉ 0.353 và IQR–IsoForest chỉ 0.247; Z-score–IsoForest là 0.381. Điều này xác nhận mỗi phương pháp đang bắt các kiểu điểm khác nhau, và IQR có xu hướng đánh dấu quá rộng trên dữ liệu có kurtosis âm (gần đều).
Tổng hợp ba lớp đánh giá, nhóm chọn **Isolation Forest với contamination** = 0.05 làm cấu hình chính vì thỏa ba tiêu chí thực hành: tỉ lệ loại bỏ hợp lý (5%), méo phân phối thấp, và ổn định trên dữ liệu đa chiều không chuẩn.
So sánh tỉ lệ phát hiện ngoại lai và mức đồng thuận giữa phương pháp được thể hiện tại Hình 4 và Hình 5.

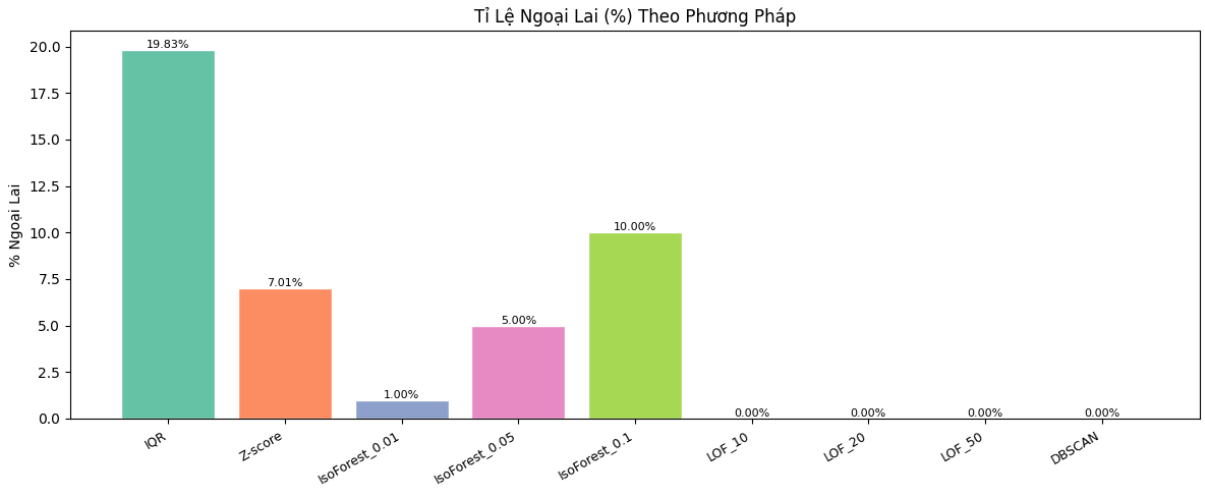

Hình 4: Tỉ lệ ngoại lai theo từng phương pháp phát hiện trên dữ liệu bảng.

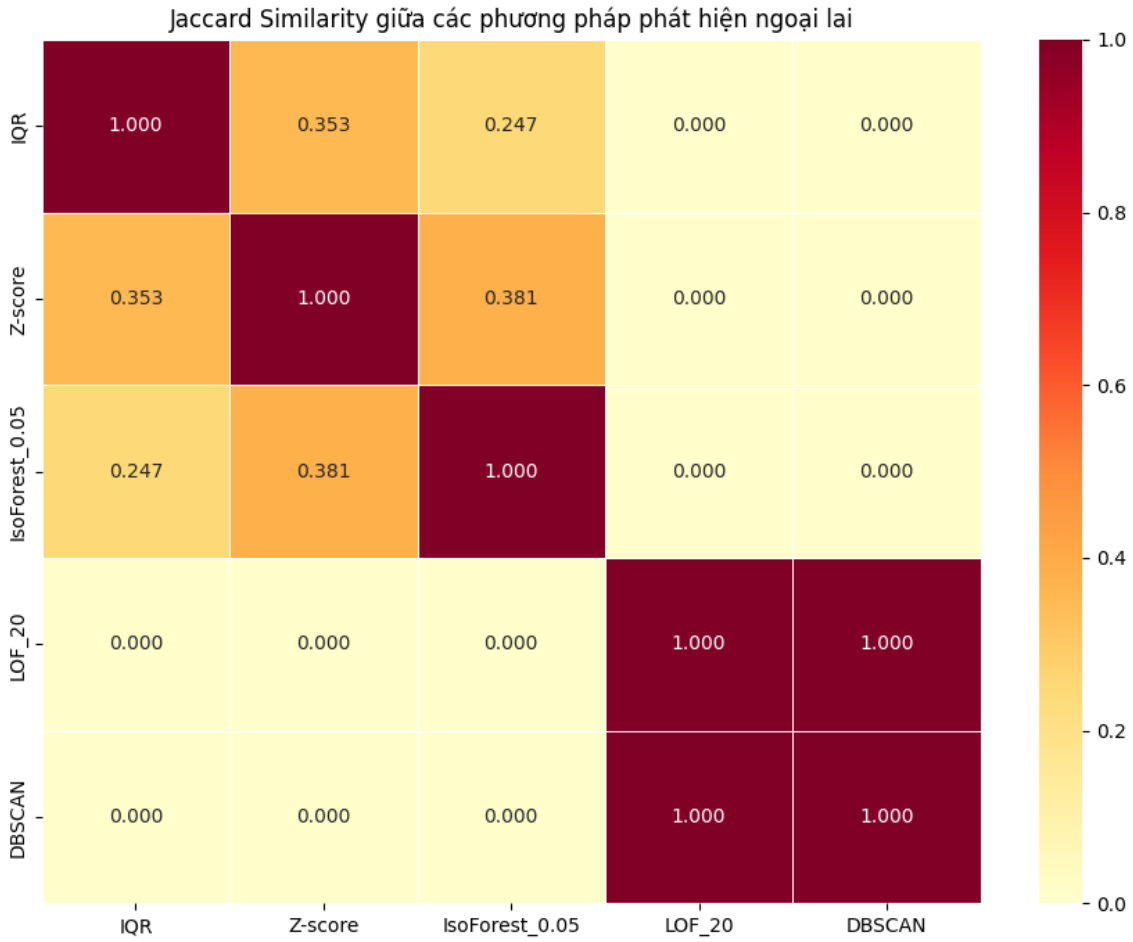

Hình 5: Ma trận Jaccard similarity giữa các phương pháp phát hiện ngoại lai.

4.3.3 Chuẩn hóa dữ liệu có kiểm định

Nhóm thử Min-Max, Z-score, Robust Scaling và Quantile Transform (Huber, 1981; scikit-learn developers, 2026b). Kết quả Levene kết hợp quan sát violin plot cho thấy **Robust Scaling** là lựa chọn cân bằng nhất: giảm ảnh hưởng ngoại lai nhưng vẫn giữ cấu trúc phân phối tốt hơn Quantile Transform.

Levene's test chủ yếu phản ánh thay đổi phương sai, nên quyết định cuối cùng được dựa thêm trên hình dạng phân phối từ violin plot (Hình 6).

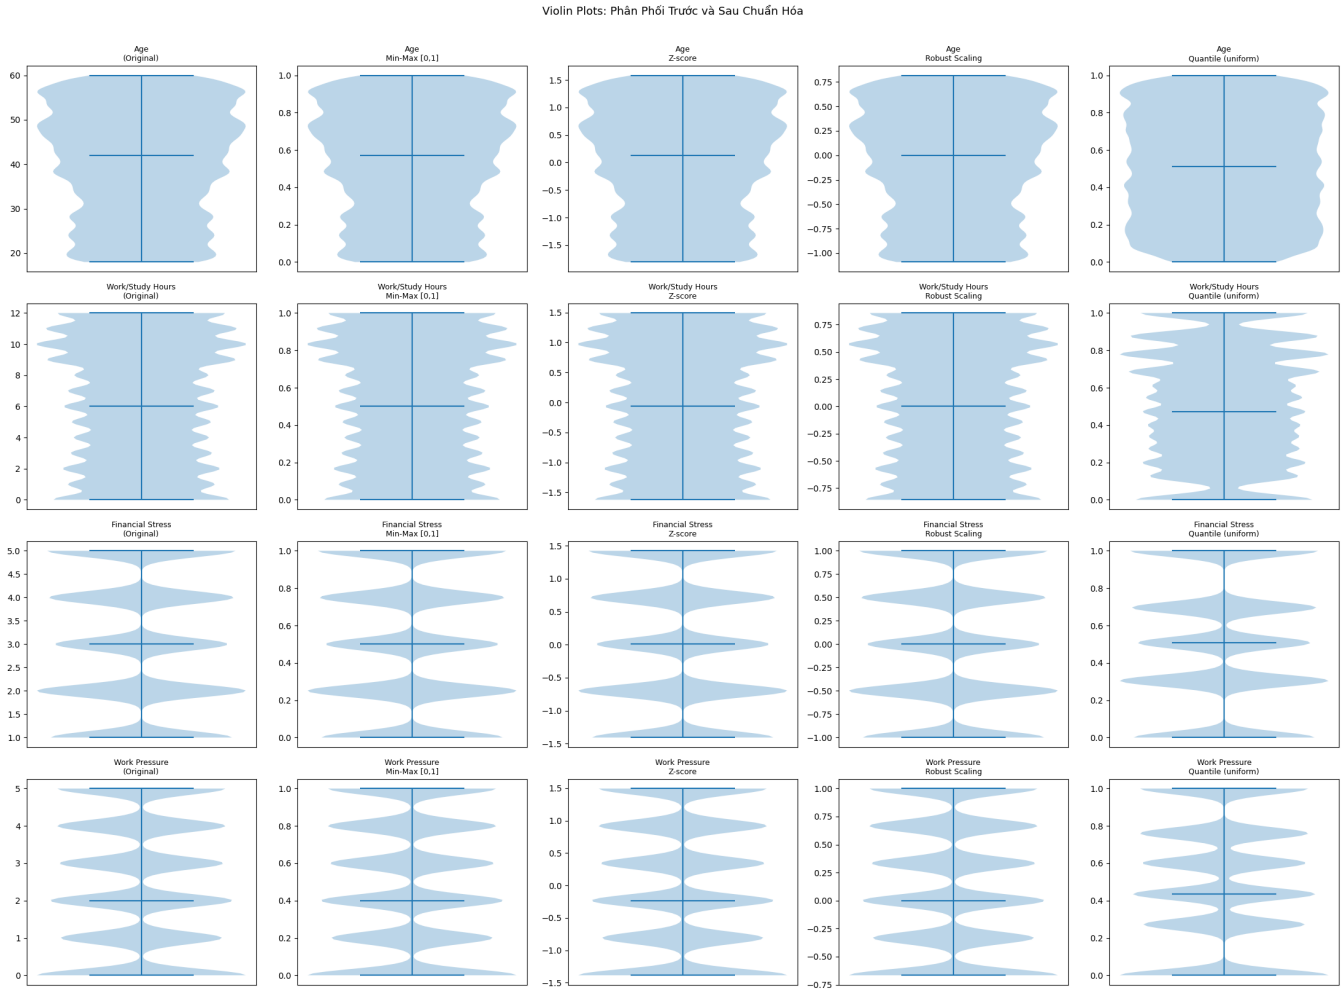

Hình 6: So sánh phân phối trước/sau chuẩn hóa bằng violin plot trên các biến số chính.

4.3.4 Mã hóa biến phân loại nâng cao

Ngoài One-Hot và Ordinal, nhóm triển khai thêm Target Encoding (K-fold), Binary Encoding và Frequency Encoding (Category Encoders developers, 2026). Đánh giá bằng VIF (James et al., 2013; statsmodels developers, 2025b) cho thấy **Binary Encoding** tốt nhất (mean VIF = 4.21), trong khi **Frequency Encoding** gây đa cộng tuyến rất cao (mean VIF = 889.59).

Vì vậy, ở bước tạo dataset cuối, nhóm chọn Binary Encoding cho toàn bộ biến phân loại để tối ưu đa cộng tuyến và giữ số chiều ở mức hợp lý.

4.3.5 Lựa chọn và giảm chiều đặc trưng

Đây là bước bắt buộc và được triển khai theo đúng 3 tầng để đảm bảo cả hiệu năng lẫn khả năng diễn giải mô hình (Breiman, 2001; Guyon et al., 2002; Jolliffe, 2002). Toàn bộ phương pháp được

đánh giá thống nhất bằng **F1-score 5-fold cross-validation** với cùng mô hình Logistic Regression để so sánh công bằng.

Tầng 1 – Lọc thống kê:

- **ANOVA F-test** cho thuộc tính số: đo mức tách lớp theo trung bình giữa các lớp.
- **Chi-square test** cho thuộc tính phân loại đã mã hóa không âm: kiểm tra mức phụ thuộc giữa biến và nhãn.
- **Mutual Information (MI)** cho toàn bộ đặc trưng: đo phụ thuộc phi tuyến, không giả định quan hệ tuyến tính.

Tầng 2 – Lọc dựa trên mô hình:

- **Random Forest importance** và **Gradient Boosting importance**: xếp hạng đặc trưng theo mức đóng góp vào giảm lỗi phân tách.
- **RFE/RFECV**: loại dần đặc trưng kém quan trọng với cross-validation để tìm tập biến gọn nhưng vẫn giữ hiệu năng.

Tầng 3 – Giảm chiều:

- **PCA**: nén thông tin vào các thành phần chính và kiểm tra ngưỡng phương sai tích lũy (90%, 95%, 99%).
- **t-SNE**: trực quan hóa không gian đặc trưng 2D để quan sát mức tách cụm lớp.
- **UMAP (khuyến nghị cho dữ liệu lớn)**: trong notebook hiện tại, nhóm dừng ở t-SNE do đã lấy mẫu 15,000 điểm cho huấn luyện và 3,000 điểm cho trực quan hóa; với quy mô lớn hơn, UMAP là lựa chọn phù hợp để giảm chi phí tính toán và giữ cấu trúc lân cận tốt hơn.

Kết quả định lượng F1-score theo số lượng đặc trưng k:

- $k = 5$: MI = 0.713, RF = 0.746, PCA = 0.724, RFE = 0.813.
- $k = 10$: MI = 0.784, RF = 0.809, PCA = 0.747, RFE = 0.813.
- $k = 15$: MI = 0.812, RF = 0.813, PCA = 0.813, RFE = 0.813.

- $k = 20$: MI = 0.813, RF = 0.813, PCA = 0.816, RFE = 0.813.

Nhận xét chuyên sâu:

- Ở vùng ít đặc trưng ($k \leq 10$), RF importance vượt MI rõ rệt, cho thấy lợi thế khi có tương tác phi tuyến.
- RFE cho F1 cao và ổn định trên toàn dải k, chứng tỏ tập đặc trưng được chọn có tính bền vững.
- PCA bắt kịp ở k lớn (tối đa 0.816 tại $k = 20$), phù hợp khi mục tiêu chính là nén chiều hơn là diễn giải theo biến gốc.
- Sau $k \geq 15$, hiệu năng gần bão hòa, hàm ý thêm đặc trưng không còn cải thiện đáng kể.

→ **Kết luận lựa chọn:** cho pipeline tabular chính, nhóm ưu tiên **RFE** vì cân bằng tốt giữa độ chính xác, độ ổn định và khả năng giải thích; RF importance được dùng làm baseline nhanh cho bài toán rút gọn đặc trưng, còn PCA/t-SNE phục vụ giảm chiều và trực quan hóa.
Biểu đồ so sánh hiệu năng theo số lượng đặc trưng được trình bày trong Hình 7.

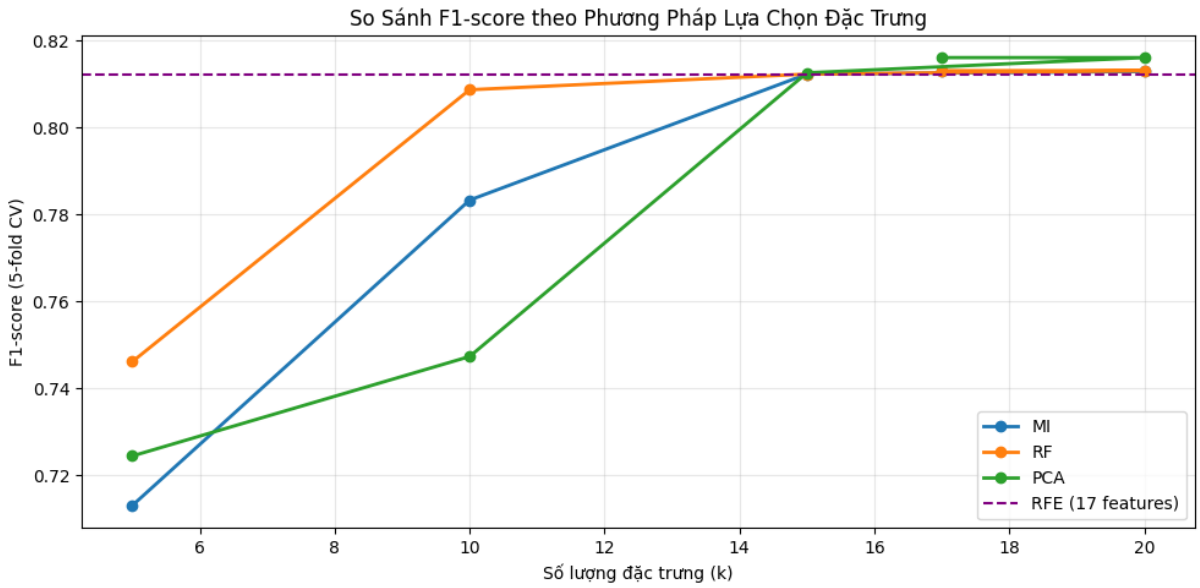

Hình 7: So sánh F1-score theo số lượng đặc trưng cho MI, RF, PCA và RFE.

4.3.6 Xử lý mất cân bằng lớp

Đây là bước nâng cao vì cần tối ưu đồng thời khả năng phát hiện lớp thiểu số và độ tin cậy tổng thể của mô hình. Nhóm đánh giá 4 cấu hình: Baseline (không resampling), SMOTE, ADASYN và

Random Under-sampling (Chawla et al., 2002; He et al., 2008). Thiết kế thí nghiệm được cố định như sau:

- Chia train/test theo *stratified split*; tập test giữ nguyên phân phối gốc để phản ánh tình huống triển khai thực tế.
- Chỉ resampling trên tập train để tránh data leakage.
- Dùng cùng một mô hình đánh giá (Random Forest, `n_estimators=50`, `max_depth=8`) cho mọi chiến lược để đảm bảo so sánh công bằng.

Kết quả định lượng trên tập test gốc:

- Baseline: Precision = 0.897, Recall = 0.869, F1-macro = 0.882, AUC-ROC = 0.969.
- SMOTE: Precision = 0.866, Recall = 0.904, F1-macro = 0.883, AUC-ROC = 0.969.
- ADASYN: Precision = 0.853, Recall = 0.901, F1-macro = 0.874, AUC-ROC = 0.964.
- Random Under-sampling: Precision = 0.836, Recall = 0.913, F1-macro = 0.866, AUC-ROC = 0.969.

Diễn giải theo góc nhìn nâng cao cho thấy Under-sampling đẩy Recall cao nhất nhưng làm giảm Precision rõ rệt do mất nhiều mẫu lớp đa số; ADASYN cải thiện Recall nhưng kém ổn định hơn ở AUC. Baseline có Precision tốt nhưng bỏ sót nhiều ca dương tính hơn. **SMOTE** là cấu hình cân bằng nhất: tăng Recall đáng kể so với baseline (+3.5% tương đối), giữ AUC-ROC không giảm, và đạt F1-macro cao nhất (0.883). Với bài toán sàng lọc nguy cơ trầm cảm, cấu hình ưu tiên Recall nhưng vẫn kiểm soát false positive ở mức hợp lý là phù hợp nhất.
Kết quả so sánh Precision, Recall, F1-macro và AUC-ROC giữa các chiến lược được trình bày trong Hình 8.

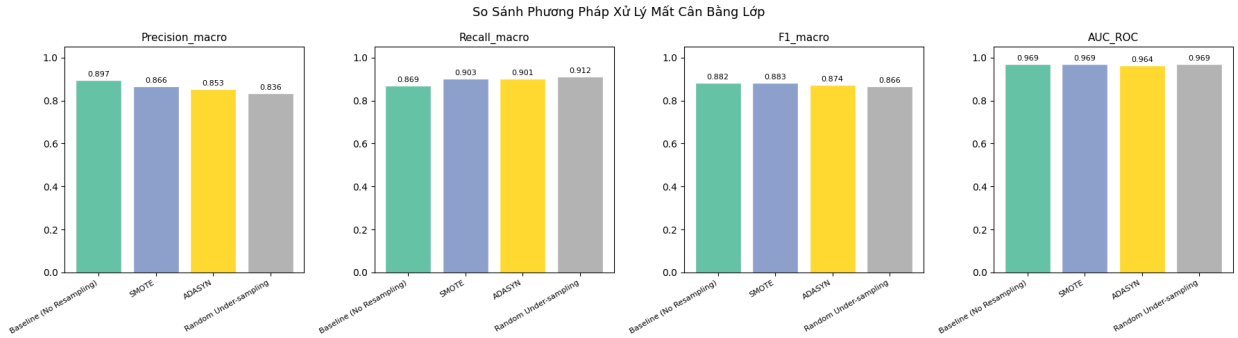

Hình 8: So sánh các chiến lược xử lý mất cân bằng lớp trên tập test gốc.

4.4 Đánh giá pipeline

Bảng 6 tổng hợp các kết quả định lượng cho từng bước trong pipeline tiền xử lý bảng

Kỹ thuật	**Phương pháp tốt nhất**	**Kém nhất**	**Chỉ số chính**
Điền khuyết	Mean	Mode	RMSE: 5.78 vs 9.03
Ngoại lai	IsoForest (0.05)	—	KS: tất cả biến $p < 0.05$
Chuẩn hóa	Robust Scaling	Quantile (uniform)	Levene + violin plot
Mã hóa	Binary Encoding	Frequency Encoding	VIF: 4.21 vs 889.59
Chọn đặc trưng	RFE	MI ($k = 5$)	F1 xấp xỉ 0.813
Cân bằng lớp	SMOTE	Random Under-sampling	F1-macro: 0.883 vs 0.866

Bảng 6: Tổng hợp kết quả định lượng cho phần dữ liệu bảng

Sau khi hoàn thành tiền xử lý, nhóm triển khai hai bước đánh giá: (1) tổng hợp phương pháp tốt nhất cho từng công đoạn tiền xử lý, và (2) dựng dataset cuối để lưu cho các bước mô hình hóa tiếp theo.

4.4.1 Tổng hợp cấu hình tốt nhất

Cấu hình được chọn cho từng bước là:

- Điền khuyết: Mean cho benchmark số, kết hợp chiến lược theo ngữ cảnh nhóm cho dữ liệu thực tế.
- Ngoại lai: Isolation Forest với contamination = 0.05.
- Chuẩn hóa: Robust Scaling.
- Mã hóa: Binary Encoding.

- Chọn đặc trưng: RFE (F1 cao và ổn định, khoảng 0.813).
- Mất cân bằng lớp: SMOTE (F1-macro cao nhất khoảng 0.883).

Hai bước (chọn đặc trưng và cân bằng lớp) được dùng cho quá trình huấn luyện mô hình, không phải là biến đổi bắt buộc để xuất file dữ liệu tiền xử lý cuối.

4.4.2 Tạo dataset tiền xử lý cuối

Pipeline xuất dữ liệu gồm 4 bước:

1. Loại ngoại lai bằng `IsoForest_0.05`.
2. Chuẩn hóa 8 biến số bằng `RobustScaler`.
3. Mã hóa nhị phân toàn bộ biến phân loại (trừ nhãn *Depression*).
4. Đưa nhãn mục tiêu về cột cuối và lưu file kết quả.

4.5 Kết luận

Từ toàn bộ hai notebook tabular (EDA và preprocessing), nhóm xây dựng pipeline đề xuất cho dữ liệu bảng gồm:

1. Điền khuyết theo ngữ cảnh vai trò (Student/Working Professional) kết hợp benchmark RMSE.
2. Phát hiện ngoại lai bằng Isolation Forest (contamination = 0.05).
3. Chuẩn hóa biến số bằng Robust Scaling.
4. Mã hóa biến phân loại theo chiến lược hỗn hợp (One-Hot cho low-cardinality, Binary cho high-cardinality).
5. Chọn đặc trưng bằng RF importance hoặc RFE để giữ tập biến gọn và ổn định.
6. Cân bằng lớp bằng SMOTE ở giai đoạn huấn luyện.

Kết quả định lượng cho thấy pipeline này vừa kiểm soát tốt chất lượng dữ liệu (thiếu, ngoại lai, đa cộng tuyến), vừa duy trì hiệu năng mô hình ở mức cao với F1-macro tốt nhất 0.883 trên bài toán phân loại *Depression*. Do đó, pipeline tabular được chọn làm cấu hình chuẩn cho các bước mô hình hóa phía sau.

5 Tiền xử lý dữ liệu chuỗi thời gian

5.1 Dữ liệu sử dụng

Nhóm sử dụng bộ dữ liệu tiêu thụ điện Tây Ban Nha (*Spain Energy Consumption Dataset*) cho phần chuỗi thời gian.

Tập dữ liệu có 35.064 quan sát theo tần suất giờ trong giai đoạn 2015–2019. Biến mục tiêu chính là tải điện (MW), đồng thời có các biến hỗ trợ theo ngữ cảnh thời gian để phục vụ bước nội suy, kiểm định tính dừng, trích xuất đặc trưng và dự báo một bước trước.

Bộ dữ liệu này phù hợp với yêu cầu đề bài ở ba điểm:

- Đủ chiều dài chuỗi theo nhiều năm.
- Có tính mùa vụ theo ngày và theo tuần.
- Có ý nghĩa thực tiễn rõ ràng cho bài toán tiền xử lý phục vụ dự báo.

5.2 Phân tích khám phá chuỗi thời gian

Nhóm tập trung vào 4 câu hỏi chính:

- Chuỗi có xu hướng dài hạn hay không?
- Mùa vụ xuất hiện ở các chu kỳ nào?
- Mức dao động thay đổi ra sao theo thời gian?
- Chuỗi có thỏa điều kiện dừng để mô hình hóa trực tiếp hay không?

Kết quả chính từ notebook EDA thời gian cho thấy:

- Biến *total load actual* chỉ thiếu 36 điểm trên toàn bộ chuỗi (xấp xỉ 0.1%), nên không làm méo cấu trúc tín hiệu tổng thể ở bước khám phá.
- Time plot toàn giai đoạn cho thấy không có xu hướng tăng/giảm tuyến tính dài hạn rõ rệt, nhưng xuất hiện mùa vụ mạnh theo năm; khi phóng to theo tuần, chu kỳ ngày và khác biệt giữa ngày làm việc–cuối tuần thể hiện rõ.

- ACF/PACF xác nhận tự tương quan mạnh ở các độ trễ ngắn và tại các bội số của 24 giờ, đồng thời xuất hiện dấu hiệu mùa vụ tuần (168 giờ).
- Rolling mean và rolling std (cửa sổ 7/30/90 ngày) đều biến thiên theo thời gian, cho thấy chuỗi chưa dừng và cần biến đổi ở bước tiền xử lý tiếp theo.

5.2.1 Time Plot

Time plot toàn giai đoạn 2015–2019 cho thấy chuỗi tải điện dao động quanh một mức trung bình tương đối ổn định, chưa ghi nhận xu hướng tuyến tính tăng/giảm dài hạn rõ rệt (Hình 9). Tuy nhiên, đường bao chuỗi lặp lại theo các nhịp lớn theo năm, phản ánh tác động mùa vụ vĩ mô (thời tiết và nhu cầu tiêu thụ theo mùa).

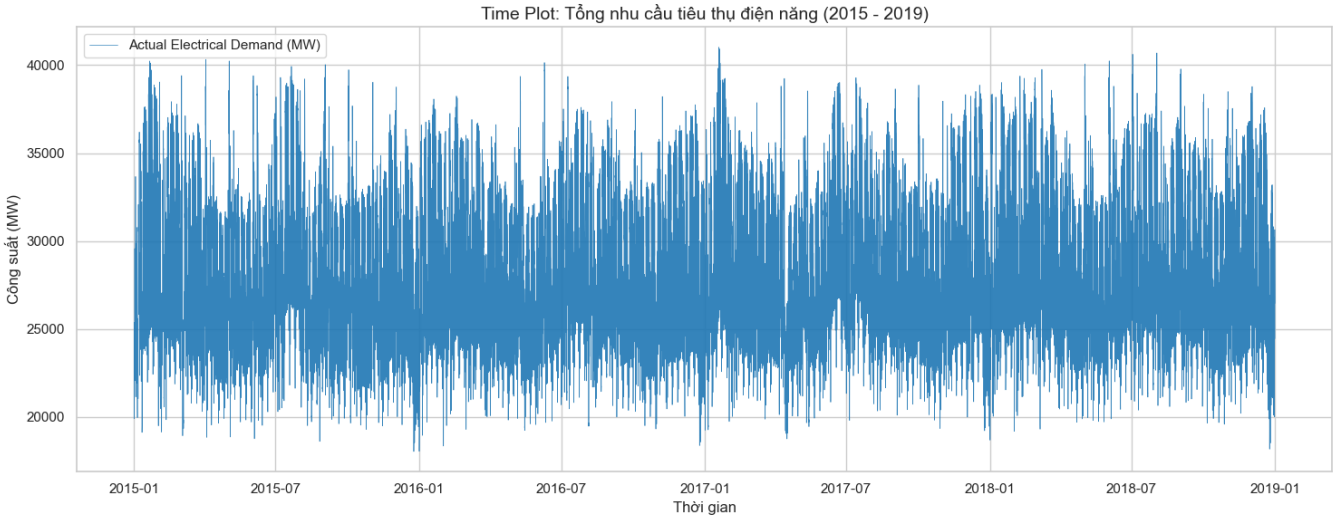

Hình 9: Time plot toàn giai đoạn 2015–2019 cho biến *total load actual*.

Khi phóng to về tuần đầu năm 2015, cấu trúc chu kỳ ngắn hạn hiện rõ hơn:

- Chu kỳ ngày (24 giờ): phụ tải giảm vào rạng sáng và tăng lên vào các khung giờ hoạt động cao trong ngày.
- Chu kỳ tuần: biên độ tải ở ngày làm việc cao hơn đáng kể so với cuối tuần.
- Hiệu ứng ngày lễ: các ngày lễ đầu năm tạo ra các điểm sụt phụ tải bất thường, khác với dao động tuần thông thường.

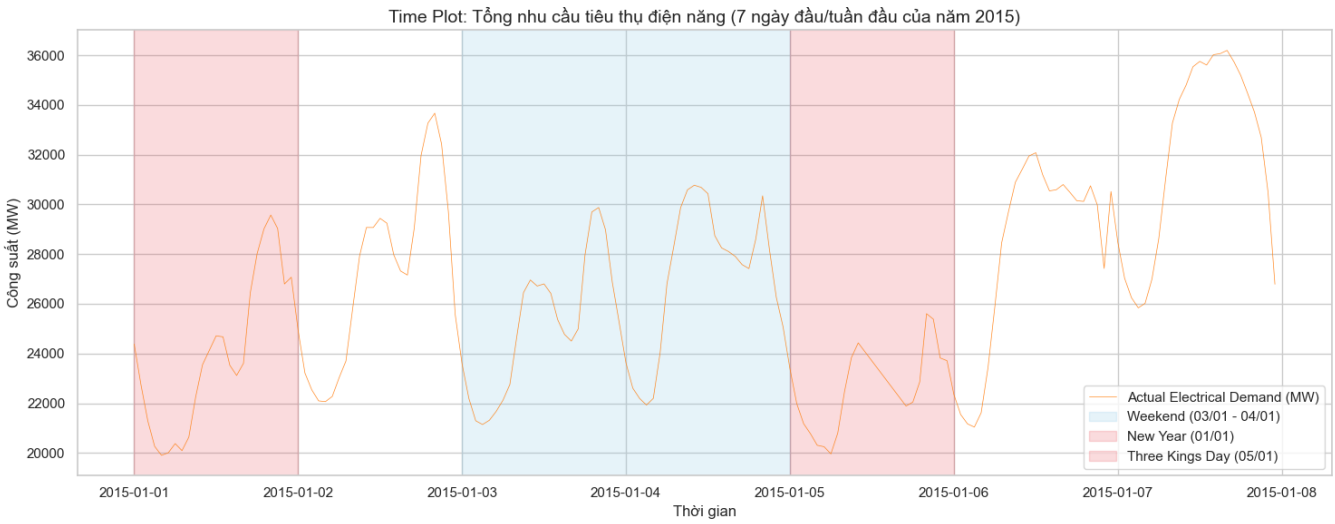

Hình 10: Time plot tuần đầu năm 2015 cho biến *total load actual*.

Phân tích time-plot cho ta thấy các thành phần cấu trúc của chuỗi có đặc điểm:

1. **Xu hướng (Trend)**: không rõ ràng, có thể coi là gần như không tồn tại trong giai đoạn này.
2. **Mùa vụ (Seasonality)**: rất rõ ràng ở cả chu kỳ ngày và tuần, với biên độ thay đổi theo mùa trong năm.
3. **Nhiễu và Hiệu ứng ngày lễ (Noise & Holiday Effects)**: có dao động ngắn hạn và một số điểm bất thường (outliers) liên quan đến ngày lễ.
4. **Tính dừng (Stationarity)**: mặc dù phương sai tương đối đồng đều và không có xu hướng dài hạn, nhưng sẽ có những tính mùa vụ lồng ghép phức tạp khiến mean của chuỗi thay đổi liên tục theo thời gian. Do đó, có thể nói đây là chuỗi không dừng (non-stationary)

5.2.2 Phân tích tương quan ACF và PACF

Theo công thức thực nghiệm $\min(10\log_{10} n, n/5)$, số lag tối đa ban đầu xấp xỉ 45 (Hình 11). Tuy nhiên, do dữ liệu có tần suất giờ, nhóm mở rộng phân tích đến 168 lag để kiểm tra đầy đủ chu kỳ ngày (24 giờ) và tuần (168 giờ) (Hình 12).

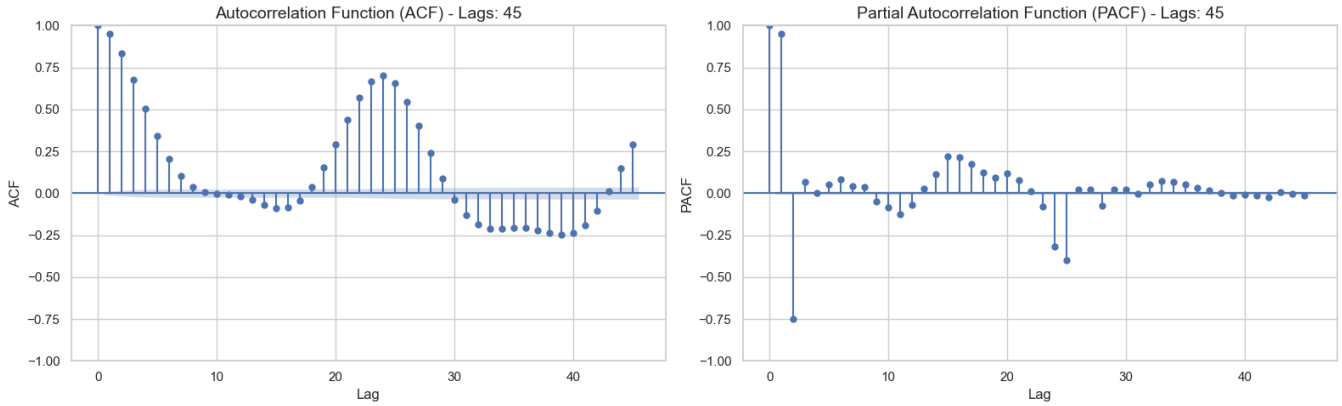

Hình 11: ACF và PACF cho biến *total load actual* với lag tối đa 45.

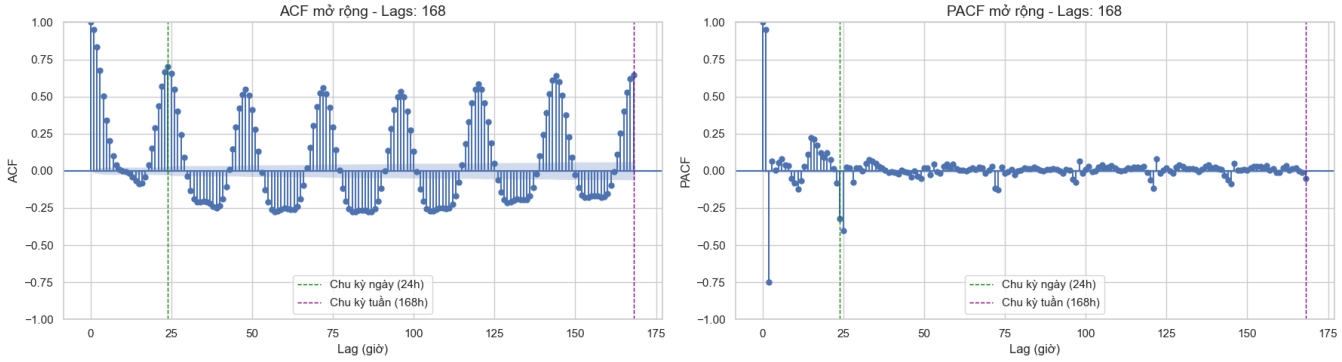

Hình 12: ACF và PACF mở rộng đến lag 168 để kiểm tra mùa vụ ngày và tuần.

Kết quả **ACF** cho thấy hệ số tự tương quan suy giảm chậm và duy trì ý nghĩa ở nhiều lag xa, hàm ý chuỗi có tính nhớ dài và chưa dừng. Đồng thời, các đỉnh lặp lại tại các bội số của 24 giờ củng cố bằng chứng về mùa vụ ngày; đỉnh tại vùng 168 giờ cho thấy mùa vụ tuần cũng hiện diện rõ.

Ở **PACF**, các gai (spikes) lớn tập trung tại các lag đầu (đặc biệt lag 1 và 2), sau đó giảm nhanh, cho thấy ảnh hưởng trực tiếp chủ yếu đến từ lịch sử rất gần. Ngoài ra, sự xuất hiện gai đáng chú ý quanh lag 24 phản ánh tác động mùa vụ ngày lên quan sát hiện tại.

Căn cứ vào PACF, khi xây dựng ma trận đặc trưng cho dự báo, ta cần bắt buộc tạo các biến trễ (lag features) ngắn hạn quan trọng lag $t-1, t-2$ và các lag có giá trị tương quan âm mạnh tại $t-3$ và đặc biệt là $t-24$ để nắm bắt được ảnh hưởng của chu kỳ ngày.

5.2.3 Rolling statistics

Rolling mean và rolling standard deviation được tính trên ba cửa sổ 168, 720 và 2160 giờ (tương ứng 7, 30 và 90 ngày) để đánh giá sự ổn định của kỳ vọng và phương sai theo thời gian.

Quan sát trên rolling mean cho thấy khi tăng kích thước cửa sổ, nhiễu ngắn hạn được làm phẳng nhưng đường trung bình vẫn dao động có chu kỳ thay vì hội tụ về hằng số. Ở cửa sổ dài (90 ngày), đường trung bình thể hiện rõ các nhịp lên xuống vĩ mô theo mùa.
Với rolling std, độ biến thiên cũng thay đổi theo thời gian: ở cửa sổ ngắn dao động mạnh, còn ở cửa sổ dài vẫn duy trì dạng dao động có cấu trúc. Điều này cho thấy phương sai của chuỗi không ổn định theo nghĩa thống kê.
Như vậy, cả hai điều kiện dừng quan trọng (mean và variance bất biến theo thời gian) đều bị vi phạm. Đây là cơ sở để áp dụng bước ổn định phương sai (log/Box-Cox) kết hợp sai phân hoặc decomposition ở các bước tiền xử lý kế tiếp.

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Pipeline tiền xử lý cho dữ liệu chuỗi thời gian được tổ chức theo thứ tự: xử lý giá trị thiếu theo mốc thời gian, kiểm định tính dừng và biến đổi, phân rã cấu trúc chuỗi, phát hiện dị thường, xây dựng ma trận đặc trưng, rồi đánh giá bằng bài toán dự báo một bước trước $(t + 1)$. Kết quả chi tiết từng bước được dùng để chọn cấu hình tiền xử lý tối ưu theo cả tiêu chí thống kê và hiệu năng dự báo.

5.3.1 Xử lý khoảng trống thời gian và nội suy

Nhóm chủ động loại bỏ ngẫu nhiên 5% dữ liệu theo cơ chế MCAR để so sánh 5 phương pháp: Forward Fill, Linear, Polynomial bậc 2, Polynomial bậc 3 và Spline Cubic. Sai số được đánh giá trên đúng các vị trí bị che bằng MAE và RMSE; đồng thời kiểm định Ljung-Box được dùng để kiểm tra cấu trúc phần dư sau nội suy (Ljung and Box, 1978; statsmodels developers, 2025a).
Kết quả cho thấy:

- **Forward Fill** kém nhất (MAE xấp xỉ 1160, RMSE xấp xỉ 1604), do không theo kịp độ cong tự nhiên của phụ tải theo giờ.
- **Linear** cải thiện đáng kể (MAE xấp xỉ 427) nhưng vẫn chưa nắm bắt tốt phi tuyến cục bộ.
- Nhóm phương pháp phi tuyến vượt trội; **Polynomial bậc 2** tốt nhất với MAE xấp xỉ 276.23 và RMSE xấp xỉ 508.74.

- Với cả 5 phương pháp, p-value Ljung-Box đều lớn hơn 0.05 (khoảng 0.4889–0.9014), nghĩa là phần dư không còn tự tương quan có ý nghĩa thống kê.

Phân phối phần dư của phương pháp tốt nhất (Polynomial bậc 2) được thể hiện tại Hình 13.

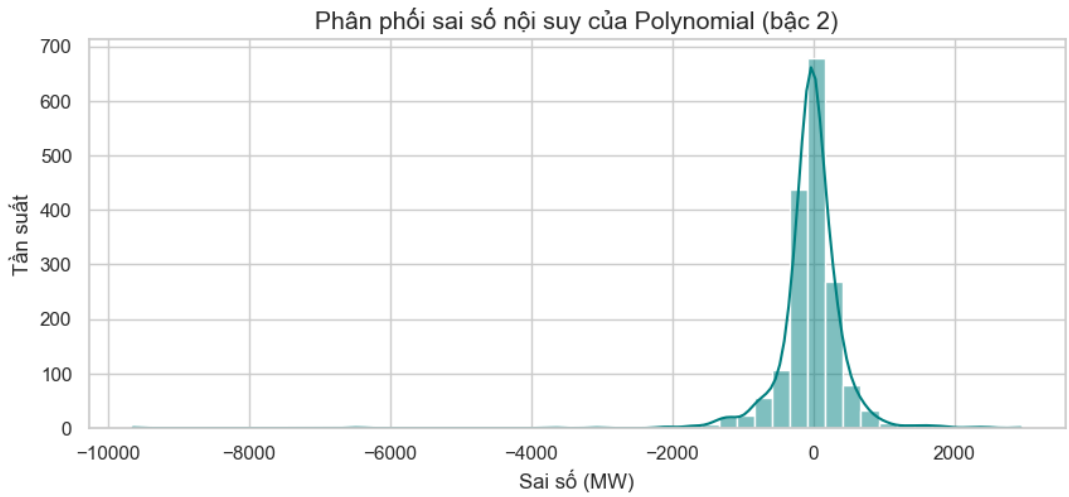

Hình 13: Phân phối phần dư của phương pháp nội suy Polynomial bậc 2 tại các điểm thiếu MCAR 5%.

Từ đó, nhóm chọn **Polynomial bậc 2** làm cấu hình nội suy chính cho pipeline làm sạch dữ liệu lịch sử.

5.3.2 Kiểm định tính dừng (Stationarity Tests)

Nhóm dùng bộ ba kiểm định ADF, KPSS và Phillips-Perron (PP) trên nhiều phiên bản chuỗi: chuỗi gốc, Log-transform, Box-Cox, Box-Cox + sai phân bậc 1, và sai phân bậc 2 (Dickey and Fuller, 1979; Kwiatkowski et al., 1992; Phillips and Perron, 1988; statsmodels developers, 2025d, 2025e). Cách phối hợp ba kiểm định giúp giảm rủi ro kết luận sai nếu chỉ dựa vào một phép thử.
Giả thuyết kiểm định được dùng theo chuẩn:

- ADF/PP: H_0 chuỗi có unit root (không dừng), H_1 chuỗi dừng.
- KPSS: H_0 chuỗi dừng, H_1 chuỗi không dừng.

Quy tắc ra quyết định trong báo cáo:

- Chỉ chấp nhận chuỗi dừng khi ADF và PP cùng bác bỏ H_0 (p-value nhỏ), đồng thời KPSS không bác bỏ H_0 (p-value đủ lớn).

- Nếu kết quả mâu thuẫn, ưu tiên biến đổi nhẹ hơn để tránh over-differencing.

Nhận xét kết quả kiểm định:

- **Chuỗi gốc chưa dừng:** KPSS chạm ngưỡng dưới 0.0100.
- **Log-transform chưa đủ mạnh:** KPSS vẫn ở mức 0.0100.
- **Box-Cox + sai phân bậc 1 cho kết quả tốt nhất:** với $\lambda \approx 0.6341$, KPSS lên ngưỡng trên 0.1000, đồng thời ADF và PP cho p-value rất nhỏ (Box and Cox, 1964; SciPy Community, 2025a).
- **Sai phân bậc 2 không cần thiết:** không cải thiện rõ ràng, có nguy cơ over-differencing và làm mất tín hiệu ngắn hạn.

→ **Kết luận lựa chọn:** biến đổi được chốt cho pipeline là **Box-Cox + sai phân bậc 1**. Lựa chọn này vừa đạt tính dừng về mặt thống kê, vừa giữ được thông tin cần thiết cho bài toán dự báo $t+1$.

5.3.3 Phân rã chuỗi thời gian

Nhóm so sánh Additive, Multiplicative và STL với chu kỳ tuần 168 giờ (phù hợp dữ liệu theo giờ). Chỉ số đánh giá là tỉ lệ phương sai phần dư (Cleveland et al., 1990; statsmodels developers, 2025c):

$$\mathrm{RVR} = \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(y_t)}.$$

Kết quả:

- Additive: RVR = 0.7200 (khả năng bóc tách cấu trúc thấp).
- Multiplicative: RVR = 0.0000 (kết quả không đáng tin cậy về mặt thực tiễn, có dấu hiệu artifact).
- STL: RVR = 0.3319 (hợp lý và tốt nhất trong ba phương pháp).

Cấu trúc các thành phần sau phân rã được minh họa tại Hình 14.

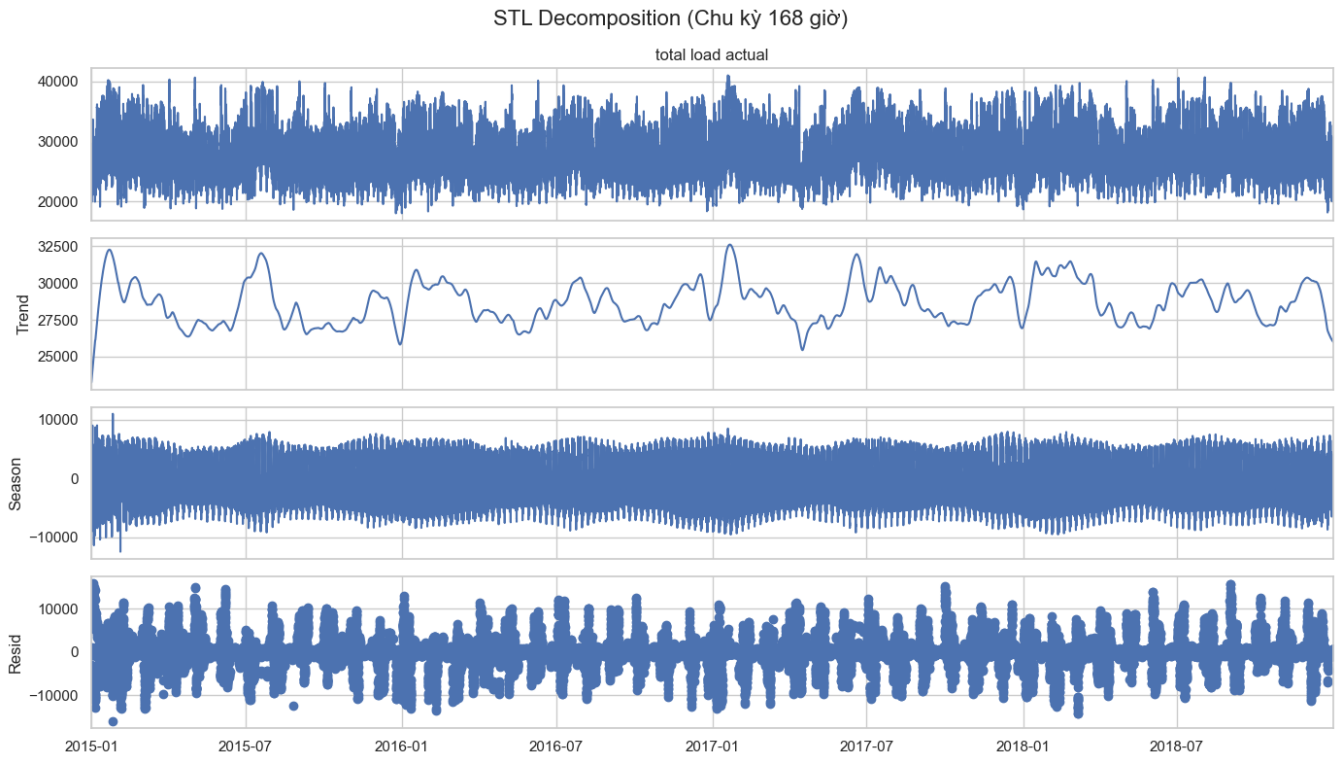

Hình 14: Kết quả STL decomposition với chu kỳ tuần 168 giờ trên chuỗi đã làm sạch.

Theo đó, nhóm sử dụng **STL decomposition** để lấy các chuỗi dẫn xuất: `stl_trend`, `stl_seasonal`, `stl_resid`, `deseasonalized`, `detrend` cho các bước tiếp theo.

5.3.4 Feature Engineering & Phát hiện dị thường

Phát hiện dị thường

Phát hiện dị thường được thực hiện sau khi chuỗi đã nội suy và phân rã STL, nhằm tách rõ dị thường biên độ lớn khỏi dao động mùa vụ bình thường. Nhóm triển khai ba hướng bổ sung nhau:

- **Z-score** trên chuỗi deseasonalized (ngưỡng $|z| > 3$): bắt các điểm lệch mạnh theo chuẩn hóa toàn cục.
- **Isolation Forest** (contamination = 0.01) trên đặc trưng rolling 24h: phát hiện dị thường theo hình học đa chiều cục bộ.
- **STL residual thresholding** với ngưỡng 3σ: nhắm trực tiếp vào phần dư sau khi đã tách trend và seasonality.

Số lượng điểm dị thường phát hiện được:

- Z-score: 662 điểm.
- Isolation Forest (contamination = 0.01): 350 điểm.
- STL Residual Thresholding: 1055 điểm.

Nhận xét theo mục tiêu vận hành:

- **Isolation Forest** cho tập dị thường hẹp nhất, phù hợp kịch bản cảnh báo bảo thủ.
- **Z-score** ở mức trung gian, dễ diễn giải nhưng nhạy với giả định phân phối.
- **STL residual thresholding** cho độ phủ lớn nhất, phù hợp khi ưu tiên không bỏ sót các cú sốc ngoại sinh (ngày lễ, thời tiết cực đoan, sự cố hệ thống).

Phân bố điểm dị thường theo từng phương pháp được minh họa tại Hình 15.

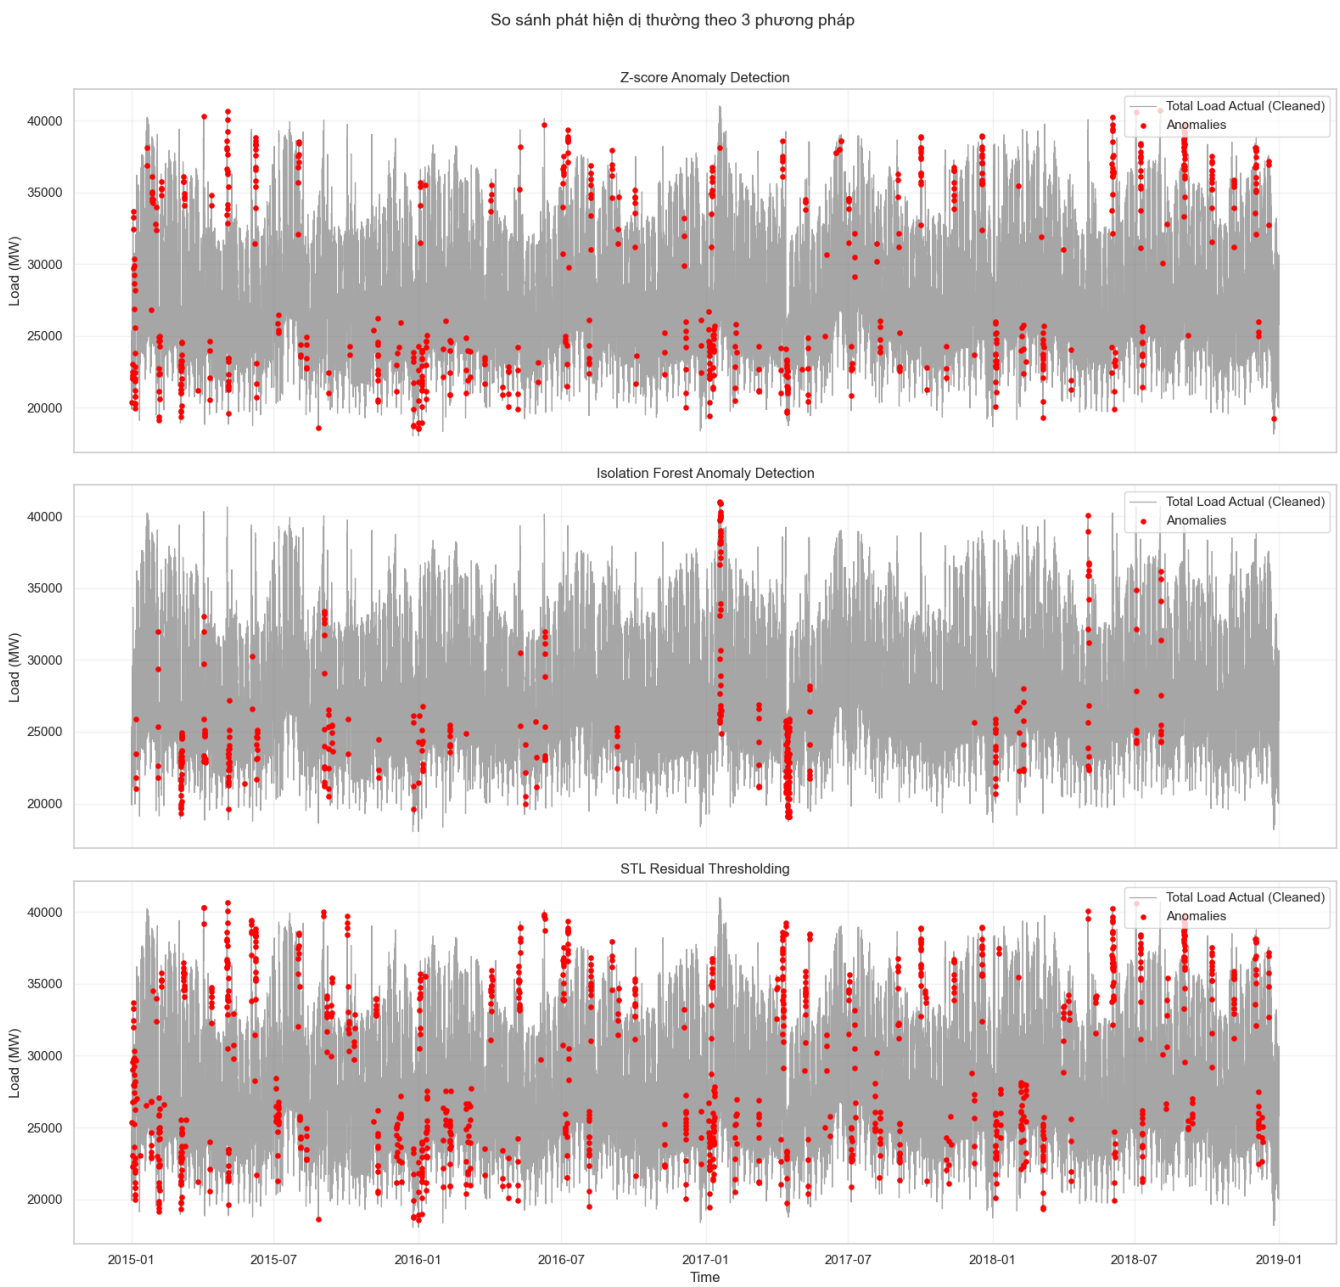

Hình 15: So sánh các điểm dị thường được phát hiện bởi Z-score, Isolation Forest và ngưỡng phần dư STL.

→ **Kết luận lựa chọn:** nhóm chọn **STL Residual Thresholding** làm lớp dị thường chính và dùng Z-score/Isolation Forest làm lớp đối chiếu. Cách kết hợp này giúp tăng độ bao phủ cảnh báo nhưng vẫn có cơ chế kiểm tra chéo để tránh cảnh báo giả quá mức.

Xây dựng ma trận đặc trưng thời gian

Nhóm chuyển chuỗi thời gian về bài toán supervised dự báo một bước trước $(t+1)$: mỗi dòng dữ liệu tại thời điểm t dùng để dự báo `load` tại thời điểm $t+1$. Ma trận đặc trưng được xây dựng theo nguyên tắc không dùng thông tin tương lai (causal features only), gồm:

- **Lag features:** $t-1, t-2, t-3, t-24$ (theo kết quả PACF), đại diện cho trí nhớ ngắn hạn và chu kỳ ngày.
- **Rolling features:** mean/std/min/max trên các cửa sổ 6h, 24h, 168h để mã hóa biến thiên nội ngày, nội tuần và mức dao động cục bộ.
- **Cyclic encoding:** sin/cos cho giờ, thứ, tháng nhằm biểu diễn chu kỳ mà không tạo ngắt quãng giả tại biên (ví dụ 23h sang 0h).
- **Calendar feature:** cờ ngày lễ Tây Ban Nha để bắt các dịch chuyển phụ tải do hành vi tiêu thụ đặc biệt.
- **Decomposition-based features:** `stl_trend`, `stl_seasonal`, `stl_resid` và các biến dẫn xuất để tách thông tin cấu trúc khỏi nhiễu.
- **Stationary feature:** `diff_1` từ chuỗi Box-Cox + sai phân bậc 1, giúp mô hình học động học thay đổi biên độ.

Nhận xét về vai trò của ma trận đặc trưng:

- Nhóm **lag + rolling** giúp mô hình học trí nhớ ngắn hạn và mức dao động cục bộ.
- Nhóm **cyclic + holiday** mã hóa đúng bối cảnh hành vi tiêu thụ theo lịch.
- Nhóm **STL + diff_1** giúp tách thông tin cấu trúc nền khỏi nhiễu và biến thiên đột ngột.

Trong khâu huấn luyện, nhóm tách train/test theo thời gian (năm cuối làm test) để bảo toàn thứ tự thời gian và tránh rò rỉ thông tin.
→ **Kết luận lựa chọn:** ma trận đặc trưng này đáp ứng đồng thời ba mục tiêu của bài toán dự báo tải điện: bám sát động học ngắn hạn, nắm bắt mùa vụ đa chu kỳ, và giữ được thông tin bối cảnh lịch.

5.4 Đánh giá pipeline

5.4.1 Đánh giá pipeline bằng dự báo một bước

Để kiểm định chất lượng toàn bộ pipeline, nhóm huấn luyện Random Forest Regressor trên dạng supervised $t+1$, chia tập theo thời gian (năm cuối làm test) (Breiman, 2001; scikit-learn developers, 2026a).

Kết quả trên tập test:

- MAE = 304.15 MW.
- RMSE = 505.03 MW.

Với mức phụ tải trung bình khoảng 28,700 MW, sai số MAE vào khoảng 1%, cho thấy pipeline tiền xử lý tạo ra không gian đặc trưng đủ tốt để mô hình nền đạt hiệu năng dự báo cao.

Phân tích feature importance cũng nhất quán với EDA trước đó:

- `load` chi phối mạnh nhất (xấp xỉ 89.51%).
- `diff_1` đứng thứ hai (xấp xỉ 5.04%).
- Cặp `hour_cos`, `hour_sin` xác nhận vai trò chu kỳ ngày.

Top đặc trưng quan trọng nhất của mô hình được thể hiện tại Hình 16.

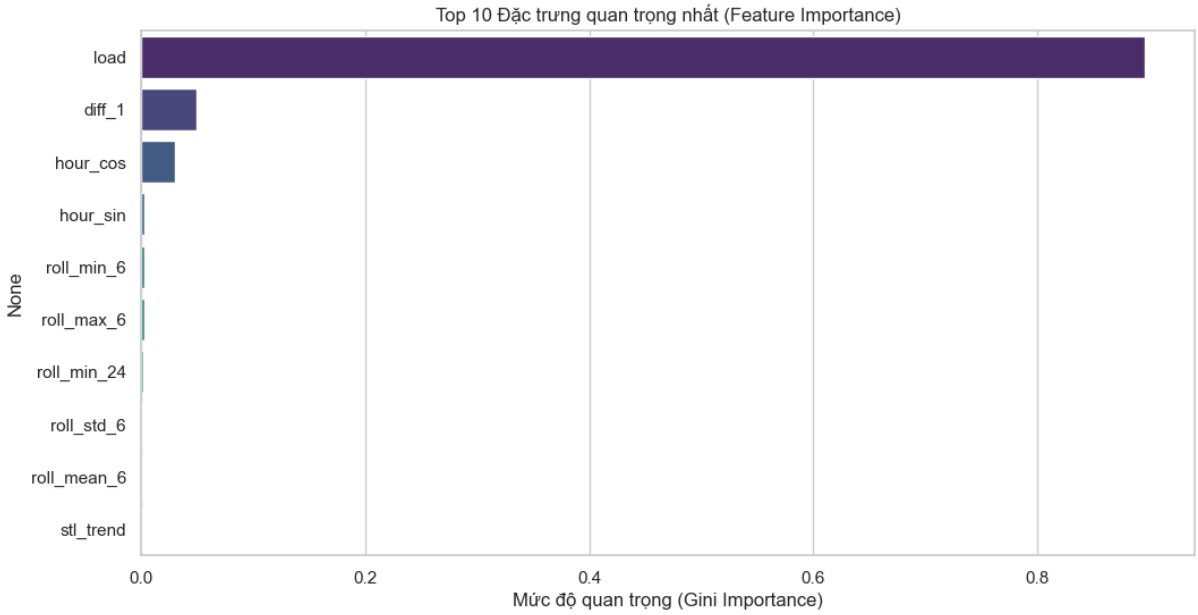

Hình 16: Top 10 đặc trưng quan trọng nhất của mô hình Random Forest cho bài toán dự báo $t+1$.

5.4.2 Phân tích nhân quả Granger đa biến

Nhóm kiểm định Granger ở lag 3 trên các chuỗi đã được chuẩn hóa tính dừng (bao gồm `ts_diff` cho tải và sai phân bậc 1 cho các biến ngoại sinh) (Granger, 1969).
Các quan hệ nổi bật theo F-statistic:

- load → solar: 947.4.
- load → price: 872.0.
- price → load: 670.3.
- solar → load: 633.9.
- load → gas: 544.6.

Nhóm biến gió có F-stat thấp hơn đáng kể, cho thấy tính độc lập cao hơn so với các biến còn lại. Kết quả này củng cố luận điểm rằng tải tiêu thụ và giá điện có cơ chế dẫn dắt hai chiều theo thời gian, và các nguồn phát linh hoạt như khí đóng vai trò cân bằng hệ thống.
Ma trận độ mạnh nhân quả Granger giữa các biến được trình bày tại Hình 17.

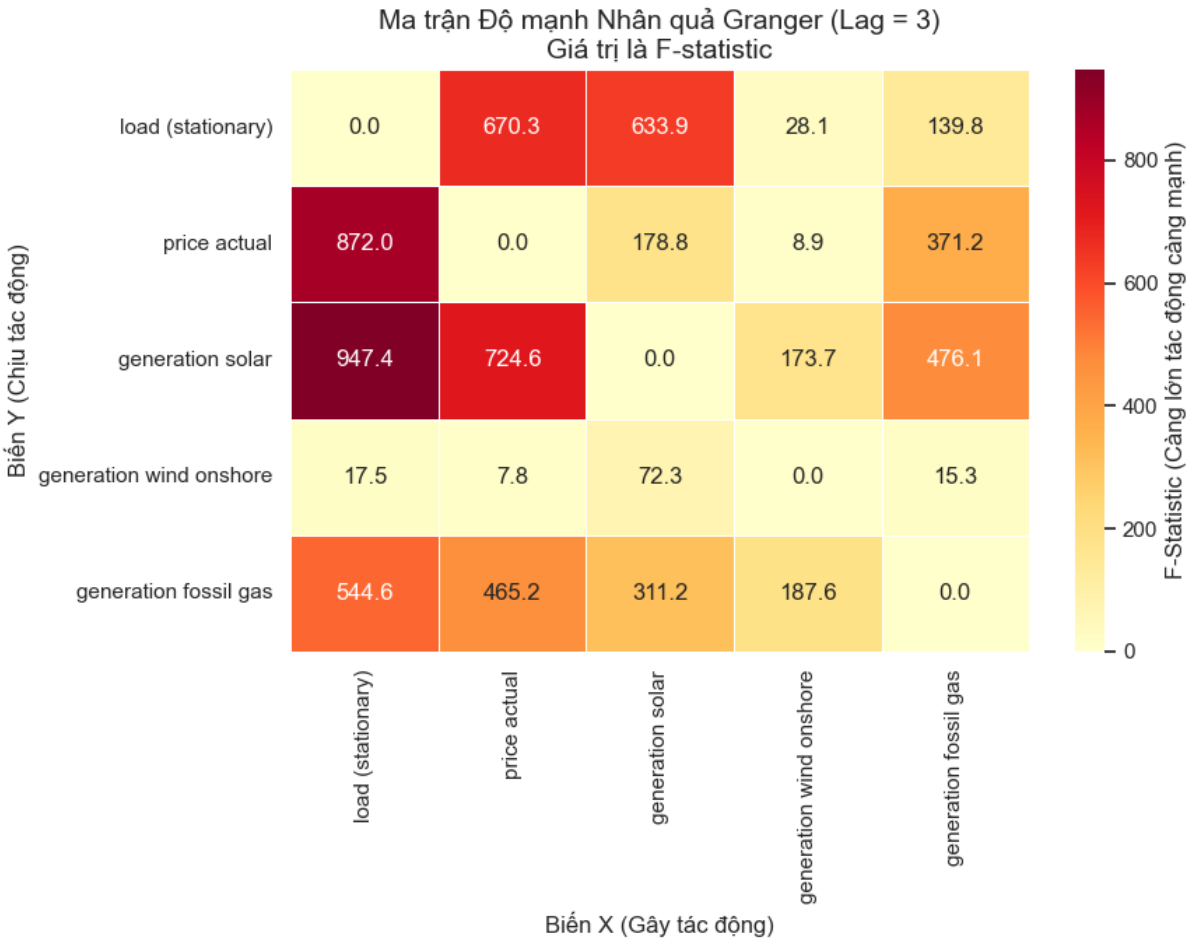

Hình 17: Ma trận độ mạnh nhân quả Granger (F-statistic) với lag 3 trên dữ liệu đã chuẩn hóa tính dừng.

Bảng 7 tổng hợp các kết quả định lượng chính cho từng bước trong pipeline tiền xử lý chuỗi thời gian, cung cấp cái nhìn tổng quan về hiệu quả của từng kỹ thuật đã triển khai.

Bước	**Lựa chọn**	**Kết quả chính**
Nội suy thiếu	Polynomial bậc 2	MAE $\approx$ 276.23, RMSE $\approx$ 508.74; Ljung-Box p-value $>$ 0.05
Ổn định chuỗi	Box-Cox + sai phân bậc 1	$\lambda \approx 0.6341$; KPSS từ 0.0100 lên 0.1000
Phân rã	STL (period = 168)	RVR thấp nhất hợp lý: 0.3319
Dị thường	STL residual thresholding	Phát hiện 1055 điểm bất thường
Dự báo $t+1$	Random Forest (baseline)	MAE = 304.15 MW; RMSE = 505.03 MW
Granger	Lag 3, dữ liệu dừng đa biến	Quan hệ mạnh giữa load, price, solar, gas

Bảng 7: Tổng hợp kết quả định lượng cho pipeline tiền xử lý chuỗi thời gian

5.5 Kết luận

Từ toàn bộ ba notebook temporal, nhóm đã xây dựng một pipeline tiền xử lý hoàn chỉnh cho dữ liệu chuỗi thời gian gồm các bước:

1. Chuẩn hóa trục thời gian theo giờ.
2. Điền thiếu bằng Polynomial bậc 2.
3. Ổn định chuỗi bằng Box-Cox + sai phân bậc 1.
4. Phân rã STL theo chu kỳ 168 giờ.
5. Phát hiện dị thường dựa trên phần dư STL.
6. Xây dựng đặc trưng lag–rolling–cyclic–calendar.
7. Đánh giá bằng dự báo một bước trước $(t+1)$.

Kết quả định lượng cho thấy pipeline này vừa đảm bảo tính đúng đắn thống kê (chuỗi đạt dừng sau biến đổi, phân rã tách được cấu trúc rõ ràng), vừa cho hiệu năng dự báo tốt trên dữ liệu thực tế với bài toán một bước trước (MAE 304.15 MW, RMSE 505.03 MW).

6 Kết luận

Tài liệu

Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society: Series B (Methodological)*, *26*(2), 211–252. https://doi.org/10.1111/j.2517-6161.1964.tb00553.x

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). Lof: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93–104. https://doi.org/10.1145/342009.335388

Category Encoders developers. (2026). *Category_encoders.binary.binaryencoder*. Retrieved April 18, 2026, from https://contrib.scikit-learn.org/category_encoders/binary.html

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). Stl: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, *6*(1), 3–73.

D'Agostino, R. B., & Pearson, E. S. (1973). Tests for departure from normality. empirical results for the distributions of b_2 and $\sqrt{b_1}$. *Biometrika*, *60*(3), 613–622. https://doi.org/10.1093/biomet/60.3.613

Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, *74*(366a), 427–431. https://doi.org/10.1080/01621459.1979.10482531

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, 226–231.

Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, *37*(3), 424–438. https://doi.org/10.2307/1912791

Guyon, I., Weston, J., Barnhill, S., & Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. *Machine Learning*, *46*(1–3), 389–422. https://doi.org/10.1023/A:1012487302797

He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). Adasyn: Adaptive synthetic sampling approach for imbalanced learning. *2008 IEEE International Joint Conference on Neural Networks*, 1322–1328. https://doi.org/10.1109/IJCNN.2008.4633969

Huber, P. J. (1981). *Robust statistics*. Wiley.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning with applications in r*. Springer.

Jolliffe, I. T. (2002). *Principal component analysis* (2nd ed.). Springer.

Kwiatkowski, D., Phillips, P. C. B., Schmidt, P., & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, *54*(1–3), 159–178. https://doi.org/10.1016/0304-4076(92)90104-Y

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *2008 Eighth IEEE International Conference on Data Mining*, 413–422. https://doi.org/10.1109/ICDM.2008.17

Ljung, G. M., & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, *65*(2), 297–303. https://doi.org/10.1093/biomet/65.2.297

Phillips, P. C. B., & Perron, P. (1988). Testing for a unit root in time series regression. *Biometrika*, *75*(2), 335–346. https://doi.org/10.1093/biomet/75.2.335

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, *63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

scikit-learn developers. (2026a). *Sklearn.ensemble.randomforestregressor*. Retrieved April 18, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html

scikit-learn developers. (2026b). *Sklearn.preprocessing.robustscaler*. Retrieved April 18, 2026, from https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.RobustScaler.html

SciPy Community. (2025a). *Scipy.stats.boxcox*. Retrieved April 18, 2026, from https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.boxcox.html

SciPy Community. (2025b). *Scipy.stats.normaltest*. Retrieved April 18, 2026, from https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.normaltest.html

statsmodels developers. (2025a). *Statsmodels.stats.diagnostic.acorr_ljungbox*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.acorr_ljungbox.html

statsmodels developers. (2025b). *Statsmodels.stats.outliers_influence.variance_inflation_factor*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.stats.outliers_influence.variance_inflation_factor.html

statsmodels developers. (2025c). *Statsmodels.tsa.seasonal.stl*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.STL.html

statsmodels developers. (2025d). *Statsmodels.tsa.stattools.adfuller*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.adfuller.html

statsmodels developers. (2025e). *Statsmodels.tsa.stattools.kpss*. Retrieved April 18, 2026, from https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.kpss.html

Troyanskaya, O., Cantor, M., Sherlock, G., Brown, P., Hastie, T., Tibshirani, R., Botstein, D., & Altman, R. B. (2001). Missing value estimation methods for dna microarrays. *Bioinformatics*, *17*(6), 520–525. https://doi.org/10.1093/bioinformatics/17.6.520

van Buuren, S., & Groothuis-Oudshoorn, K. (2011). Mice: Multivariate imputation by chained equations in r. *Journal of Statistical Software*, *45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03