ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

23TNT1

Đồ án 1

Đề tài: Tiền xử lý dữ liệu

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

22120457 - Khưu Hải Châu

23122006 - Lưu Thượng Hồng

23122020 - Nguyễn Thiên Ấn

23122034 - Lê Nguyên Khang

23122036 - Nguyễn Ngọc Khoa

Giáo viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Lê Nhựt Nam

Ngày 18 tháng 4 năm 2026

Mục lục

1 Giới thiệu **1**

2 Phân công công việc **1**

3 Tiền xử lý dữ liệu ảnh **2**

3.1 Dữ liệu sử dụng 2

3.2 Phân tích khám phá và chất lượng dữ liệu 2

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 2

3.4 Kết luận cho pipeline dữ liệu ảnh 3

4 Tiền xử lý dữ liệu dạng bảng **3**

4.1 Dữ liệu sử dụng 3

4.2 Phân tích thống kê khám phá (EDA chuyên sâu) 4

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 4

4.4 Kết luận cho pipeline dữ liệu bảng 5

5 Tiền xử lý dữ liệu chuỗi thời gian **6**

5.1 Dữ liệu sử dụng 6

5.2 Phân tích khám phá và chất lượng dữ liệu 6

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng 6

5.4 Kết luận cho pipeline dữ liệu chuỗi thời gian 6

6 Kết luận **7**

1 Giới thiệu

Báo cáo này trình bày quá trình tiền xử lý dữ liệu cho ba nhóm bài toán của đồ án: dữ liệu ảnh, dữ liệu bảng và dữ liệu chuỗi thời gian. Trọng tâm của nhóm là triển khai các kỹ thuật theo đề bài, đo lường định lượng tác động của từng bước, và đưa ra lựa chọn cuối cùng dựa trên bằng chứng thực nghiệm.

Về dữ liệu ảnh, nhóm phân tích phân bố lớp, phát hiện ảnh trùng bằng perceptual hash, đánh giá độ sáng/độ tương phản và thực hiện ablation theo kích thước ảnh để chọn cấu hình tiền xử lý phù hợp. Về dữ liệu bảng, nhóm sử dụng bộ *Mental Health Survey Dataset* để phân tích phân phối, cơ chế thiếu dữ liệu, đa cộng tuyến, và tác động của các chiến lược tiền xử lý đến hiệu năng phân loại. Về dữ liệu chuỗi thời gian, nhóm sử dụng dữ liệu tải điện Tây Ban Nha để đánh giá nội suy, kiểm định tính dừng, trích xuất đặc trưng, phát hiện dị thường, và kiểm chứng chất lượng dữ liệu đã xử lý thông qua bài toán dự báo một bước.

Tiêu chí xuyên suốt của báo cáo là: (i) mỗi kỹ thuật đều có số đo định lượng đi kèm; (ii) kết luận được đưa ra từ so sánh có đối chứng; và (iii) kết quả có thể tái lập từ notebook và các file đầu ra trong thư mục `data/processed`.

Thông tin dữ liệu sử dụng được trình bày trực tiếp trong subsection *Dữ liệu sử dụng* của từng phần: dữ liệu ảnh, dữ liệu bảng và dữ liệu chuỗi thời gian.

2 Phân công công việc

MSSV	Họ và tên	Công việc
22120457	Khưu Hải Châu	Phân tích dữ liệu ảnh
23122006	Lưu Thượng Hồng	Viết báo cáo
23122020	Nguyễn Thiên Ấn	Viết báo cáo
23122034	Lê Nguyên Khang	Phân tích dữ liệu dạng bảng
23122036	Nguyễn Ngọc Khoa	Phân tích dữ liệu chuỗi thời gian

Bảng 1: Phân công công việc của nhóm

3 Tiền xử lý dữ liệu ảnh

3.1 Dữ liệu sử dụng

Nhóm sử dụng tập ảnh phong cảnh gồm 6 lớp: *buildings, forest, glacier, mountain, sea, street*. Tập dữ liệu gốc có 5,000 ảnh RGB kích thước 150×150, tương ứng nhãn dạng số với 6 lớp.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số ảnh	$\geq$ 5,000	5,000	Đạt
Kích thước ảnh	Đồng nhất	150×150×3	Đạt
Số lớp	$\geq$ 5	6 lớp	Đạt

Bảng 2: Kiểm tra tiêu chí lựa chọn dữ liệu ảnh

3.2 Phân tích khám phá và chất lượng dữ liệu

Phân bố lớp. Tập dữ liệu có phân bố khá đều giữa các lớp. Số ảnh theo lớp lần lượt là: buildings (789), forest (778), glacier (863), mountain (870), sea (814), street (886). Tỉ lệ lớp lớn nhất/lớp nhỏ nhất là 1.14, nhỏ hơn ngưỡng 3, do đó dữ liệu được xem là cân bằng.

Phát hiện ảnh trùng. Nhóm dùng perceptual hash (pHash) để dò ảnh trùng hoặc gần trùng. Kết quả phát hiện 7 ảnh trùng trên 5,000 ảnh (0.14%). Sau khi loại trùng, tập dữ liệu còn 4,993 ảnh.

Độ sáng và tương phản toàn cục. Trên tập đã loại trùng, thống kê mức sáng và độ tương phản cho thấy biên độ biến thiên lớn, phù hợp với đặc thù dữ liệu cảnh ngoài trời.

Thuộc tính	**Độ lệch chuẩn**	**Nhỏ nhất**	**Lớn nhất**
Độ sáng toàn cục	30.8812	18.6553	210.4190
Độ tương phản	13.1707	13.6147	104.6476

Bảng 3: Thống kê độ sáng và độ tương phản trên 4,993 ảnh

3.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Ablation theo kích thước ảnh. Nhóm đánh giá pipeline cổ điển *flatten + PCA-100 + Logistic Regression / k-NN* bằng 5-fold CV trên mẫu con 2,500 ảnh để chọn kích thước resize phù hợp.

Cấu hình	**LogReg (mean ± std)**	**k-NN (mean ± std)**
Baseline 150×150	0.4924 ± 0.0195	0.4640 ± 0.0194
Resize 32×32	0.4836 ± 0.0205	0.4676 ± 0.0165
Resize 64×64	**0.4936 ± 0.0177**	**0.4672 ± 0.0186**
Resize 128×128	0.4884 ± 0.0162	0.4648 ± 0.0207

Bảng 4: So sánh ablation theo kích thước ảnh (n=2,500, PCA-100, 5-fold CV)

Dựa trên kết quả trên, nhóm chọn kích thước 64×64 cho các bước xử lý và mô hình hóa tiếp theo vì cho hiệu năng tổng thể tốt nhất trong các cấu hình thử nghiệm.

3.4 Kết luận cho pipeline dữ liệu ảnh

Pipeline đề xuất cho dữ liệu ảnh gồm: (i) loại ảnh trùng bằng pHash, (ii) resize ảnh về 64×64, (iii) chuẩn bị đặc trưng phù hợp mô hình (ví dụ flatten + PCA cho mô hình cổ điển). Quy trình này giữ được cân bằng lớp, giảm nhiễu dữ liệu trùng và tối ưu chi phí tính toán so với dùng ảnh gốc 150×150.

4 Tiền xử lý dữ liệu dạng bảng

4.1 Dữ liệu sử dụng

Nhóm sử dụng *Mental Health Survey Dataset* cho phần dữ liệu bảng. Tập dữ liệu được lưu tại `data/raw/mental_health_train.csv` và `data/raw/mental_health_test.csv`. Tập huấn luyện có 140,700 bản ghi, gồm các nhóm thuộc tính nhân khẩu học, học tập/công việc và thói quen sinh hoạt, với nhãn mục tiêu *Depression*. Bộ dữ liệu này thỏa đầy đủ tiêu chí đề bài: quy mô lớn, có đồng thời thuộc tính số và phân loại, và có tỉ lệ thiếu cao ở một số biến.

Tiêu chí	**Yêu cầu**	**Thực tế**	**Kết quả**
Số records	$\geq$ 10,000	140,700	Đạt
Số thuộc tính	$\geq$ 10	17 features	Đạt
Số + phân loại	Có	8 số + 9 phân loại	Đạt
Tỉ lệ thiếu $\geq$ 5%	Có	80.17% (Academic Pressure)	Đạt

Bảng 5: Kiểm tra tiêu chí lựa chọn dữ liệu bảng

4.2 Phân tích thống kê khám phá (EDA chuyên sâu)

Kiểm tra phân phối. Nhóm áp dụng kiểm định D'Agostino-Pearson cho toàn bộ 8 thuộc tính số (do $n > 5000$). Kết quả cho thấy tất cả biến đều có p-value xấp xỉ 0, tức là không tuân theo phân phối chuẩn. Đồng thời, kurtosis trung bình quanh -1.2 cho thấy dữ liệu có xu hướng gần đều.

Tương quan đa biến. Ma trận tương quan Pearson và Spearman chỉ ra biến *Age* có liên hệ mạnh nhất với nhãn *Depression* với $r = -0.565$ (Pearson) và $\rho = -0.541$ (Spearman). Kết quả này được dùng làm căn cứ ban đầu cho bước chọn đặc trưng ở phần sau.

Phân tích giá trị thiếu. Cấu trúc thiếu dữ liệu thể hiện rõ cơ chế MAR theo nhóm đối tượng: nhóm sinh viên thiếu chủ yếu ở *Work Pressure* và *Job Satisfaction*, trong khi nhóm người đi làm thiếu ở *Academic Pressure*, *CGPA*, và *Study Satisfaction*. Vì vậy, chiến lược điền khuyết được thiết kế theo ngữ cảnh từng nhóm thay vì dùng một quy tắc đồng nhất cho toàn bộ tập.

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Xử lý giá trị thiếu có kiểm soát

Nhóm so sánh 7 chiến lược điền khuyết trên kịch bản tạo thêm 10% thiếu MCAR và đánh giá bằng RMSE. Kết quả trung bình cho thấy **Mean** đạt RMSE tốt nhất (5.78), trong khi **Mode** kém nhất (9.03, cao hơn khoảng 66%). Với bài toán đơn biến, kNN và MICE cho kết quả gần tương đương Mean.

Phát hiện và xử lý ngoại lai

Các phương pháp IQR, Z-score, Isolation Forest, LOF và DBSCAN đều được triển khai và so sánh. Nhóm chọn **Isolation Forest** với contamination $= 0.05$ làm cấu hình chính vì ổn định trên dữ liệu không chuẩn. Kiểm định KS trước/sau khi loại ngoại lai cho 8 biến đều có $p < 0.05$, cho thấy việc loại ngoại lai làm thay đổi phân phối một cách có ý nghĩa thống kê.

Chuẩn hóa dữ liệu có kiểm định

Nhóm thử Min-Max, Z-score, Robust Scaling và Quantile Transform. Kết quả Levene kết hợp quan sát violin plot cho thấy **Robust Scaling** là lựa chọn cân bằng nhất: giảm ảnh hưởng ngoại lai nhưng vẫn giữ cấu trúc phân phối tốt hơn Quantile Transform.

Mã hóa biến phân loại nâng cao

Ngoài One-Hot và Ordinal, nhóm triển khai thêm Target Encoding (K-fold), Binary Encoding và Frequency Encoding. Đánh giá bằng VIF cho thấy **Binary Encoding** tốt nhất (mean VIF = 4.21), trong khi **Frequency Encoding** gây đa cộng tuyến rất cao (mean VIF = 889.59).

Lựa chọn và giảm chiều đặc trưng

Nhóm đánh giá MI, RF importance, RFE và PCA bằng F1-score cross-validation 5-fold. Ở mức $k = 10$, RF đạt F1 = 0.809 (cao hơn MI với F1 = 0.784). Khi $k \geq 15$, hiệu năng bão hòa quanh F1 ≈ 0.813, cho thấy số đặc trưng hữu ích thực tế không cần quá lớn.

Xử lý mất cân bằng lớp

Trên tập test giữ nguyên phân phối gốc, **SMOTE** đạt F1-macro cao nhất (0.883), nhỉnh hơn baseline (0.882) và ADASYN (0.874). Baseline vẫn có AUC-ROC cao (0.969), nhưng SMOTE cho cân bằng Precision–Recall tốt hơn cho bài toán phát hiện lớp thiểu số.

Kỹ thuật	**Phương pháp tốt nhất**	**Kém nhất**	**Chỉ số chính**
Điền khuyết	Mean	Mode	RMSE: 5.78 vs 9.03
Ngoại lai	IsoForest (0.05)	—	KS: tất cả biến $p < 0.05$
Chuẩn hóa	Robust Scaling	Quantile (uniform)	Levene + violin plot
Mã hóa	Binary Encoding	Frequency Encoding	VIF: 4.21 vs 889.59
Chọn đặc trưng	RF importance ($k = 10$)	MI ($k = 5$)	F1: 0.809 vs 0.713
Cân bằng lớp	SMOTE	Random Under-sampling	F1-macro: 0.883 vs 0.866

Bảng 6: Tổng hợp kết quả định lượng cho phần dữ liệu bảng

4.4 Kết luận cho pipeline dữ liệu bảng

Từ các kết quả trên, pipeline đề xuất cho dữ liệu bảng gồm: điền khuyết theo ngữ cảnh dữ liệu, phát hiện ngoại lai bằng Isolation Forest (0.05), chuẩn hóa bằng Robust Scaling, mã hóa ưu tiên Binary cho biến nhiều mức, chọn đặc trưng theo RF importance/RFE, và cân bằng lớp bằng SMOTE khi huấn luyện.

5 Tiền xử lý dữ liệu chuỗi thời gian

5.1 Dữ liệu sử dụng

Nhóm sử dụng bộ dữ liệu tiêu thụ điện Tây Ban Nha (*Spain Energy Consumption Dataset*) cho phần chuỗi thời gian. Dữ liệu thô được lưu tại `data/raw/P4_energy_dataset.csv` và dữ liệu đã xử lý trung gian được lưu tại `data/processed/P4_energy_dataset_processed.csv`.

Tập dữ liệu có 35,064 quan sát theo tần suất giờ trong giai đoạn 2015–2019. Biến mục tiêu chính là tải điện (MW), đồng thời có các biến hỗ trợ theo ngữ cảnh thời gian để phục vụ bước nội suy, kiểm định tính dừng, trích xuất đặc trưng và dự báo một bước trước.

Bộ dữ liệu này phù hợp với yêu cầu đề bài ở ba điểm: (i) đủ chiều dài chuỗi theo nhiều năm; (ii) có tính mùa vụ theo ngày và theo tuần; và (iii) có ý nghĩa thực tiễn rõ ràng cho bài toán tiền xử lý phục vụ dự báo.

5.2 Phân tích khám phá và chất lượng dữ liệu

Phần EDA chuỗi thời gian tập trung vào ba nhóm tín hiệu chính: xu hướng dài hạn, mùa vụ ngắn hạn theo chu kỳ ngày/tuần, và mức độ nhiễu theo từng giai đoạn. Ngoài các thống kê mô tả theo cửa sổ thời gian, nhóm sử dụng trực quan hóa theo khung giờ và theo ngày trong tuần để kiểm tra tính ổn định của chuỗi trước khi nội suy và biến đổi.

5.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

Pipeline tiền xử lý cho dữ liệu chuỗi thời gian được tổ chức theo thứ tự: xử lý giá trị thiếu theo mốc thời gian, kiểm định tính dừng, tạo đặc trưng trễ (lag) và đặc trưng cuộn (rolling), sau đó đánh giá bằng các chỉ số lỗi dự báo ở bài toán một bước trước. Kết quả chi tiết của từng kỹ thuật được tổng hợp để chọn cấu hình tiền xử lý cân bằng giữa độ chính xác và tính ổn định theo thời gian.

5.4 Kết luận cho pipeline dữ liệu chuỗi thời gian

Từ các phân tích trên, pipeline đề xuất cho dữ liệu chuỗi thời gian gồm: chuẩn hóa trục thời gian theo tần suất giờ, nội suy có kiểm soát cho điểm thiếu, kiểm định tính dừng trước/sau biến đổi, xây dựng tập đặc trưng lag–rolling theo chu kỳ ngày và tuần, và đánh giá bằng nhóm chỉ số lỗi dự

báo trước khi chuyển sang bước mô hình hóa.

6 Kết luận